

Algoritmos e Linguagens de Programação para Ciência de Dados (ALPCD)

Lic. em Ciência de Dados (2ºano)

Trabalho Prático nº 2 (*Web scrapping*)

Ano letivo 2024/2025

1 Objetivos e organização

Este trabalho prático, que aplica toda a matéria lecionada até à data, tem como principais objetivos:

- Aplicar os conhecimentos adquiridos sobre *Web Scraping* para desenvolver, em **Python**, extratores de datasets a partir de sites recorrendo aos módulos **beautifulsoup2** e **requests**;
- Reforçar a utilização do módulo 're' para limpeza a pré-processamento dos dados.

Neste TP, que se pretende que seja resolvido rapidamente, **aprecia-se a imaginação/criatividade** dos grupos ao incluir outros processamentos!

Deve colocar a sua solução final no repositório git do seu grupo até **dia 15 de Dezembro**.

O programa desenvolvido será apresentado aos membros da equipa docente, totalmente pronto e a funcionar e será defendido por **todos os elementos do grupo** no dia **18 de Dezembro**.

2 Enunciado

Mais uma vez, pretende-se que o produto final seja uma *Command Line Interface* (CLI) que permita a um utilizador interagir e obter dados da REST API e enriquecê-los com informações de outros websites.

Uma CLI recebe como argumento um texto e executa determinadas funções necessárias para produzir uma certa saída que providencie os dados solicitados.

Para isso é recomendável o uso da biblioteca **typer**, uma vez que é uma biblioteca simples que facilita a construção de CLIs e permite melhorar o output, validar o input, etc... de maneira rápida e com menos necessidade de produzir código para atingir o objetivo final (menos manual).

Pretende-se que as novas funcionalidades sejam adicionadas ao trabalho realizado no TP1.

Para cada alínea crie ou altere os comandos da CLI de maneira a responder ao pedido:

- a) A CLI deverá permitir obter informações sobre um jobID específico utilizando a API do *itjobs.pt* e adicionar informações acerca da empresa que publicita o trabalho.

Utilizando o *website* <https://www.ambitionbox.com>, recolha as seguintes informações acerca da empresa e adicione-as ao objeto JSON que será impresso no terminal¹:

- Rating geral da empresa 0-5;

¹utilize este headers no pedido :{ "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:98.0) Gecko/20100101 Firefox/98.0", "Accept": "text/html,application/xhtml+xml,application/xml;q=0.9,image/avif,image/webp,*/*;q=0.8", "Accept-Language": "en-US,en;q=0.5", "Accept-Encoding": "gzip, deflate", "Connection": "keep-alive", "Upgrade-Insecure-Requests": "1", "Sec-Fetch-Dest": "document", "Sec-Fetch-Mode": "navigate", "Sec-Fetch-Site": "none", "Sec-Fetch-User": "?1", "Cache-Control": "max-age=0" } caso contrário será bloqueado pelo *website*.

- Descrição da empresa;
- Principais benefícios de trabalhar na empresa.

Exemplo :

```
> python jobs.py get jobID
> {"id":125378,...,"rating":4,"ambition_box_description":"...", "ambition_box_benefits":"..."}
```

- b) A CLI deverá permitir ao utilizador, a partir da lista de trabalhos, criar uma contagem de vagas por tipo/nome da posição e por região.

Deve produzir um ficheiro *CSV* com as seguintes colunas:

- Zona;
- Tipo de Trabalho;
- Nº de vagas.

Exemplo :

```
> python jobs.py statistics zone
> Ficheiro de exportação criado com sucesso.
```

- c) A CLI deverá permitir ao utilizador, a partir da lista de trabalhos no textitwebsite (ambitionbox), recolher as principais skills (top10) pedidas para um determinado trabalho. Para cada skill encontrada, deve apresentar o seu nome e a contagem de ocorrências. Por exemplo para data scientist, a url utilizando o *website* seria: <https://www.ambitionbox.com/jobs/search?tag=data%20scientist>.

Deve imprimir a informação no terminal em formato *JSON*.

Exemplo :

```
> python jobs.py list skills "data scientist"
> [{skill:"python", count:1000},...]
```

- d) Explore pelo menos uma fonte de dados alternativa (*website*) que poderia ser adicionada para recolher as informações pedidas acima.

Justifique porque a escolheu e faça a implementação de pelos menos a alínea a).

- e) Para cada uma das funcionalidades (a), (c) deve adicionar a funcionalidade **de exportar para CSV** a informação com os campos relevantes. Para isso pode adicionar um argumento opcional a cada um dos comandos que permite indicar se pretende criar o *CSV*.