



Universidade do Minho
Licenciatura em Ciência de Dados

Unidade Curricular de Ciência de Dados em Grande Escala

Ano Letivo de 2025/2026, 2º Semestre

Sistema de Análise de Dados de Grande Escala para Suporte à Decisão em Distribuição Especializada de Bebidas

Dean Kuijf A106832, Fernando Leite A106822, Lorenzo Perry A106865, Tomás Bourbon A106824

Maio, 2026

Data da Receção	
Responsável	
Avaliação	
Observações	

Sistema de Análise de Dados de Grande Escala para Suporte à Decisão em Distribuição Especializada de Bebidas

Dean Kuijf A106832, Fernando Leite A106822, Lorenzo Perry A106865, Tomás Bourbon A106824

Maio, 2026

Resumo

O presente trabalho descreve a concepção e implementação de um sistema de análise de dados de grande escala para suporte à decisão no contexto da distribuição especializada de bebidas, tendo como caso de estudo a empresa fictícia BKLP Supply & Distribution, que opera em regime B2B(Business to business) e B2C(business to customer) nas 16 regiões administrativas alemãs.

O sistema foi desenvolvido sobre uma arquitetura Data Lakehouse organizada segundo o modelo *Medallion* em camadas *Bronze*, *Silver* e *Gold*, implementada com Apache Spark, Delta Lake e MinIO como plataforma de *object storage*. O processo de integração de dados incorpora três fontes heterogêneas: dados transacionais de vendas em formato CSV, registos meteorológicos diários obtidos via API Open-Meteo em formato JSON, e publicações sintéticas de redes sociais em formato txt sobre as quais foi aplicado um modelo de Processamento de Linguagem Natural para extração de sentimento. O pipeline executa semanalmente com mecanismos de Change Data Capture, checkpointing e idempotência, sendo orquestrado pelo Prefect. Os dados são materializados num Data Warehouse em PostgreSQL e disponibilizados através de *dashboards* analíticos em Power BI.

Para além disso foram desenvolvidos três modelos de *machine learning*, dois modelos de previsão de procura por produto e região, com e sem variáveis climáticas, e um modelo de classificação de risco de churn por cliente.

Índice

1. Definição do Sistema	7
1.1 Contexto de Aplicação.....	7
1.2 Motivação e Objetivos do Trabalho.....	7
1.3 Análise da Viabilidade do Processo.....	9
1.4 Recursos e Equipa de Trabalho	10
1.5 Plano de Execução do Projeto.....	11
2. Levantamento e Análise de Requisitos	12
2.1 Método Adotado	12
2.2 Organização dos Requisitos Levantados.....	13
2.3 Análise e Validação Geral dos Requisitos	14
3. Implementação do Sistema de Análise	15
3.1 Apresentação Geral.....	15
3.2 Fontes de Dados	18
3.3 Área de Preparação de Dados (staging area).....	21
3.4 Área de Dados do Sistema de Análise	27
3.5 O Processo de Integração de Dados	44
4. Exploração e Análise de Dados	57
4.1 Organização geral do sistema de dashboarding	57
4.2 Serviços de exploração e análise implementados	57
5. O Sistema de Análise de Tendências de Aquisição de Produtos	61
5.1 Definição do problema e compreensão dos elementos de análise envolvidos.....	61
5.2 Seleção e preparação dos dados.	62
5.3 Identificação e fundamentação da técnica de análise.....	63
5.4 Construção do modelo de análise.....	64
5.5 Validação do desempenho do modelo.....	66
5.6 Avaliação dos Resultados	66
6. Conclusões e Trabalho Futuro	67
6.1 Conclusões.....	67
6.2 Trabalho Futuro	68
7. Bibliografia	69
Ferramentas e Tecnologias:.....	69
Anexos.....	71

Índice de imagens

Figura 1 - Diagrama de Gantt.....	11
Figura 2 - Modelo Conceptual de (Golfarelli-Maio-Rizzi)	42
Figura 3 - Modelo multidimensional(star-schema).....	43
Figura 4 - BPMN completo Fonte: Elaboração Própria (Bizagi Modeler, 2024)	49
Figura 5 - Início do BPMN	50
Figura 6 - Segunda parte do BPMN	50
Figura 7 - Parte final do BPMN	51
Figura 8 - Dashboard de Análise de Vendas.....	58
Figura 9 - Dashboard da correlação clima-vendas	59
Figura 10 - Dashboard de análise de sentimento Social	60
Figura 11- Dashboard de previsão e análise de tendências	61

Índice de Tabelas

Tabela 1- Data understanding da fonte “vendas”	19
Tabela 2- Data understanding da fonte “meteorologia”	20
Tabela 3 - Mapeamento dos nomes das regiões.....	23
Tabela 4 - Estrutura de “vendas” no final da camada silver.....	24
Tabela 5 - Estrutura de “meteorologia” no final da camada silver.....	25
Tabela 6 - Estrutura de “tweets” no final da camada silver	26
Tabela 7- Grãos definidos para as tabelas de facto	28
Tabela 8 - Matriz de decisão	29
Tabela 9 - Caracterização das dimensões	31
Tabela 10 - Estrutura da Dim_calendário	32
Tabela 11 - Estrutura da dim_produto	33
Tabela 12 - Estrutura da dim_cliente.....	34
Tabela 13 - Exemplo SCD tipo 2 na dim_customer	35
Tabela 14 - caracterização da tabela de factos tf_vendas.....	35
Tabela 15 - Atributos das dimensões na tabela de factos tf_vendas	36
Tabela 16 - Atributos com medidas da tabela de factos tf_vendas.....	37
Tabela 17- Caracterização da tabela de factos tf_meteorologia	37
Tabela 18 - Atributos das dimensões na tabela de factos tf_meteorologia	38
Tabela 19 - Atributos com medidas da tabela de factos tf_meteorologia.....	39
Tabela 20 - Caracterização da tabela de factos tf_tweets	39
Tabela 21- Caracterização da tabela de factos tf_tweets	40
Tabela 22 - Atributos com medidas da tabela de factos tf_tweets	41
Tabela 23 - Source-to-target Datamap de “Vendas”	45
Tabela 24- Source to target datamap de “Meteorologia”	47
Tabela 25 - Source to target Datamap de “tweets”	48

1. Definição do Sistema

1.1 Contexto de Aplicação

O caso de estudo centra-se na empresa distribuidora BKLP Supply & Distribution, uma organização no setor de bebidas que opera em regime misto Business-to-Business (B2B) e Business-to-Consumer (B2C) em todo o território alemão, abrangendo as 16 regiões administrativas, os Bundesländer. A empresa gere um catálogo vasto e diversificado que abrange águas, sumos, refrigerantes e bebidas alcoólicas, servindo a sua rede de clientes retalhistas e consumidores finais através de múltiplos armazéns físicos e de uma plataforma centralizada de comércio eletrónico.

O principal desafio operacional desta distribuidora reside na elevada volatilidade da procura, fortemente influenciada por fatores externos dinâmicos que o histórico de vendas isolado não consegue capturar. Vagas de calor súbitas disparam exponencialmente a procura por águas e cervejas, enquanto o frio favorece vinhos e bebidas destiladas, por exemplo. A incapacidade de antecipar estes padrões resulta em ruturas de *stock* com perda direta de receita e insatisfação do cliente ou em excesso de inventário, com aumento dos custos de armazenamento e risco de quebra de produtos.

Para mitigar este problema, o sistema de suporte à decisão desenvolvido integra três fontes distintas de dados, refletindo a heterogeneidade característica de um ambiente de *Big Data*. Os dados semiestruturados englobam duas fontes distintas: o histórico massivo de transações de vendas em formato CSV, contendo informação sobre produtos, quantidades, clientes e localizações, e os registos meteorológicos diários provenientes de chamadas à API Open-Meteo em formato JSON temperatura máxima e precipitação para cada uma das 16 regiões alemãs. Os dados não estruturados consistem em publicações sintéticas de texto livre que simulam a recolha de dados de redes sociais, sobre as quais são aplicados algoritmos de Processamento de Linguagem Natural para extração de sentimento associado a produtos e regiões.

1.2 Motivação e Objetivos do Trabalho

No setor da distribuição de bebidas, a volatilidade da procura é um dos maiores desafios operacionais. O consumo de categorias específicas de produtos está intrinsecamente ligado a fatores externos que vão além do histórico de transações. Por um lado, as condições meteorológicas, ou seja, picos de calor ou períodos de precipitação elevada alteram o comportamento de compra. Por outro, as tendências sociais e o sentimento público, frequentemente expressos em redes sociais, criam picos de procura imprevisíveis para produtos específicos.

Os sistemas tradicionais de gestão de inventário operam por norma de forma reativa, baseando-se apenas em dados transacionais isolados. A motivação deste projeto nasce da necessidade de transformar esta abordagem numa estratégia proativa e preditiva. O sistema de suporte à decisão proposto justifica-se pela capacidade de integrar, processar e retirar valor de grandes volumes de dados de natureza altamente heterogénea: transações de vendas em formato CSV, registos meteorológicos em formato JSON obtidos via API Open-Meteo, e publicações sintéticas de texto livre que simulam dados de redes sociais.

Objetivos do Trabalho

Desenvolvimento de um Pipeline de Integração de Dados em Arquitetura Data Lakehouse Construir uma arquitetura centralizada, organizada em camadas Bronze, Silver e Gold, capaz de extrair e unificar de forma automática os dados sintéticos transacionais de vendas, os registos meteorológicos das 16 regiões alemãs e as publicações sintéticas de redes sociais. O *pipeline* implementa um mecanismo de Change Data Capture (CDC), garantindo que apenas os dados novos são processados em cada ciclo semanal de atualização.

Processamento Analítico e NLP em Grande Escala Utilizar o Apache Spark como motor de processamento para limpar, normalizar e cruzar os dados das três fontes, aplicando o modelo de Processamento de Linguagem Natural sobre as publicações para extração da polaridade de sentimento positivo, negativo ou neutro e deteção de menções a produtos e regiões.

Análise de Tendências e Correlação Multidimensional Estabelecer correlações estatísticas entre as variáveis meteorológicas, o sentimento social agregado e o volume real de vendas, identificando quais os produtos e categorias mais reativos a variações climáticas e quais os mais influenciados por fenómenos de sentimento online.

Construção de um Sistema de Dashboarding Disponibilizar interfaces visuais dinâmicas em Power BI, ligadas diretamente a um Data Warehouse, que traduzam os modelos analíticos complexos em *insights* claros e acionáveis para os decisores de negócio.

Modelação Preditiva de Tendências de Procura Desenvolver e validar modelos de previsão de séries temporais para identificar e antecipar a procura por categoria e produto em cada uma das 16 regiões alemãs, incorporando variáveis externas como temperatura máxima e sentimento social como features adicionais.

Decisões Suportadas pelo Sistema

Gestão Dinâmica de Inventário e Logística O sistema suporta decisões de alocação antecipada de *stocks* com uma antecedência de alguns meses, cruzando as previsões de procura geradas pelos modelos com os padrões climáticos e as tendências de sentimento social detetadas. A correlação estabelecida entre temperatura máxima e volume de vendas de categorias como água e refrigerantes permite antecipar um aumento de procura numa região específica antes de uma vaga de calor, evitando ruturas de *stock* e os custos associados à redistribuição de emergência entre armazéns.

Estratégias de Marketing Ágil O sistema suporta decisões de lançamento de campanhas promocionais direcionadas com base na identificação de produtos com sentimento positivo crescente mas volume de vendas ainda estagnado. Este sinal precoce de oportunidade comercial não é detetável por sistemas baseados apenas em histórico de vendas. Adicionalmente, a análise dos tweets rejeitados por produto não reconhecido fornece *inputs* para decisões de expansão de portfólio, identificando produtos mencionados pelos clientes que a distribuidora ainda não comercializa.

Otimização de Portfólio e Gestão de Clientes O sistema suporta a identificação precoce de declínios na popularidade de produtos, conjugando sentimento negativo online com quebras consistentes de volume de vendas, permitindo ajustar as recomendações de compra feitas à rede de clientes retalhistas. Paralelamente, a identificação automática de clientes sem compras nos últimos 4 meses suporta decisões de intervenção proativa para mitigação do risco de churn.

1.3 Análise da Viabilidade do Processo

A viabilidade deste projeto assenta na necessidade crítica de transitar de uma gestão reativa para uma gestão preditiva no setor da distribuição especializada de bebidas. A complexidade de cruzar grandes volumes de dados de vendas com variáveis externas dinâmicas torna a análise manual inviável, justificando o investimento numa solução assente em arquiteturas de *Big Data*.

Do ponto de vista técnico, todas as tecnologias necessárias para a implementação do sistema são *open-source*, amplamente documentadas e com comunidades ativas

Do ponto de vista operacional, o sistema integra-se naturalmente no fluxo de decisão da organização idealizada, fornecendo *insights* que permitem antecipar tendências de consumo com base na evidência produzida pelo cruzamento das três fontes de dados. A adoção de *dashboards* em Power BI garante acessibilidade a perfis não técnicos.

Como medidas concretas de viabilidade do projeto destacam-se os seguintes indicadores:

- Cobertura geográfica total: o sistema cobre a totalidade das 16 regiões administrativas alemãs, garantindo que nenhuma área de negócio fica excluída da análise, o que representa uma cobertura de 100% do território operacional da empresa.
- Disponibilidade e custo das fontes de dados: as três fontes de dados utilizadas têm custo zero de aquisição. Os dados de vendas são gerados internamente, os dados meteorológicos são obtidos gratuitamente via API Open-Meteo, e os dados de redes sociais são simulados sinteticamente, eliminando qualquer dependência financeira de fornecedores externos.
- Compatibilidade técnica: todas as ferramentas selecionadas são compatíveis entre si e integráveis através de conectores nativos.
- Qualidade dos dados: a fonte primária de dados de vendas é um dataset sintético de retalho especializado com estrutura bem definida e domínios categóricos consistentes, o que garante à partida uma base de dados de qualidade adequada para suportar o sistema de análise pretendido.
- Modelos NLP validados: a existência de modelos de análise de sentimento pré-treinados e validados cientificamente, elimina a necessidade de desenvolver modelos de raiz, reduzindo significativamente o risco técnico e o tempo de implementação.
- Escalabilidade comprovada: a arquitetura que será adotada é parecida a aquelas utilizadas por empresas como Databricks, Microsoft e AWS para volumes de dados na ordem dos *petabytes*, garantindo que o sistema suportará o crescimento futuro do volume de dados sem necessidade de redesenho muito complexo.

1.4 Recursos e Equipa de Trabalho

Equipa de Trabalho

A equipa de desenvolvimento será composta por quatro elementos, todos alunos do 3º ano da Licenciatura em Ciência de Dados da Universidade do Minho, com formação nas áreas de engenharia de dados, ciência de dados e análise de dados:

- **Dean Kuijf**
- **Fernando Leite**
- **Lorenzo Perry**
- **Tomás Bourbon**

Dado o carácter académico do projeto, não existirá uma divisão formal de papéis: todos os elementos participarão de forma transversal nas diferentes fases de desenvolvimento, desde a exportação e transformação de dados até à construção dos modelos analíticos e dashboards de visualização.

Recursos Materiais

O desenvolvimento e execução do sistema serão realizados em ambiente local, nos equipamentos pessoais dos membros da equipa, sem necessidade de recorrer a infraestruturas *cloud* ou servidores dedicados. Todas as tecnologias a adotar serão open-source e de utilização gratuita, o que eliminará custos de licenciamento e garantirá a reprodutibilidade do sistema em qualquer ambiente de desenvolvimento.

Ambiente de Desenvolvimento e Colaboração

O desenvolvimento do projeto será suportado por um conjunto de ferramentas de produtividade e colaboração. Para o desenvolvimento e prototipagem do código serão utilizados o Visual Studio Code e os Jupyter Notebooks, que permitirão o desenvolvimento iterativo e a documentação dos pipelines de dados. O controlo de versões e a partilha de código entre os membros da equipa serão assegurados pelo GitHub, garantindo rastreabilidade das alterações ao longo de todo o processo de desenvolvimento. Para a construção dos dashboards analíticos será utilizado o Power BI, ligado diretamente ao Data Warehouse. A comunicação e coordenação remota entre os elementos da equipa serão asseguradas pelo Discord, utilizado para reuniões de trabalho e discussão técnica, e pelo WhatsApp, para comunicação informal e partilha rápida de informação.

1.5 Plano de Execução do Projeto




Figura 1 - Diagrama de Gantt

| Fonte: Elaboração Própria

O plano de execução do projeto foi estruturado em cinco fases principais, organizadas de forma sequencial com sobreposições pontuais onde a independência entre tarefas o permite. O diagrama de Gantt apresentado ilustra a distribuição temporal que visamos cumprir de cada tarefa ao longo do semestre, cobrindo o período de fevereiro até ao final de maio de 2026.

Fase 1: Definição e Planeamento (semanas 1 a 3: 23/02 a 14/03)

A fase inicial compreende a definição do sistema e do contexto de aplicação, a escolha da arquitetura e da *stack* tecnológica. A definição do sistema e da arquitetura são desenvolvidas em paralelo dado que as duas decisões são interdependentes.

Fase 2: Levantamento de Requisitos (semanas 4 a 6, 17/03 a 28/03)

Esta fase compreende a análise documental das fontes de dados, o *data understanding e profiling* das fontes de dados, o levantamento de requisitos por *role-playing* dado o carácter académico do projeto, e a validação dos requisitos levantados.

Fase 3: Implementação do Sistema (semanas 7 a 10, 31/03 a 30/04)

A fase de implementação é a mais extensa do projeto, compreendendo o desenvolvimento do pipeline de integração de dados nas camadas Bronze, Silver e Gold, a população do Data

Warehouse em PostgreSQL e a implementação do mecanismo de Change Data Capture e do pipeline semanal de atualização.

Fase 4: Exploração e Análise (semanas 11 a 14, 01/05 a 29/05)

Esta fase compreende duas linhas de trabalho paralelas e independentes: o desenvolvimento dos *dashboards* em Power BI e o desenvolvimento dos modelos de machine learning para previsão de procura e identificação de churn.

Fase 5: Documentação Final (semanas 13 a 14, 15/05 a 22/05)

A fase final, desenvolvida em sobreposição com o final da fase anterior, é dedicada à revisão e finalização do relatório e à preparação da defesa do projeto. A redação do relatório será feita de forma incremental ao longo de todo o projeto, sendo esta fase dedicada à sua consolidação final.

2. Levantamento e Análise de Requisitos

2.1 Método Adotado

O processo de levantamento de requisitos para o sistema de suporte à decisão baseou-se numa abordagem mista, adequada à natureza académica do projeto. Dado que não existe acesso direto a utilizadores finais reais, foram adotadas duas metodologias complementares para identificar as necessidades analíticas do sistema.

Análise Documental e de Fontes de Dados

A primeira metodologia consistiu na análise técnica de todas as fontes de dados disponíveis, nomeadamente o *dataset* transacional de vendas gerado sinteticamente com base numa referência pública disponível no Kaggle, a documentação técnica da API Open-Meteo e a especificação do *dataset* sintético de publicações de redes sociais. Esta análise, realizada através de técnicas de *data profiling* com recurso à biblioteca YData Profiling, permitiu caracterizar em detalhe cada fonte de dados antes de definir os requisitos do sistema, confirmando a existência de granularidade diária e regional nas três fontes, condição necessária para o cruzamento entre vendas, clima e sentimento social. Os resultados do *profiling* constituíram documentação de referência para as decisões de transformação tomadas nas fases subseqüentes de implementação e encontram-se detalhados no capítulo 3.

Análise de Processos de Negócio

A segunda metodologia consistiu na análise dos principais processos de negócio da distribuidora de bebidas, nomeadamente a gestão de inventário, a logística regional e a estratégia de *marketing*. Com base na caracterização do cenário aplicacional definido no capítulo 1, foram identificadas as perguntas analíticas críticas que cada processo exige que o sistema seja capaz de responder. Esta análise, baseada em *role-playing* dado o carácter académico do projeto, constituiu a base para a definição formal dos requisitos de negócio e técnicos apresentados na secção seguinte, garantindo que o sistema desenvolvido responde a necessidades analíticas concretas e justificáveis no contexto da organização idealizada.

2.2 Organização dos Requisitos Levantados

Os requisitos do sistema foram organizados em torno de quatro áreas de análise distintas, cada uma correspondendo a um conjunto de necessidades analíticas identificadas durante o levantamento. Cada área define um conjunto de perguntas de negócio que o sistema deverá ser capaz de responder, dirigidas a utilizadores com necessidades de análise retrospectiva, correlacional ou preditiva sobre os dados da distribuidora.

Área 1: Análise de Vendas

Esta área foca-se na monitorização e compreensão do desempenho comercial da distribuidora ao longo do tempo e do território, sendo dirigida a utilizadores com necessidade de análise histórica e comparativa do comportamento de vendas. Os requisitos identificados são:

- Quais os produtos e categorias com maior volume de vendas por região no período 2021-2026?
- Qual a evolução trimestral das vendas por categoria ao longo dos 5 anos de dados históricos?
- Existem diferenças significativas no padrão de compra entre clientes B2B e B2C?
- Quais as regiões com maior crescimento de vendas entre 2021 e 2026?
- Existem produtos com tendência de declínio consistente ao longo do período histórico?

Área 2: Correlação Clima-Vendas

Esta área foca-se na identificação e quantificação do impacto das condições meteorológicas no comportamento de compra, sendo dirigida a utilizadores com necessidade de compreender e antecipar variações sazonais de procura com base em variáveis externas. Os requisitos identificados são:

- Existe correlação entre temperatura máxima diária elevada e aumento de vendas de categorias como água e refrigerantes?
- Existe correlação entre precipitação elevada e variação de vendas em determinadas categorias?
- Quais as categorias de produtos com maior sensibilidade a variações de temperatura e precipitação?
- Há regiões onde a correlação clima-vendas é mais pronunciada do que outras?

Área 3: Análise de Sentimento Social

Esta área foca-se na monitorização das tendências de opinião pública sobre os produtos da distribuidora, sendo dirigida a utilizadores com necessidade de identificar sinais precoces de mudança no comportamento do consumidor a partir de dados não estruturados de redes sociais. Os requisitos identificados são:

- Existe correlação temporal entre o sentimento agregado por produto e a evolução das vendas desse produto?
- Há produtos com sentimento positivo crescente mas volume de vendas ainda estagnado no período histórico?
- O sentimento negativo agregado por produto antecede quedas de vendas nas semanas seguintes?

Área 4: Previsão de Procura e Análise de Tendências

Esta área foca-se na modelação preditiva da procura e na identificação de padrões de crescimento ou declínio, sendo dirigida a utilizadores com necessidade de suportar decisões de planeamento de *stocks* e gestão de clientes com base em previsões quantitativas. Os requisitos identificados são:

- Qual a procura prevista por produto e região para as próximas estações do ano com base em séries temporais históricas?
- É possível melhorar a precisão da previsão incorporando variáveis climáticas como features adicionais?
- Quais os clientes sem compras nas últimas 4 meses que representam risco de churn?

2.3 Análise e Validação Geral dos Requisitos

Após o levantamento dos requisitos apresentado na secção anterior, foi realizada uma análise de validação com o objetivo de verificar a consistência, completude, viabilidade e clareza de cada requisito antes do início da implementação do sistema.

Consistência

A análise de consistência verificou que não existem requisitos contraditórios entre as quatro áreas definidas. As áreas de Análise de Vendas, Correlação Clima-Vendas e Análise de Sentimento Social partilham as mesmas dimensões temporais e geográficas, o que garante que os resultados de cada área podem ser cruzados entre si sem conflitos de granularidade ou de período de análise.

Completude

A análise de completude confirmou que os requisitos levantados cobrem as três dimensões de dados disponíveis no sistema, ou seja, vendas, meteorologia e sentimento social e que cada dimensão está representada por pelo menos uma área de análise dedicada. Foi identificada uma lacuna inicial na área de Previsão de Procura, onde a análise de risco de churn não estava contemplada nos requisitos originais. Esta lacuna foi corrigida com a adição do requisito relativo à identificação de clientes com declínio de compras nos últimos 4 meses, garantindo uma cobertura mais completa das necessidades de negócio identificadas.

Viabilidade

A análise de viabilidade verificou que todos os requisitos são tecnicamente realizáveis com os dados disponíveis. Contudo, foram identificadas duas limitações que condicionam o âmbito de alguns requisitos. Em primeiro lugar, os dados meteorológicos disponibilizam apenas temperatura máxima diária e precipitação total diária, o que restringe a análise climática a estas duas variáveis. Como ação corretiva, os requisitos de correlação clima-vendas foram reformulados para se circunscreverem explicitamente a estas duas variáveis, eliminando qualquer referência a indicadores climáticos não disponíveis. Em segundo lugar, o volume de publicações sintéticas de redes sociais, é significativamente inferior ao que seria expectável num cenário real. Como ação corretiva, os requisitos de análise de sentimento foram ajustados para que os seus resultados sejam interpretados como indicativos de tendências e não como conclusivos.

Clareza

A análise de clareza confirmou que todos os requisitos estão formulados de forma suficientemente precisa para guiar a implementação, com perguntas de negócio concretas e mensuráveis. Não foram identificadas ambiguidades que pudessem originar interpretações divergentes durante o desenvolvimento do sistema.

3. Implementação do Sistema de Análise

3.1 Apresentação Geral

Visão Geral do Sistema

O sistema implementado é uma plataforma de análise de dados de grande escala para suporte à decisão no contexto da distribuição especializada de bebidas. A plataforma integra dados de três fontes heterogêneas, processa-os com recurso a tecnologias preparadas para ambientes de *Big Data* e disponibiliza os resultados através de um Data Warehouse ligado a *dashboards* analíticos em Power BI e modelos preditivos de séries temporais.

Arquitetura Adotada

A arquitetura adotada segue o padrão Data Lakehouse, organizado segundo o modelo *Medallion* em três camadas funcionais distintas, cada uma com responsabilidades bem definidas no processo de integração e disponibilização dos dados.

A camada *Bronze* constitui a zona de aterragem dos dados brutos, onde os dados são recebidos nas suas formas originais sem qualquer transformação, preservando o dado original e servindo de ponto de recuperação em caso de falha nas camadas superiores.

A camada *Silver* constitui a zona de tratamento de dados (limpeza, tipagem e normalização...), onde os dados brutos são transformados em estruturas analiticamente utilizáveis em formato Parquet.

A camada *Gold* constitui a zona de agregação e modelação dimensional, onde os dados *Silver* são estruturados nas tabelas de dimensões e factos em formato Delta Lake, constituindo a fonte de verdade do sistema.

O Data Warehouse em PostgreSQL constitui um *serving layer*, populado a partir da camada *Gold* através de materialização externa e disponibilizando os dados ao Power BI através de ligação direta.

A descrição detalhada de cada camada, incluindo a organização das subpastas, os mecanismos de qualidade e as transformações aplicadas, é apresentada na secção 3.3.

Componentes e Serviços

A infraestrutura do sistema é inteiramente *containerizada* através do Docker, garantindo portabilidade e reprodutibilidade em qualquer ambiente de desenvolvimento. Os serviços implementados são os seguintes:

O MinIO é o serviço de *object storage* que aloja as camadas *Bronze*, *Silver* e *Gold* do *Data Lakehouse*. A sua escolha justifica-se pela compatibilidade nativa com o protocolo S3 da Amazon, que garante interoperabilidade com o Apache Spark através do conector S3A, e pela possibilidade de execução local sem custos de infraestrutura *cloud*.

O PostgreSQL é o sistema de gestão de base de dados relacional que serve como Data Warehouse do sistema, alojando o modelo dimensional com as tabelas de dimensões e factos. A sua escolha justifica-se pela familiaridade da equipa, robustez, pela maturidade para suporte a *queries* analíticas complexas e pela integração nativa com o Power BI através de conector direto.

O pgAdmin é a interface web de administração e monitorização do PostgreSQL, utilizada para validação das estruturas de dados e execução de queries analíticas ad-hoc durante o desenvolvimento e teste do sistema.

Ferramentas de Processamento e Orquestração

O Apache Spark com a interface PySpark é o motor de processamento central do sistema, utilizado em todas as fases de transformação de dados desde a camada *Bronze* até à camada *Gold*. A sua escolha justifica-se pela capacidade nativa de processar dados em múltiplos formatos de forma distribuída e escalável, pela integração nativa com o MinIO através do conector S3A e com o PostgreSQL através do driver JDBC, e pelo suporte ao formato Delta utilizado na camada *Gold*.

O Python é a linguagem de programação principal do projeto, utilizada para o desenvolvimento de todos os *scripts* de pipeline, geração sintética de dados e integração com a API Open-Meteo.

O Prefect é a ferramenta de orquestração do pipeline semanal de atualização de dados. A sua escolha justifica-se pela capacidade de garantir a execução sequencial e monitorizada das tarefas do pipeline, pelo suporte nativo a *retry* com *backoff* exponencial em caso de falha transitória de conectividade, e pela interface de monitorização que permite acompanhar o estado de cada execução. O Prefect orquestra duas tarefas principais por ciclo semanal: a geração sintética de novos dados seguida da execução do pipeline de integração, garantindo

que o pipeline só é executado após a geração de dados ser concluída com sucesso, simulando efetivamente a extração dos dados semanais da empresa.

Ferramentas de Qualidade e Processamento de Linguagem Natural

A biblioteca YData Profiling é utilizada na fase de análise exploratória das fontes de dados, anterior à implementação do sistema, para geração de relatórios detalhados de qualidade incluindo análise de *completeness*, distribuições, correlações e detecção de anomalias. Os resultados desta análise informaram as decisões de transformação aplicadas na camada *Silver* e encontram-se documentados no capítulo 3.3.

A biblioteca Transformers da HuggingFace é utilizada para a aplicação do modelo cardiffnlp/twitter-xlm-roberta-base-sentiment sobre as publicações sintéticas de redes sociais, classificando cada publicação como positiva, negativa ou neutra. A escolha deste modelo justifica-se pela sua validação científica em contextos multilingues e pela eliminação da necessidade de desenvolver e treinar um modelo de raiz.

Ferramentas de Visualização

O Power BI é a ferramenta de visualização e *dashboarding* analítico, ligada diretamente ao PostgreSQL para construção dos *dashboards* de análise de vendas, correlação clima-vendas, sentimento social e previsão de procura. A sua escolha justifica-se pela familiaridade da equipa com a ferramenta, pela integração nativa com o PostgreSQL e pela capacidade de disponibilizar *dashboards* interativos acessíveis a perfis não técnicos.

Mecanismo de Atualização e Tolerância a Falhas

O sistema implementa um mecanismo de Change Data Capture baseado em timestamps que garante que apenas os dados novos são processados em cada ciclo semanal de atualização. O estado do CDC é persistido simultaneamente no MinIO, num ficheiro JSON na camada Bronze, e no PostgreSQL, numa tabela dedicada de watermarks, sendo o MinIO a fonte de verdade e o PostgreSQL utilizado exclusivamente para monitorização.

Para garantir a recuperação segura em caso de falha, o pipeline implementa um sistema de checkpointing granular com fases distintas, persistido num ficheiro JSON no MinIO. Em caso de falha, o pipeline retoma automaticamente a partir da última fase concluída com sucesso, sem necessidade de reprocessar o histórico. Este mecanismo é complementado pela idempotência de cada fase: o Bronze e o Silver usam overwrite atómico; o Gold usa left anti join com append nas dimensões estáticas, garantindo que apenas os registos novos são inseridos, e MERGE nativo do Delta Lake na dim_cliente para o SCD Tipo 2, sendo ambas as operações idempotentes por natureza. As dimensões no PostgreSQL utilizam INSERT ON CONFLICT DO NOTHING para as dims calendario, regioao e produto, e INSERT ON CONFLICT DO UPDATE (upsert) para a dim_cliente, garantindo que as atualizações do SCD Tipo 2 geradas no Gold se propagam corretamente ao Data Warehouse sem duplicação de dados.

3.2 Fontes de Dados

O sistema integra três fontes de dados de natureza estruturalmente distinta, cobrindo as dimensões transacional, ambiental e social do problema de negócio. Para cada fonte foi realizado um processo de *Data Understanding* antes do início da implementação, com o objetivo de caracterizar o significado semântico e as características técnicas de cada campo, garantindo uma compreensão completa dos dados antes de definir as transformações a aplicar nas camadas *Silver* e *Gold*.

A seguir ao *Data Understanding* é realizado o processo de *Data Profiling*, que consiste numa análise sistemática das características técnicas e de qualidade dos dados antes de qualquer decisão de implementação. Este processo permite identificar problemas de qualidade, compreender a estrutura real dos dados e fundamentar as transformações a aplicar nas fases subsequentes. De forma geral, um processo de *Data Profiling* avalia a completeness, verificando a ausência de valores em falta em campos críticos; a unicidade, detetando registos duplicados que possam distorcer agregações e métricas; a consistência dos domínios categóricos, garantindo que os valores seguem um conjunto controlado sem variações de formatação ou erros de escrita; a distribuição estatística dos campos numéricos (mínimos, médias, máximos e quartis), identificando outliers e valores anómalos; a validade dos formatos, confirmando que datas, identificadores e valores numéricos respeitam os formatos esperados; e a cardinalidade dos campos, caracterizando o número de valores distintos por coluna e identificando campos com baixa variabilidade que possam ter utilidade analítica limitada. Os resultados do profiling de cada fonte encontram-se documentados nas secções seguintes e constituíram a base para as decisões de transformação implementadas no pipeline.

Fonte 1: Dados Transacionais de Vendas

A primeira e principal fonte de dados é um dataset sintético de transações de vendas, gerado de raiz pela equipa com base numa referência pública disponível na plataforma Kaggle, adaptado ao contexto da distribuidora BKLP Supply & Distribution. O *dataset* cobre o período de 1 de janeiro de 2021 até à data atual, sendo atualizado semanalmente através de um gerador sintético que produz novos registos respeitando a estrutura, os domínios e a lógica sazonal definidos para o sistema.

O *schema* do *dataset* inclui os campos Order_ID, Customer_ID, Customer_Type, Product, Category, Unit_Price, Quantity, Discount, Total_Price, Region e Order_Date, abrangendo 47 produtos distintos organizados em 4 categorias, nomeadamente “Water”, “Soft Drinks”, “Juices” e “Alcoholic Beverages”, e as 16 regiões administrativas alemãs. Esta fonte constitui a base analítica central do sistema, sobre a qual todas as correlações com as restantes fontes serão estabelecidas.

Tabela 1- Data understanding da fonte “vendas”

Campo	Tipo	Descrição
Order_ID	String	Identificador único da encomenda. Uma encomenda pode ter entre 1 a 5 linhas correspondentes a produtos distintos.
Customer_ID	String	Identificador único do cliente.
Customer_Type	String	Tipo de cliente: B2B (cliente empresarial/retalhista) ou B2C (consumidor final).
Product	String	Nome comercial do produto vendido. O catálogo contém 47 produtos distintos.
Category	String	Categoria do produto: Water, Soft Drinks, Juices ou Alcoholic Beverages.
Unit_Price	Decimal	Preço unitário do produto em euros. Varia entre 0.32€ e 169.53€.
Quantity	Integer	Quantidade de unidades encomendadas. Varia entre 1 e 100 unidades.
Discount	Decimal	Desconto aplicado à encomenda em formato decimal (0.0 a 0.15, correspondendo a 0% a 15%).
Total_Price	Decimal	Valor total da linha de encomenda em euros, calculado como $\text{Unit_Price} \times \text{Quantity} \times (1 - \text{Discount})$.
Region	String	Região administrativa alemã (Bundesland) associada à encomenda. Cobre as 16 regiões da Alemanha.
Order_Date	Date	Data em que a encomenda foi registada.

| Fonte: Elaboração Própria

Os resultados do profiling revelaram que os dados de vendas apresentam qualidade elevada: completeness de 100% em todas as colunas e ausência de valores fora dos domínios categóricos esperados. Foi identificada durante o profiling a ausência dos caracteres especiais alemães nos nomes das regiões, nomeadamente em "Baden-Wurtemberg" e "Thuringen", inconsistência que foi corrigida através de um mapeamento explícito na camada Silver. Os outputs completos do profiling das vendas encontram-se no [Anexo 1](#).

Fonte 2: Meteorologia (API Open-Meteo)

A segunda fonte consiste em dados meteorológicos históricos extraídos através da API pública Open-Meteo, que disponibiliza registos climáticos diários sem necessidade de autenticação e sem custos de acesso. Para cada uma das 16 regiões alemãs são extraídos dois indicadores diários, nomeadamente a temperatura máxima em graus *Celsius* e a precipitação acumulada em milímetros, cobrindo o mesmo intervalo temporal dos dados de vendas, de 2021 até à data atual. A extração é realizada de forma programática, iterando sobre as coordenadas geográficas de cada *Bundesland* e persistindo os resultados em ficheiros JSON individuais por região na camada *Bronze*. No âmbito do pipeline semanal de atualização, a API é consultada automaticamente para o período correspondente aos novos dados de vendas detetados. Garantindo que as três fontes se mantêm sempre sincronizadas temporalmente. Esta fonte é fundamental para estabelecer a correlação entre condições climáticas e variações no volume de vendas por categoria de produto e região.

Tabela 2- Data understanding da fonte "meteorologia"

Campo	Tipo	Descrição
Regiao	Texto	Nome da região da Alemanha a que os dados se referem. Cobre as 16 regiões da Alemanha
Data	Date	Data exata da medição climática.
Temp_Max_C	Decimal	Temperatura máxima diária registada a 2 metros do solo (em Celsius). Varia entre -10.5° até 38.9° C.
Precipitacao_mm	Decimal	Soma total de chuva caída num dia, em milímetros. Varia entre 0 mm até 93.8 mm.

| Fonte: Elaboração Própria

Os resultados do profiling dos dados meteorológicos revelaram qualidade e integridade excelentes: completeness de 100% nos campos todos, e ausência de anomalias ou valores fora dos domínios físicos esperados. Foi confirmada a inexistência de precipitação negativa na coluna `Precipitacao_mm` e que todos os registos da coluna `Temp_Max_C` se encontram no intervalo térmico realista definido para a Alemanha, entre -40°C e 45°C.

Os outputs completos do *profiling* meteorológico encontram-se no [Anexo 2](#).

Fonte 3: Dados de Tendências Sociais (*Dataset* Sintético)

A terceira fonte consiste num conjunto de dados não estruturados que simula publicações em redes sociais no formato do Twitter/X, relacionadas com produtos e categorias de bebidas. Dado que o acesso à API oficial do Twitter/X implica custos de subscrição incompatíveis com o contexto académico deste projeto, optou-se pela geração de um *dataset* sintético controlado. A geração segue uma lógica de negócio realista, associando produtos refrescantes a contextos de calor e produtos de inverno a contextos de frio, com distribuição temporal alinhada com o intervalo dos dados de vendas, de 2021 até à data atual. Cada registo segue o formato abaixo exemplado:

Exemplo: [2023-09-16 00:00:00] @user9937: O sol em Bremen está a derreter tudo. Fui a correr comprar San Pellegrino. #verao #calor

Esta fonte é persistida na camada *Bronze* em formato de texto livre e processada na camada *Silver* através da aplicação do modelo de NLP, que extrai a polaridade de sentimento de cada publicação e deteta menções a produtos e regiões do catálogo. A opção pela geração sintética é assumida como uma limitação do projeto, sendo documentada de forma transparente, e o seu impacto sobre os resultados da análise de sentimento será discutido na avaliação crítica do trabalho.

Os dados de tendências sociais, por se encontrarem em formato de texto livre não estruturado, não são passíveis de *profiling* formal com YData Profiling. A caracterização desta fonte baseou-se numa análise manual do formato, do volume de publicações e da lógica de geração sintética.

3.3 Área de Preparação de Dados (staging area)

O sistema adota um Data Lake como área de preparação de dados, implementado sobre o MinIO, um serviço de object storage. A utilização de uma área de preparação justifica-se pela heterogeneidade das fontes de dados do sistema: os dados de vendas em formato CSV, os dados meteorológicos em formato JSON e as publicações sintéticas em texto livre requerem abordagens de processamento distintas antes de poderem ser integrados num modelo analítico unificado. Um *Data Lakehouse* permite preservar os dados nas suas formas originais e aplicar transformações progressivas.

O *Data Lakehouse* está organizado segundo o padrão *Medallion* em três camadas funcionais, cada uma com responsabilidades distintas no processo de preparação e integração de dados: *Bronze*, *Silver* e *Gold*. Esta organização garante rastreabilidade completa desde o dado bruto original até ao dado analiticamente pronto para consumo, permitindo reprocessar qualquer camada a partir da anterior em caso de erro ou alteração dos requisitos de transformação.

Camada *Bronze*

A camada *Bronze* constitui a zona de aterragem dos dados brutos do sistema, correspondendo ao primeiro nível de persistência após a extração dos dados das fontes. Os dados são armazenados nas suas formas originais, sem qualquer transformação. Garantindo que o dado original é sempre preservado e recuperável. Esta camada serve simultaneamente de ponto de partida para o processamento *Silver* e de zona de segurança em caso de falha nas camadas superiores, uma vez que qualquer camada pode ser reconstruída a partir da *Bronze* sem necessidade de extração das fontes.

A camada *Bronze* está organizada em três subpastas no MinIO, uma por fonte de dados. A subpasta *raw/vendas/* armazena o ficheiro CSV de transações de vendas, que cresce progressivamente com cada ciclo semanal de atualização através de *append* ao ficheiro existente. A subpasta *raw/meteo/* armazena os 16 ficheiros JSON de dados meteorológicos, um por região alemã, que são atualizados semanalmente com os novos registos climáticos obtidos da API Open-Meteo. A subpasta *raw/social/* armazena o ficheiro de texto livre com as publicações sintéticas de redes sociais, que cresce progressivamente por *append* a cada ciclo semanal. Adicionalmente, a subpasta *raw/cdc/* armazena o ficheiro JSON que regista a última data processada pelo pipeline e é atualizado no final de cada ciclo de execução.

O sistema implementa uma zona de quarentena para dois pontos críticos do pipeline, persistindo os registos rejeitados no Bronze MinIO com um campo *motivo_rejeicao* que permite auditoria e diagnóstico posterior.

O primeiro ponto de rejeição ocorre no processamento *Silver* das vendas, onde os registos com campos obrigatórios nulos são desviados para *raw/rejected/vendas/*. Esta abordagem garante que o pipeline continua a processar os registos válidos sem interrupção, mantendo simultaneamente um registo auditável de todas as anomalias detetadas.

O segundo ponto de rejeição ocorre no processamento NLP dos tweets, onde as publicações sem produto reconhecido, sem região reconhecida, ou sem ambos são desviadas para *raw/rejected/tweets/* com o motivo de rejeição correspondente, ou seja, *sem_produto*, *sem_regiao* ou *sem_produto_e_regiao*. É importante destacar que os tweets rejeitados por produto não reconhecido têm valor de negócio adicional: permitem identificar produtos mencionados pelos clientes que ainda não fazem parte do catálogo da distribuidora, representando potenciais oportunidades de expansão do portfólio. A análise periódica desta subpasta é por isso recomendada como *input* para decisões de gestão de portfólio.

Camada *Silver*

A camada *Silver* constitui a zona de tratamento dos dados. Todos os dados processados nesta camada são persistidos em formato Parquet, um formato colunar binário que oferece compressão eficiente e leitura seletiva de colunas, reduzindo significativamente o tempo de processamento. Todo o processamento desta camada é realizado com Apache Spark, tirando partido do paralelismo *multi-core* disponível. Para garantir idempotência em caso de *retry*, o processamento *Silver* aplica *overwrite* atómico do período em processamento antes de

reescrever os ficheiros Parquet de destino, eliminando o risco de dados duplicados no caso de re-execução parcial.

Dados de Vendas

O processamento Silver dos dados de vendas lê o ficheiro CSV da camada Bronze. Os registos com campos obrigatórios nulos são desviados para a zona de quarentena em `raw/rejected/vendas/` antes de qualquer transformação adicional. As transformações aplicadas sobre os registos válidos são a remoção da coluna `Discount`, dado que o `Total_Price` já incorpora o desconto no seu cálculo, e o mapeamento dos nomes das regiões para os nomes oficiais alemães com os caracteres especiais correctos, nomeadamente a conversão de "Baden-Wurttemberg" para "Baden-Württemberg" e de "Thuringen" para "Thüringen", garantindo a consistência referencial com as restantes fontes de dados. O resultado é persistido em formato Parquet na subpasta `silver/vendas/`.

Tabela 3 - Mapeamento dos nomes das regiões

Nome Original (CSV Vendas)	Nome Oficial Alemão (Após Mapeamento)
Baden-Wurttemberg	Baden-Württemberg
Thuringen	Thüringen

Tabela 4 - Estrutura de “vendas” no final da camada silver

Campo	Tipo	Descrição
Order_ID	String	Identificador único da transação
Customer_ID	String	Identificador único do cliente
Customer_Type	String	Tipo de cliente (B2B ou B2C)
Product	String	Nome do produto vendido
Category	String	Categoria do produto
Unit_Price	Decimal	Preço unitário do produto
Quantity	Integer	Quantidade vendida na transação
Total_Price	Decimal	Valor total da transação
Region	String	Região administrativa alemã (Bundesland)
Order_Date	Date	Data da transação

| Fonte: Elaboração Própria

Dados Meteorológicos

O processamento Silver dos dados meteorológicos é o mais complexo das três fontes, dado que os dados de origem se encontram distribuídos por 16 ficheiros JSON individuais com uma estrutura hierárquica de *arrays* aninhados. O Spark lê todos os ficheiros em simultâneo com a opção *multiLine*. O aplanamento da estrutura hierárquica é realizado de forma nativa

através da combinação das funções `arrays_zip` e `explode`, que converte os *arrays* paralelos de datas, temperaturas e precipitações numa linha por dia por região.

O resultado é persistido em formato Parquet na subpasta `silver/meteo/`, com as colunas `Regiao`, `Data`, `Temp_Max_C` e `Precipitacao_mm`.

Tabela 5 - Estrutura de “meteorologia” no final da camada silver

Campo	Tipo	Descrição
Regiao	String	Região administrativa alemã (Bundesland)
Data	Date	Data do registo meteorológico
Temp_Max_C	Decimal	Temperatura máxima diária em graus Celsius
Precipitacao_mm	Decimal	Precipitação total diária em milímetros

| Fonte: Elaboração Própria

Dados de Tendências Sociais

O processamento *Silver* dos dados de tendências sociais é composto por três fases sequenciais, justificadas pela natureza não estruturada dos dados de origem.

A primeira fase realiza o *parsing* do ficheiro de texto bruto, onde cada linha segue o formato composto por data, identificador de utilizador e texto livre. O Spark lê o ficheiro linha a linha com `spark.read.text` e extrai os três campos através de expressões regulares, convertendo o texto não estruturado num *DataFrame* semi-estruturado com os campos `tweet_date`, `user_id` e `texto_original`. As linhas inválidas ou vazias são filtradas e o resultado é persistido como na subpasta `silver/social/parsed/`.

A segunda fase aplica o modelo de Processamento de Linguagem Natural `cardiffnlp/twitter-xlm-roberta-base-sentiment` sobre o texto de cada publicação. Este processamento é realizado com a biblioteca `Transformers` da `HuggingFace`, classificando cada publicação como positiva, negativa ou neutra e calculando um score de sentimento entre 0 e 1. Em paralelo, são detetados o produto mencionado e a região geográfica referida através de correspondência de texto com os catálogos de produtos e regiões da nossa empresa. As publicações sem produto reconhecido, sem região reconhecida, ou sem ambos são

desviadas para a zona de quarentena em raw/rejected/tweets/ com o respetivo motivo de rejeição, sendo excluídas do processamento subsequente. O resultado dos registos válidos é persistido na subpasta silver/social/nlp/.

A terceira fase lê o ficheiro resultante com o Spark, remove as colunas user_id e texto_original, que não entram no modelo dimensional e insere na subpasta silver/social/parquet/. O *dataset* final da camada *Silver* dos dados sociais contém os campos tweet_date, sentimento, score_sentimento, produto_mencionado e regioao_mencionada.

Tabela 6 - Estrutura de “tweets” no final da camada silver

Campo	Tipo	Descrição
tweet_date	Date	Data de publicação do tweet
sentimento	String	Polaridade do sentimento (positivo, negativo ou neutro)
score_sentimento	Float	Pontuação de confiança do modelo NLP entre 0 e 1
produto_mencionado	String	Produto identificado no texto do tweet
regiao_mencionada	String	Região administrativa identificada no texto do tweet

| Fonte: Elaboração Própria

Camada Gold

A camada Gold constitui o último nível antes da disponibilização ao PostgreSQL. É nesta camada que os dados das três fontes, já limpos e normalizados na camada Silver, são cruzados, agregados e estruturados em duas zonas funcionais distintas: o modelo dimensional para serving analítico ao Power BI através do PostgreSQL, e as tabelas de serving desnormalizadas para consumo direto pelos modelos de Machine Learning. A estrutura detalhada do modelo dimensional, os grãos definidos e a fundamentação das opções de modelação são apresentados na secção 3.4.

Ao contrário da camada Silver, que persiste os dados em formato Parquet, a camada Gold adota o formato Delta em todas as suas tabelas. Esta escolha justifica-se pelas funcionalidades adicionais que o Delta Lake oferece sobre o Parquet simples, nomeadamente

suporte nativo a operações MERGE idempotentes e versionamento que permite auditoria e rollback em caso de erro.

A atualização da camada Gold segue uma abordagem incremental. Em vez de recalculando todas as tabelas do zero a cada execução, o pipeline identifica os registos novos em cada dimensão através de estratégias distintas consoante o tipo de dimensão. Para as dimensões calendário, região e produto é utilizado um left anti join que compara os candidatos do batch atual com os registos já existentes na dimensão, inserindo apenas os valores que ainda não existem. Para a dimensão cliente é utilizado um MERGE nativo do Delta Lake que implementa o SCD Tipo 2, fechando o registo anterior quando o tipo de cliente muda e inserindo um novo registo ativo com a data de início atualizada. A natureza idempotente destas operações garante que a re-execução em caso de falha produz sempre o mesmo resultado sem duplicação de dados. Os ids surrogates existentes nunca são alterados entre execuções, garantindo a estabilidade das chaves do modelo dimensional. As tabelas de facto e as tabelas de serving são atualizadas por append, dado que o CDC timestamp-based é aplicado na extração, tornando todos os dados gerados na camada Gold sempre incrementais. Esta abordagem garante que o custo de processamento da camada Gold cresce apenas com o volume de dados novos e não com o volume histórico acumulado, tornando o pipeline escalável para volumes de dados de grande dimensão. A descrição detalhada da estrutura e fundamentação destas tabelas é apresentada na secção 3.4.

A zona de serving para Machine Learning é composta por duas tabelas desnormalizadas, *serving_vendas* e *serving_clima*, construídas através de joins entre as tabelas de facto e as dimensões correspondentes. Ao contrário do modelo dimensional onde os nomes descritivos estão nas dimensões e os factos contêm apenas surrogate keys, as tabelas de serving incluem diretamente os atributos descritivos, eliminando a necessidade de joins adicionais por parte dos modelos de ML.

3.4 Área de Dados do Sistema de Análise

Visão Geral

O sistema de dados implementado para suporte à análise assenta numa arquitetura de *serving* híbrida, combinando um Data Warehouse relacional em PostgreSQL e uma zona de *serving* dedicada em Delta Lake na camada Gold. O PostgreSQL serve como *serving layer* para o Power BI, recebendo os dados já transformados e agregados pelo Spark sem executar qualquer lógica de transformação interna. A camada *Gold* em Delta Lake serve como *serving layer* para os modelos de *Machine Learning*, disponibilizando as tabelas desnormalizadas *serving_vendas* e *serving_clima* para consumo direto, sem necessidade de passar pelo PostgreSQL. Esta separação de responsabilidades garante que cada consumidor acede aos dados através da localização mais adequada às suas necessidades.

Modelo de Dados Adotado

O modelo de dados adotado é o modelo dimensional, especificamente o esquema em constelação. Esta escolha justifica-se pela existência de três tabelas de factos com grãos distintos que partilham dimensões comuns, o que impossibilita a adoção de um esquema em estrela simples. O esquema em constelação permite que as dimensões partilhadas sejam reutilizadas pelas três tabelas de factos sem duplicação de dados, garantindo consistência entre as diferentes áreas de análise do sistema.

O modelo dimensional é otimizado para queries de agregação e filtragem multidimensional, características essenciais para responder às perguntas de negócio identificadas nos requisitos, nomeadamente correlações entre vendas, clima e sentimento ao longo do tempo e do território.

Adicionalmente ao modelo dimensional, o sistema implementa duas tabelas de *serving* desnormalizadas na camada *Gold* em Delta Lake, *serving_vendas* e *serving_clima*, desenhadas especificamente para consumo pelos modelos de *Machine Learning*. Estas tabelas não fazem parte do modelo dimensional formal mas complementam-no, disponibilizando os dados já com os atributos descritivos das dimensões resolvidos, eliminando a necessidade de *joins* adicionais durante o treino e inferência dos modelos preditivos.

Grãos Definidos

A definição do grão de cada tabela de factos foi uma decisão central no processo de modelação, determinando o nível de detalhe disponível para análise. Os grãos definidos são apresentados na tabela seguinte:

Tabela 7- Grãos definidos para as tabelas de facto

Tabela de Factos	Grão Definido	Medidas
tf_vendas	1 dia + 1 região + 1 produto + 1 cliente	quantidade,preco_total, preco_unidade
tf_meteorologia	1 dia + 1 região	temp_max_c, precipitacao_mm
tf_tweets	1 dia + 1 região + 1 produto + 1 categoria de sentimento	score_sentimento, nr_tweets

| Fonte: Elaboração Própria

Matriz de decisão

Tabela 8 - Matriz de decisão

Caracterização			
Identificação:		BKLP	
Descrição Geral: Informação para suporte à tomada de decisão na área de vendas da BKLP Supply & Distribution, providenciando elementos de dados selecionados acerca das vendas de bebidas em todas as regiões alemãs onde opera, para gestão e controlo das ações comerciais realizadas e dos stocks envolvidos, e para fazer a avaliação do desempenho e suporte à previsão de procura ao longo do tempo, com base nos dados transacionais, meteorológicos e de sentimento social.			
Estrutura base			
Tabelas de Factos	TF-Vendas	TF-Meteorologia	TF-Tweets
Dimensões			
Calendário	v	v	v
Regiões	v	v	v
Clientes	v		
Produtos	v		v
Numero Dimensões	4	2	3
Tipo	Agregada	Instantânea	agregada
Periodicidade	Semanal	Semanal	Semanal
Descrição	Análise agregada de transações comerciais de bebidas, nas 16 regiões alemãs.	Registos diários de temperatura máxima e precipitação por região.	Análise agregada de sentimento social por dia, região, produto e polaridade.

Utilidade estratégica	Avaliação do desempenho comercial por região e produto. Análise de sazonalidade e tendência de procura.	Identificação de correlações entre clima e volume de vendas. Antecipação de picos de procura com base em condições meteorológicas. Identificação de categorias mais sensíveis ao clima por região.	Correlação entre o sentimento social. E evolução de vendas por produto. Identificação de produtos com sentimento positivo crescente nas vendas estagnadas. Detecção precoce de declínio de popularidade de produtos.
Utilizadores	Dean, Fernando, Lorenzo e Tomás	Dean, Fernando, Lorenzo e Tomás	Dean, Fernando, Lorenzo e Tomás
Observacoes			
Nada a assinalar.			
Versao 1.00/2026, BKLP Supply & Distribution			

| Fonte: Elaboração Própria

Caracterização e estrutura das Dimensões

As quatro dimensões do modelo seguem o princípio das chaves *surrogates*, em que cada dimensão possui uma chave primária inteira gerada artificialmente de forma sequencial, independente das chaves naturais das fontes originais. Esta abordagem garante estabilidade das chaves mesmo que os valores das chaves naturais se alterem nas fontes, e otimiza a performance dos *joins* nas tabelas de factos. A estrutura de cada dimensão é apresentada nas tabelas seguintes.

Tabela 9 - Caracterização das dimensões

Nr	Identificação	Descrição	Esquema (Tipo)
1	Calendário	Dimensão temporal que acolhe todos os atributos que sustentam análises ao longo do tempo, nomeadamente a data completa, o mês, o trimestre, o ano, o dia e a estação do ano.	dim-Calendário (Simples)
2	Região	Caracterização das regiões administrativas alemãs (Bundesländer) onde a BKLP Supply & Distribution opera, identificando cada região por nome.	dim-Região (Simples)
3	Produto	Identificação e caracterização dos produtos comercializados pela distribuidora, incluindo o nome do produto e a categoria a que pertence.	dim-Produto (Simples)
4	Cliente	Identificação e caracterização dos clientes da distribuidora, incluindo o identificador do cliente, o tipo de cliente (B2B ou B2C) e o período de vigência de cada registo.	dim-Cliente (Com variação: SCD Tipo 2)

| Fonte: Elaboração Própria

dim_calendario

Tabela 10 - Estrutura da Dim_calendário

Nr	Identificação	Descrição	Chave (Tipo)	Domínio (Tamanho)	Variação	Exemplos
1	id_tempo	Chave surrogate da dimensão temporal	Primária (Integer)	Inteiro sequencial	Não	1, 2, 3
2	data_completa	Data completa no formato YYYY-MM-DD	Descritivo (Date)	2021-01-01 a 2026-04-30	Não	2021-01-04, 2024-06-21
3	ano	Ano da data completa	Descritivo (Integer)	4 dígitos	Não	2021, 2022
4	trimestre	Trimestre do ano	Descritivo (Integer)	1 a 4	Não	1, 2, 3, 4
5	mes	Mês do ano	Descritivo (Integer)	1 a 12	Não	1, 6, 12
6	dia	Dia do mês	Descritivo (Integer)	1 a 31	Não	1, 15, 31
7	estacao_ano	Estação do ano calculada astronomicamente	Descritivo (String)	4 valores	Não	Inverno, Primavera, Verão, Outono

| Fonte: Elaboração Própria

dim_produto

Tabela 11 - Estrutura da dim_produto

Nr	Identificação	Descrição	Chave (Tipo)	Domínio (Tamanho)	Variação	Exemplos
1	id_produto	Chave surrogate da dimensão de produto	Primária (Integer)	Inteiro sequencial	Não	1, 2, 3
2	nome_produto	Nome comercial do produto	Descritivo (String)	47 valores	Não	Coca-Cola, Heineken, Evian
3	categoria_produto	Categoria a que o produto pertence	Descritivo (String)	4 valores	Não	Soft Drinks, Alcoholic Beverages, Juices, Water

| Fonte: Elaboração Própria

dim_cliente

Tabela 12 - Estrutura da dim_cliente

Nr	Identificação	Descrição	Chave (Tipo)	Domínio (Tamanho)	Variação	Exemplos
1	id_cliente	Chave surrogate da dimensão de cliente	Primária (Integer)	Inteiro sequencial	SCD Tipo 2	1, 2, 3
2	customer_id	Identificador natural do cliente na fonte	Natural (String)	Formato CUSxxxx	Não	CUS8494, CUS3316
3	tipo_cliente	Tipo de relação comercial do cliente	Descritivo (String)	2 valores	SCD Tipo 2	B2B, B2C
4	data_inicio	Data de início de vigência do registo	Técnico (Date)	Formato YYYY-MM-DD	SCD Tipo 2	2021-01-04
5	data_fim	Data de fim de vigência do registo	Técnico (Date)	NULL se registo activo	SCD Tipo 2	2022-03-14, NULL
6	flag_atual	Indicador do registo actualmente activo	Técnico (Boolean)	true / false	SCD Tipo 2	true,

| Fonte: Elaboração Própria

A dimensão dim_cliente implementa SCD(slowly changing dimension) Tipo 2 para rastrear historicamente mudanças no tipo de cliente. As colunas data_inicio, data_fim e flag_atual permitem identificar o período de validade de cada versão do registo, garantindo que cada venda é associada ao tipo de cliente no momento da transação. O pipeline deteta mudanças de tipo de

cliente tanto dentro do mesmo *batch* de processamento como em relação ao histórico existente na camada *Gold*, fechando o registo anterior e criando um novo registo ativo com a data da primeira compra do novo tipo como *data_inicio*.

Tabela 13

Tabela 13 - Exemplo SCD tipo 2 na dim_customer

id_cliente	customer_id	tipo_cliente	data_inicio	data_fim	flag_atual
1	CUS8494	B2C	2021-01-04	2022-03-15	false
2	CUS8494	B2B	2022-03-15	NULL	true

| Fonte: Elaboração Própria

Caracterização e Estrutura das Tabelas de Factos

As tabelas de factos do modelo dimensional seguem o princípio das chaves estrangeiras para referência às dimensões, com medidas numéricas que representam os factos do processo de negócio. A estrutura de cada tabela de factos é apresentada nas tabelas seguintes.

tf_vendas

Tabela 14 - caracterização da tabela de factos tf_vendas

Caracterização da Tabela de Factos vendas	
Identificação	tf-vendas
Descrição	Tabela que acolhe todos os registos de transações de venda de bebidas realizadas pela BKLP Supply & Distribution, abrangendo os mercados B2B (clientes retalhistas) e B2C (consumidores finais) nas 16 regiões alemãs.
Data mart	BKLP Comercial
Tipo	Agregada
Utilidade estratégica	Avaliação do desempenho comercial por região, produto e categoria. Identificar a Análise de desempenho comercial. Análise de sazonalidade e tendências de procura. Suporte a estratégias de marketing e otimização de stocks.

Povoamento	Carga histórica inicial. Atualizado semanalmente pelo pipeline com os novos registos detetados pelo CDC (Change Data Capture).
Dimensão inicial	~33.553 registos após carga histórica.
Crescimento	~130 novos registos por semana (estimativa baseada no gerador sintético).
Período de dados	Janeiro 2021 até à data atual. Atualização semanal incremental.

Atributos: Dimensões

Tabela 15 - Atributos das dimensões na tabela de factos tf_vendas

Nr	Identificação	Chave	Tipo	Domínio	Descrição	Exemplos
1	id_vendas	Primária	Integer	Inteiro sequencial	Chave surrogate da tabela de factos de vendas	1, 2, 3
2	id_tempo	Estrangeira	Integer	Inteiro sequencial	Referência à dim_calendario	1, 45, 200
3	id_regiao	Estrangeira	Integer	Inteiro sequencial	Referência à dim_regiao	1, 5, 12
4	id_produto	Estrangeira	Integer	Inteiro sequencial	Referência à dim_produto	1, 10, 47
5	id_cliente	Estrangeira	Integer	Inteiro sequencial	Referência à dim_cliente	1, 100, 6693

| Fonte: Elaboração Própria

Atributos: Medidas

Tabela 16 - Atributos com medidas da tabela de factos *tf_vendas*

Nr	Identificação	Chave	Tipo	Domínio	Descrição	Exemplos
1	quantidade	Medida	Integer	Valor positivo	Quantidade total de unidades vendidas na agregação pelo grão definido	10, 25, 90
2	preco_total	Medida	Decimal	Valor positivo	Valor total da agregação definida pelo grão	5.30, 203.06, 3085.26
3	preco_unidade	Medida	Decimal	Valor positivo	Preço médio por unidade em euros	0.53, 8.55, 53.24

| Fonte: Elaboração Própria

A tabela *tf_vendas* possui chave primária *surrogate* *id_vendas*, introduzida pelo facto de o grão ser definido pela combinação de quatro chaves estrangeiras: *id_tempo*, *id_regiao*, *id_produto* e *id_cliente*, o que tornaria a chave primária composta demasiado complexa. As relações com as dimensões são todas do tipo 1 para N, dado que múltiplos registos de vendas podem corresponder ao mesmo dia, região, produto ou cliente. O *join* com a *dim_cliente* utiliza exclusivamente os registos ativos, com *flag_atual* = true, garantindo que cada conjunto de vendas é associada ao tipo de cliente vigente no momento da transação.

tf_meteorologia

Tabela 17- Caracterização da tabela de factos *tf_meteorologia*

Caracterização de Tabela de Factos	
Identificação	tf-Meteorologia
Descrição	Tabela que acolhe os registos diários de dados meteorológicos das 16 regiões alemãs, obtidos via API Open-Meteo. Permite correlacionar condições climáticas com o volume de vendas por categoria e região.
Data mart	BKLP Comercial

Tipo	<i>Snapshot</i> diário por região
Utilidade estratégica	Identificar correlações entre temperatura máxima e volume de vendas de água e refrigerantes. Antecipar picos de procura com base em previsões meteorológicas. Identificar categorias com maior sensibilidade a variações climáticas por região.
Povoamento	Carga histórica inicial. Atualizado semanalmente pelo pipeline consultando a API Open-Meteo para o período dos novos dados de vendas detetados pelo CDC.
Dimensão inicial	~31.136 registos após carga histórica (1943 dias × 16 regiões).
Crescimento	~112 novos registos por semana (16 regiões × 7 dias).
Período de dados	Janeiro 2021 até à data atual. Sincronizado temporalmente com tf-Vendas.

| Fonte: Elaboração Própria

Atributos: Dimensões

Tabela 18 - Atributos das dimensões na tabela de factos tf_meteorologia

Nr	Identificação	Chave	Tipo	Domínio	Descrição	Exemplos
1	id_tempo	Primária + Estrangeira	Integer	Inteiro sequencial	Componente da chave composta: referência à dim_calendario	1,45,200
2	id_regiao	Primária + Estrangeira	Integer	Inteiro sequencial	Componente da chave composta: referência à dim_regiao	1,5,12

| Fonte: Elaboração Própria

Atributos: Medidas

Tabela 19 - Atributos com medidas da tabela de factos tf_meteorologia

Nr	Identificação	Chave	Tipo	Domínio	Descrição	Exemplos
1	temp_max_c	Medida	Decimal	Valor real	Temperatura máxima diária em graus Celsius	2.4, 15.7, 34.2
2	precipitacao_mm	Medida	Decimal	Valor não negativo	Precipitação total diária em milímetros	0.0, 0.5, 12.3

| Fonte: Elaboração Própria

A tabela tf_meteorologia tem chave primária composta pela combinação de id_tempo e id_regiao. Esta opção justifica-se pelo facto de o grão ser univocamente identificado por estas duas chaves estrangeiras, não existindo duplicados possíveis.

tf_tweets

Tabela 20 - Caracterização da tabela de factos tf_tweets

Caracterização de Tabela de Factos	
Identificação	tf -tweets
Descrição	Tabela que acolhe os registos agregados de análise de sentimento social por dia, região e produto, obtidos a partir de publicações sintéticas de redes sociais processadas pelo modelo NLP
Data mart	BKLP Comercial
Tipo	agregado por dia, região, produto e categoria de sentimento
Utilidade estratégica	Correlacionar sentimento social com evolução de vendas por produto. Identificar produtos com sentimento positivo crescente mas volume de vendas estagnado. Detetar precocemente declínios de popularidade.

Povoamento	Carga histórica inicial cobrindo o período de 01/01/2021 a 31/12/2025. Atualizado semanalmente pelo pipeline com tweets sintéticos gerados por ciclo semanal, após processamento NLP na camada Silver.
Dimensão inicial	~6000 tweets
Crescimento	~150 novos tweets por semana processados pelo pipeline NLP.
Período de dados	Janeiro 2021 até à data atual. Sincronizado temporalmente com TF-Vendas e TF-Meteorologia.

| Fonte: Elaboração Própria

Atributos: Dimensões

Tabela 21- Caracterização da tabela de factos tf_tweets

Nr	Identificação	Chave	Tipo	Domínio	Descrição	Exemplos
1	id_tweets	Primária	Integer	Inteiro sequencial	Chave surrogate da tabela de factos de tweets	1, 2, 3
2	id_tempo	Estrangeira	Integer	Inteiro sequencial	Referência à dim_calendario	1, 45, 200
3	id_regiao	Estrangeira	Integer	Inteiro sequencial	Referência à dim_regiao	1, 5, 12
4	id_produto	Estrangeira	Integer	Inteiro sequencial	Referência à dim_produto	1, 10, 47
5	categoria_sentimento	Descritivo	String	3 valores	Polaridade do sentimento do tweet agregado	positivo, negativo, neutro

| Fonte: Elaboração Própria

Atributos:Medidas

Tabela 22 - Atributos com medidas da tabela de factos *tf_tweets*

Nr	Identificação	Chave	Tipo	Domínio	Descrição	Exemplos
1	score_sentimento	Medida	Float	0.0 a 1.0	Score médio de confiança do modelo NLP para o sentimento agregado	0.10, 0.50, 0.98
2	nr_tweets	Medida	Integer	Valor positivo	Número de tweets agregados por combinação de data, região, produto e sentimento	1, 5, 23

| Fonte: Elaboração Própria

A tabela *tf_tweets* possui chave primária *surrogate* *id_tweets*, introduzida pelo facto de o grão ser definido pela combinação de quatro chaves estrangeiras, nomeadamente *id_tempo*, *id_regiao*, *id_produto*, o que tornaria a chave primária composta demasiado complexa.

Adicionalmente ao modelo dimensional, o sistema implementa duas tabelas de *serving* na camada *Gold* em Delta Lake para consumo direto pelos modelos de *Machine Learning*. A tabela *serving_vendas* contém os campos *id_tempo*, *data_completa*, *id_regiao*, *nome_regiao*, *id_produto*, *nome_produto*, *categoria_produto*, *id_cliente*, *quantidade*, *preco_total* e *preco_unidade*. A tabela *serving_clima* contém os campos da tabela anterior mais o *temp_max_c* e *precipitacao_mm*. Ambas as tabelas são atualizadas incrementalmente por *append* a cada ciclo semanal do pipeline, em simultâneo com as tabelas de factos do modelo dimensional.

Estratégia de Materialização

A estratégia de materialização adotada é de materialização externa, consistindo na escrita do modelo dimensional no PostgreSQL pelo Spark via ligação JDBC, após todas as transformações e agregações terem sido realizadas na camada *Gold*. O PostgreSQL serve exclusivamente como *serving layer* para o Power BI. A escolha do PostgreSQL justifica-se pela familiaridade da equipa com a ferramenta, pela integração nativa com o pgAdmin, e pela integração nativa com o Power BI através de conector direto.

Estratégia de Serving

O sistema adota uma arquitetura de *serving* híbrida, disponibilizando os dados a partir de dois destinos distintos consoante o consumidor.

O PostgreSQL serve como *serving layer* para o Power BI, disponibilizando o modelo dimensional através de ligação direta.

As tabelas *serving_vendas* e *serving_clima*, diretamente na camada *Gold* em formato Delta Lake, servem os modelos de machine learning via Spark. Este destino é adequado para leitura de grandes volumes históricos durante o treino dos modelos, beneficiando da leitura colunar nativa e distribuída do formato Delta Lake sem necessidade de movimentação dos dados para um sistema externo.

Os resultados gerados pelos modelos de *machine learning* são posteriormente escritos em tabelas dedicadas no PostgreSQL, integrando-se no mesmo *serving layer* do Power BI e garantindo que as previsões e classificações são consumidas através da mesma interface que os restantes dados analíticos.

Modelação Conceptual(Golfarelli-Maio-Rizzi)

O diagrama conceptual apresentado foi desenvolvido a baixo seguindo a notação de Golfarelli-Maio-Rizzi.




Figura 2 - Modelo Conceptual de (Golfarelli-Maio-Rizzi)

| Fonte: Elaboração Própria, adaptado de Golfarelli, Maio & Rizzi

Modelação multidimensional

O diagrama apresentado representa a implementação do modelo multidimensional, detalhando a estrutura de cada tabela com as suas chaves primárias, chaves *surrogates*, chaves naturais, chaves estrangeiras e atributos. O esquema em constelação é claramente visível através das ligações entre as três tabelas de factos e as dimensões partilhadas *dim_calendario* e *dim_regiao*. A *dim_cliente* representa a implementação do SCD Tipo 2, com os atributos *data_inicio*, *data_fim* e *flag_atual* que permitem rastrear historicamente as mudanças no tipo de cliente, e o *id_original_cliente* como chave natural que preserva a rastreabilidade entre versões do mesmo cliente. A *tf_meteorologia* tem chave primária composta por *id_regiao* e *id_tempo*, refletindo o facto de o grão ser univocamente identificado por estas duas dimensões sem necessidade de uma *surrogate key* adicional.




Figura 3 - Modelo multidimensional(star-schema)

| Fonte: Elaboração Própria

3.5 O Processo de Integração de Dados

Visão Geral do Processo de Integração

O processo de integração de dados foi desenvolvido seguindo uma abordagem incremental e modular, organizada em torno da arquitetura Data Lakehouse em camadas *Bronze*, *Silver* e *Gold*. O processo divide-se em dois momentos distintos: a carga histórica inicial, que processou os dados do período de janeiro de 2021 até janeiro de 2026, e o pipeline de atualização semanal, que processa de forma paralela e incremental os novos dados gerados a cada ciclo. O processo de integração é documentado através da notação BPMN, apresentada na subsecção seguinte, que modela todas as tarefas, decisões e fluxos de dados do pipeline de forma visualmente acessível e independente da implementação técnica.

Ferramentas e Métodos de Integração

O **Apache Spark** é o motor central de integração e processamento do pipeline. É utilizado para leitura das fontes em múltiplos formatos (CSV, JSON, texto livre), aplicação de todas as transformações de limpeza e normalização na camada *Silver*, construção do modelo dimensional na camada *Gold* através de operações de agregação, join e MERGE nativo do Delta Lake, e escrita no PostgreSQL via JDBC. A ligação ao MinIO é estabelecida através do conector S3A do Hadoop e a ligação ao PostgreSQL através do driver JDBC.

O **Prefect** é a ferramenta de orquestração do pipeline semanal. Garante a execução sequencial das duas tarefas principais, nomeadamente, geração de dados seguida do pipeline de integração, com *retry* automático com *backoff* exponencial (3 tentativas, *factor* de *backoff* de 2) em caso de falha transitória de conectividade. Assegura que o pipeline só executa após a geração de dados ser concluída com sucesso.

O **MinIO** é o serviço de *object storage* que aloja as camadas *Bronze*, *Silver* e *Gold* do Data Lakehouse. Serve também como repositório de estado do pipeline, alojando o ficheiro `cdc_state.json` com o *watermark* do CDC e o ficheiro `checkpoint.json` com o estado das fases do pipeline.

O **PostgreSQL** é o destino final do modelo dimensional, recebendo os dados já transformados pelo Spark via JDBC. Serve como *serving layer* para o Power BI e como destino dos resultados das previsões dos modelos de Machine Learning. O estado do CDC é também replicado numa tabela `cdc_watermark` apenas para monitorização.

A biblioteca **Transformers da HuggingFace** é utilizada especificamente para o **processamento NLP** dos tweets, aplicando os modelos como o `cardiffnlp/twitter-xlm-roberta-base-sentiment` para atribuição de sentimento e deteção de produtos e regiões mencionados.

O **Delta Lake** é o formato de armazenamento adotado na camada *Gold*, suportando as operações MERGE idempotentes utilizadas para a evolução Incremental das dimensões, o versionamento para auditoria e *rollback*, e a leitura colunar distribuída utilizada pelos modelos de *Machine Learning* via Spark.

A biblioteca **Requests** do Python é utilizada especificamente para a extração dos dados meteorológicos, realizando chamadas HTTP à API REST do Open-Meteo para cada uma das

16 regiões alemãs. A cada execução semanal do pipeline, a biblioteca constrói os pedidos com os parâmetros de data de início e fim correspondentes ao novo período a processar, garantindo que apenas os dados meteorológicos do novo período são obtidos sem necessidade de filtrar o histórico. A resposta JSON devolvida pela API é mantida em memória Python e posteriormente convertida num DataFrame Spark para carregamento na camada Bronze.

Mapeamento Source-to-Target da Fonte “Vendas”

Tabela 23 - Source-to-target Datamap de “Vendas”

Campo Fonte	Tipo Fonte	Camada Silver	Camada Gold	Campo Destino	Tabela Destino
Order_Date	Date	Sem transformação	Extração de atributos temporais e estação do ano	ano (Integer), trimestre(Integer), mes (Integer), dia (Integer), estacao_ano (String), data_completa (Date)	dim_calendario
Order_Date	Date	Sem transformação	Join com dim_calendario	id_tempo (Integer)	tf_vendas
Region	String	Mapeamento das regiões	Deduplicação, geração de surrogate key	nome_regiao (String), id_regiao (Integer)	dim_regiao
Region	String	Sem transformação	Join com dim_regiao	id_regiao (Integer)	tf_vendas
Product	String	Sem transformação	Deduplicação produto, geração de surrogate key	nome_produto (String), id_produto (Integer)	dim_produto
Category	String	Sem transformação	Sem transformação	categoria_produto (String)	dim_produto

Product	String	Sem transformação	Join com dim_produto	id_produto (Integer)	tf_vendas
Customer_ID	String	Sem transformação	SCD Tipo 2, geração de surrogate key	customer_id (String), id_cliente (Integer)	dim_cliente
Customer_Type	String	Sem transformação	SCD Tipo 2, detecção de mudanças	tipo_cliente (String), data_inicio (Date), data_fim (Date), flag_atual (Boolean)	dim_cliente
Customer_ID	String	Sem transformação	Join com dim_cliente (flag_atual=true)	id_cliente (Integer)	tf_vendas
Quantity	Integer	Sem transformação	SUM por grão	quantidade (Integer)	tf_vendas
Total_Price	Decimal	Sem transformação	SUM por grão	preco_total (Decimal)	tf_vendas
Unit_Price	Decimal	Sem transformação	AVG por grão	preco_unidade (Decimal)	tf_vendas
Discount	Decimal	Removido: incorporado no Total_Price	Não aplicável	Não aplicável	Não aplicável
Order_ID	String	Removido: não entra no modelo dimensional	Não aplicável	Não aplicável	Não aplicável

| Fonte: Elaboração Própria

Mapeamento Source-to-Target da “Meteorologia”

Tabela 24- Source to target datamap de “Meteorologia”

Campo Fonte	Tipo Fonte	Camada Silver	Camada Gold	Campo Destino	Tabela Destino
Data	Date	Sem transformação	Join com dim_calendario	id_tempo (Integer)	tf_meteorologia
Data	Date	Sem transformação	Extração de atributos temporais e estação do ano	id_tempo(integer), ano (Integer), trimestre (Integer), mes (Integer), dia (Integer), estacao_ano (String), data_completa (Date)	dim_calendario
Regiao	String	Sem transformação	Join com dim_regiao	id_regiao (Integer)	tf_meteorologia
Temp_Max_C	Decimal	Sem transformação	Sem transformação	temp_max_c (Decimal)	tf_meteorologia
Precipitacao_mm	Decimal	Sem transformação	Sem transformação	precipitacao_mm (Decimal)	tf_meteorologia

| Fonte: Elaboração Própria

Mapeamento Source-to-Target da Fonte "Tweets"

Tabela 25 - Source to target Datamap de "tweets"

Campo Fonte	Tipo Fonte	Camada Silver	Camada Gold	Campo Destino	Tabela Destino
Linha de texto bruto	String	Extração de tweet_date via regex	Extração de atributos temporais e estação do ano	id_tempo(integer),ano (Integer), trimestre (Integer), mes (Integer), dia (Integer), estacao_ano (String), data_completa (Date)	dim_calendario
Linha de texto bruto	String	Extração de tweet_date via regex	Join com dim_calendario	id_tempo (Integer)	tf_tweets
Linha de texto bruto	String	Extração de user_id via regex	Removido: não entra no modelo dimensional	Não aplicável	Não aplicável
Linha de texto bruto	String	Extração de texto_original via regex	Removido: não entra no modelo dimensional	Não aplicável	Não aplicável
texto_original	String	Aplicação modelo NLP: detecção de produto mencionado	Deduplicação, geração de surrogate key	nome_produto (String), id_produto (Integer)	dim_produto
texto_original	String	Aplicação modelo NLP: detecção de produto mencionado	Join com dim_produto	id_produto (Integer)	tf_tweets
texto_original	String	Aplicação modelo NLP: detecção de região mencionada	Deduplicação, geração de surrogate key	nome_regiao (String), id_regiao (Integer)	dim_regiao

texto_original	String	Aplicação modelo NLP: detecção de região mencionada	Join com dim_regiao	id_regiao (Integer)	tf_tweets
texto_original	String	Aplicação modelo NLP: classificação de sentimento	Agregação por grão	categoria_sentimento (String)	tf_tweets
texto_original	String	Aplicação modelo NLP: score de sentimento	AVG por grão	score_sentimento (Decimal)	tf_tweets
texto_original	String	Aplicação modelo NLP	COUNT por grão	nr_tweets (Integer)	tf_tweets
Linha de texto bruto	String	Tweets sem produto ou região reconhecidos desviados para zona de quarentena	Não aplicável	Não aplicável	Não aplicável

| Fonte: Elaboração Própria

Modelo BPMN do Processo de Integração de Dados

O diagrama seguinte representa o modelo BPMN do pipeline semanal de integração de dados, desenvolvido com recurso à ferramenta Bizagi Modeler. Devido à extensão do diagrama, o modelo é apresentado em três partes sequenciais.




Figura 4 - BPMN completo
| Fonte: Elaboração Própria (Bizagi Modeler, 2024)




Figura 5 - Início do BPMN

| Fonte: Elaboração Própria (Bizagi Modeler, 2024)




Figura 6 - Segunda parte do BPMN

| Fonte: Elaboração Própria (Bizagi Modeler, 2024)




Figura 7 - Parte final do BPMN

| Fonte: Elaboração Própria (Bizagi Modeler, 2024)

Descrição do Processo de Integração de Dados

O processo de integração de dados é executado semanalmente pelo orquestrador Prefect e segue o fluxo modelado no diagrama BPMN apresentado. O pipeline inicia com a leitura do estado do CDC e do *checkpoint*, seguida da detecção de dados novos nas fontes locais, do processamento em camadas *Bronze*, *Silver* e *Gold*, e termina com o carregamento no PostgreSQL e a atualização do *watermark*.

Fase de Inicialização

O pipeline inicia com a tarefa de leitura do estado do CDC, que lê o ficheiro `cdc_state.json` do MinIO para obter a data da última execução bem sucedida. Esta data define o *watermark* que será utilizado para filtrar apenas os dados novos nas fontes locais.

De seguida é verificada a existência de um *checkpoint* ativo para o período em processamento. Se existir um ficheiro `checkpoint.json` no MinIO correspondente ao mesmo período de dados, o pipeline retoma a execução a partir da última fase concluída com sucesso, evitando reprocessar fases já concluídas. Se não existir, é inicializado um novo *checkpoint* com todas as fases no estado pendente.

O pipeline deteta de seguida os dados novos nas fontes locais, nomeadamente o ficheiro CSV de vendas e o ficheiro TXT de tweets, filtrando apenas os registos com data posterior ao *watermark*. Se não existirem dados novos o pipeline termina imediatamente sem processamento. Se existirem dados novos, a API Open-Meteo é consultada para o período correspondente, garantindo sincronização temporal entre as três fontes, e o *checkpoint* é atualizado.

Fase de Validação e *Bronze*

Antes de carregar os dados para o *Bronze* é validado o *schema* do ficheiro CSV de vendas, verificando que todas as colunas esperadas estão presentes. Se o *schema* for inválido o pipeline termina imediatamente com um erro, dado que uma alteração estrutural na fonte requer intervenção manual antes de continuar. Se o *schema* for válido, os dados das três fontes são carregados para as respetivas subpastas do *Bronze* no MinIO, nomeadamente *Bronze/vendas/*, *Bronze/social/* e *Bronze/meteo/*, nas suas formas originais sem qualquer transformação. O *checkpoint* é atualizado após a conclusão do carregamento *Bronze*.

Fase *Silver*

Após a conclusão do carregamento *Bronze*, o pipeline inicia o processamento *Silver* em paralelo para as três fontes, dado que são independentes entre si.

Processamento *Silver* das Vendas

O Spark lê o ficheiro CSV do *Bronze* com um *schema* explícito e rigorosamente definido, aplicando casting explícito dos tipos de dados para cada campo. As transformações aplicadas são a remoção da coluna *Discount*, que não entra no modelo dimensional dado que o *Total_Price* já incorpora o desconto no seu cálculo, e o mapeamento dos nomes das regiões para os nomes oficiais alemães com os caracteres especiais correctos, nomeadamente a conversão de "Baden-Wurttemberg" para "Baden-Württemberg" e de "Thuringen" para "Thüringen", garantindo a consistência referencial com as restantes fontes de dados. Após as transformações é verificada a existência de registos com campos obrigatórios nulos. Se existirem variáveis com campos nulos, são desviados para a zona de quarentena em *raw/rejected/vendas/* com o campo *motivo_rejeicao* preenchido, sem interromper o pipeline. Os registos válidos são persistidos em formato Parquet na subpasta *silver/vendas/* do MinIO. O *checkpoint* é atualizado após a conclusão desta fase.

Processamento *Silver* dos Tweets

O Spark lê o ficheiro TXT do *Bronze* linha a linha e extrai os três campos estruturados através de expressões regulares, convertendo o texto não estruturado num *DataFrame* com os campos *tweet_date*, *user_id* e *texto_original*. As linhas inválidas ou vazias são filtradas e o resultado é persistido como CSV estruturado na subpasta *silver/social/parsed/*.

De seguida é aplicado o modelo de NLP sobre o texto de cada publicação, classificando-a como positiva, negativa ou neutra e calculando um score de sentimento entre 0 e 1. Em paralelo são detetados o produto mencionado e a região geográfica referida através de correspondência de texto com os catálogos do sistema. As publicações sem produto reconhecido, sem região reconhecida ou sem ambos são desviadas para a zona de quarentena em *Bronze/rejected/tweets/* com o motivo de rejeição correspondente, nomeadamente *sem_produto*, *sem_regiao* ou *sem_produto_e_regiao*. Os registos válidos

são enriquecidos com os campos `sentimento`, `score_sentimento`, `produto_mencionado` e `regiao_mencionada`.

As colunas `user_id` e `texto_original` são removidas dado que não entram no modelo dimensional, e o resultado final é convertido para Parquet na subpasta `silver/social/parquet/`. O *checkpoint* é atualizado após a conclusão desta fase.

Processamento *Silver* da Meteorologia

O Spark lê os 16 ficheiros JSON do *Bronze* em simultâneo com a opção *multiLine* e aplanar a estrutura hierárquica de *arrays* aninhados através das funções `arrays_zip` e `explode`, convertendo os *arrays* paralelos de datas, temperaturas e precipitações numa linha por dia por região. O resultado é persistido em formato Parquet na subpasta `silver/meteo/` com as colunas `Regiao`, `Data`, `Temp_Max_C` e `Precipitacao_mm`. O *checkpoint* é atualizado após a conclusão desta fase.

Após a conclusão das três fases *Silver* em paralelo, o *gateway* de sincronização aguarda que todos os ramos estejam concluídos antes de avançar para a fase *Gold*.

Fase *Gold*

Após a sincronização do processamento *Silver*, o pipeline inicia a construção do modelo dimensional na camada *Gold* do MinIO em formato Delta Lake. Esta fase divide-se em três subfases sequenciais: construção das dimensões, construção das tabelas de factos e construção das tabelas de *serving* para *Machine Learning*.

Construção das Dimensões

As quatro dimensões são construídas em paralelo dado que são independentes entre si. Para cada dimensão o pipeline lê os dados *Silver* relevantes, identifica os registos novos através de operações MERGE nativas do Delta Lake ou operações de left anti join e insere apenas os registos que ainda não existem na tabela de destino. A natureza idempotente do MERGE e do join garante que a re-execução desta fase em caso de falha produz sempre o mesmo resultado sem duplicação de dados. Os *ids surrogates* existentes nunca são alterados entre execuções, garantindo a estabilidade das chaves do modelo dimensional.

A `dim_calendario` é construída a partir da união das datas únicas presentes nas três fontes *Silver*, com derivação dos atributos temporais e da estação do ano para cada data. A `dim_regiao` é construída a partir da união das regiões únicas presentes nos dados de vendas e meteorologia. A `dim_produto` é construída a partir dos produtos únicos presentes nos dados de vendas.

A `dim_cliente` recebe tratamento especial através da implementação de SCD Tipo 2. O pipeline deteta mudanças de tipo de cliente tanto dentro do mesmo *batch* de processamento como em relação ao histórico existente na camada *Gold*. Para cada mudança detetada, o registo anterior é fechado com a atualização de `data_fim` e `flag_atual = false`, e um novo

registo ativo é criado com a data da primeira compra do novo tipo como `data_inicio` e `flag_atual = true`. O *checkpoint* é atualizado após a conclusão de cada dimensão.

Construção das Tabelas de Factos

Após a sincronização da construção das dimensões, as três tabelas de factos são construídas em paralelo. Para cada tabela de factos o pipeline lê os *lookups* completos das dimensões, agrega os dados *Silver* ao grão definido e realiza os *joins* com as *surrogate keys* das dimensões.

A `tf_vendas` é construída a partir dos dados *Silver* de vendas, agregados ao grão de um dia, uma região, um produto e um cliente. O *join* com a `dim_cliente` utiliza exclusivamente os registos ativos com `flag_atual = true`, garantindo que cada venda é associada ao tipo de cliente no momento da transação. As medidas calculadas são a soma das quantidades vendidas, a soma do valor total das vendas e a média do preço unitário.

A `tf_meteorologia` é construída a partir dos dados *Silver* de meteorologia, que já se encontram ao grão correto de um dia por região, não sendo necessária qualquer agregação adicional. As medidas são a temperatura máxima diária e a precipitação acumulada diária.

A `tf_tweets` é construída a partir dos dados *Silver* de tendências sociais, agregados ao grão de um dia, uma região, um produto e uma categoria de sentimento. Dado que os tweets sem produto ou região reconhecidos foram previamente desviados para a zona de quarentena na fase *Silver*, todos os registos que chegam a esta fase possuem correspondência garantida nas dimensões. As medidas calculadas são a média do score de sentimento e a contagem de publicações. O *checkpoint* é atualizado individualmente após a conclusão de cada tabela de factos.

Construção das Tabelas de Serving para Machine Learning

Após a sincronização da construção das tabelas de facto, as duas tabelas de *serving* são construídas em paralelo. A `serving_vendas` resulta do *join* entre `tf_vendas`, `dim_calendario`, `dim_regiao` e `dim_produto`, incluindo diretamente os atributos descritivos para eliminar a necessidade de *joins* adicionais pelos modelos de ML. A `serving_clima` resulta do *join* entre `tf_meteorologia`, `dim_calendario` e `dim_regiao`. Ambas as tabelas são persistidas em formato Delta Lake e atualizadas por *append incremental* a cada ciclo semanal.

Fase PostgreSQL e Finalização

Após a conclusão de toda a fase *Gold*, o pipeline inicia o carregamento do modelo dimensional no PostgreSQL. Este carregamento segue uma ordem sequencial obrigatória: as dimensões são sempre carregadas antes das tabelas de facto para garantir a integridade referencial do modelo dimensional.

Carregamento das Dimensões

As 4 dimensões são carregadas de forma paralela no PostgreSQL de forma incremental. As dimensões `dim_calendario`, `dim_regiao` e `dim_produto` são carregadas via JDBC com inserção incremental, utilizando `INSERT ON CONFLICT DO NOTHING` para garantir que apenas os registos novos são inseridos e que os registos existentes não são alterados.

Para a *dim_cliente*. O carregamento é feito com `INSERT ON CONFLICT DO UPDATE(upsert)`, que garante que as atualizações geradas pelo SCD Tipo 2 no Gold nomeadamente o fecho de registos com *data_fim* e *flag_atual = false* se propagam corretamente ao PostgreSQL, mantendo a consistência do histórico de variação do tipo de cliente entre o Delta Lake e o Data Warehouse.

Carregamento das Tabelas de Factos

Após a sincronização do carregamento das dimensões, as três tabelas de facto são carregadas no PostgreSQL via JDBC por *append* direto. A idempotência é garantida pela arquitetura do pipeline: em caso de re-execução as tabelas de facto são truncadas para o período que estamos a processar e reescritas a partir dos dados já validados e únicos na camada *Gold*.

Finalização e Atualização do *Watermark*

Após a conclusão do carregamento de todas as tabelas no PostgreSQL, o pipeline executa as tarefas de finalização em sequência. O *watermark* do CDC é atualizado simultaneamente em dois locais: no MinIO, através da escrita do ficheiro *cdc_state.json* com a nova *ultima_data_processada*, e no PostgreSQL, na tabela *cdc_watermark*. O MinIO é a fonte de verdade do *watermark* e o PostgreSQL é utilizado exclusivamente para monitorização.

Por fim o ficheiro *checkpoint.json* é resetado no MinIO, sinalizando que a execução foi concluída com sucesso. A reset dos checkpoints é a última operação do pipeline e garante que uma eventual re-execução futura não seja confundida com uma recuperação de falha. O pipeline termina com o evento de fim.

Processo de Validação e Testes

O processo de validação e testes foi aplicado em três momentos distintos: antes da implementação, durante o desenvolvimento e após a conclusão do pipeline.

Para facilitar a monitorização manual durante o desenvolvimento, os testes foram inicialmente realizados sobre uma amostra reduzida de aproximadamente uma dezena de registos por fonte, permitindo verificar visualmente o comportamento de cada transformação e validar os resultados esperados antes de executar o pipeline sobre o volume histórico completo. Esta abordagem permitiu identificar e corrigir problemas de forma rápida e controlada, reduzindo o tempo de ciclo de desenvolvimento e teste.

Validação Pré-Implementação

Antes de iniciar a implementação foi realizado um processo de *data profiling* sobre as fontes de vendas e meteorologia com recurso à biblioteca YData Profiling, cujos resultados se encontram documentados nos anexos. Este *profiling* permitiu validar a qualidade das fontes, confirmar a granularidade diária e regional necessária para o modelo dimensional e identificar as transformações a aplicar na camada *Silver*. Os resultados confirmaram *completeness* de 100% em todos os campos críticos das vendas e ausência de anomalias nos dados meteorológicos, validando a viabilidade técnica do sistema antes de qualquer desenvolvimento.

Validação Durante o Desenvolvimento

Durante o desenvolvimento foram aplicados testes incrementais após a conclusão de cada camada do pipeline:

Na camada *Bronze* foi validado que os dados eram persistidos nas suas formas originais sem alterações.

Na camada *Silver* fomos verificando se os registos inválidos eram corretamente desviados para a zona de quarentena e também validada as transformações documentadas no capítulo 3.

Na camada *Gold* foi validada a integridade referencial do modelo dimensional, verificando que todos os *joins* entre tabelas de facto e dimensões produziam resultados sem valores nulos nas chaves estrangeiras. Foi também validado o comportamento do SCD Tipo 2 na *dim_cliente*, confirmando que mudanças de tipo de cliente geravam corretamente novos registos com *flag_atual* = true e fechavam os registos anteriores com *flag_atual* = false.

No PostgreSQL foi validada a consistência entre os dados da camada *Gold* e o Data Warehouse, verificando as contagens de registos em cada tabela e executando *queries* analíticas no pgAdmin para confirmar que os resultados eram coerentes com os dados esperados.

Validação do Mecanismo de CDC e *Checkpointing*

O mecanismo de CDC foi validado através de execuções controladas do pipeline com diferentes *watermarks*, confirmando que apenas os registos com data posterior ao *watermark* eram processados em cada execução e que o *watermark* era corretamente atualizado no final de cada ciclo.

O mecanismo de *checkpointing* foi validado através da simulação de falhas em diferentes fases do pipeline, interrompendo deliberadamente a execução e confirmando que o pipeline retomava corretamente a partir da última fase concluída sem reprocessar fases já concluídas e sem duplicar dados.

Validação do Modelo NLP

O modelo de análise de sentimento foi validado através da inspeção manual de uma amostra de publicações e das respetivas classificações geradas pelo modelo, confirmando que as classificações eram coerentes com o conteúdo textual das publicações. Foi também validada a deteção de produtos e regiões, verificando que os produtos e regiões do catálogo eram corretamente identificados nos textos das publicações sintéticas.

Validação Final do Sistema

Após a conclusão do desenvolvimento foi realizada uma validação *end-to-end* do pipeline completo, executando um ciclo semanal completo e verificando que todos os componentes funcionavam corretamente de forma integrada. Foi confirmado que os dashboards do Power BI apresentavam dados corretos e atualizados após cada execução do pipeline, e que as tabelas de *serving* para *Machine Learning* continham os dados esperados na camada *Gold*.

4. Exploração e Análise de Dados

4.1 Organização geral do sistema de dashboarding

Para organizar o sistema de *dashboards*, optámos por dividir a informação em quatro grandes áreas temáticas (Como o nosso modelo de dados é complexo e podemos ter diferentes tipos de utilizadores a aceder à plataforma, esta separação garante que cada perfil encontra rapidamente aquilo de que precisa, sem se perder no meio de métricas que não interessam para o seu trabalho diário. A organização foi pensada da seguinte forma:

- **Perfil de Gestão e Estratégia (Visão Macro):** Estes utilizadores(nós no caso) precisam de olhar para o negócio de cima. Para eles, construímos a Análise de Vendas (para acompanharem o histórico e verem quem está a crescer) e a Previsão de Procura e Análise de Tendências (para planearem o futuro e controlarem o risco de perder clientes).
- **Perfil de Operações e Logística (Visão Tática):** As equipa (nós no caso) que gerem a distribuição precisam de dados mais práticos. O *dashboard* de Correlação entre Clima e Vendas é ideal para este perfil, porque ajuda a perceber como o tempo (chuva ou calor) afeta a saída dos produtos, permitindo ajustar o fornecimento de forma rápida.
- **Perfil de Marketing e Comunicação (Visão Comportamental):** Aqui o foco é a marca. O painel de Análise de Sentimento Social cruza as vendas com o que as pessoas dizem nas redes sociais. Isto serve para a equipa perceber se uma campanha correu bem ou para detetar o início de uma crise de reputação antes que ela afete seriamente a faturação.

4.2 Serviços de exploração e análise implementados

Desenvolvemos quatro *dashboards* interativos para dar resposta aos requisitos do projeto. A escolha de cada gráfico não foi ao acaso: procurámos sempre a melhor forma de traduzir os dados (sejam eles de vendas, meteorologia ou redes sociais) em informações diretas e prontas a usar.

Dashboard: Análise de Vendas

O dashboard de Análise de Vendas responde aos requisitos da Área 1 e destina-se a utilizadores com necessidade de análise histórica e comparativa do desempenho comercial da distribuidora. O dashboard disponibiliza cinco visuais complementares. O gráfico de Crescimento Regional apresenta a taxa de crescimento de vendas por Bundesland, permitindo identificar as regiões com maior expansão no período 2021-atualidade. A Evolução das Vendas por Categoria mostra a tendência mensal de cada categoria ao longo do histórico, respondendo ao requisito de análise trimestral e identificação de categorias em declínio. O visual B2B vs B2C compara o volume de vendas por categoria entre os dois tipos de cliente, respondendo ao requisito de análise diferenciada dos padrões de compra. A Evolução das Vendas por Produto permite analisar a trajetória de um produto específico ao longo do tempo. O Volume de Vendas por Região apresenta a distribuição do volume por categoria em cada

região, permitindo identificar os produtos dominantes em cada território. O dashboard inclui filtros por estação do ano e por região, tornando-o operacional para análises segmentadas.

- Como funciona:
 - Usámos um **Gráfico de Barras** com cores dinâmicas para mostrar logo quem está a crescer (a verde) e alertar para as regiões mais fracas.
 - O **Gráfico de Linhas** ajuda a ver a evolução das categorias ao longo do tempo e a detetar facilmente se algum produto está a cair.
 - Colocámos botões de Estação do Ano e um filtro de Região para que o utilizador consiga explorar os dados livremente e procurar os seus próprios *insights*.



Figura 8 - Dashboard de Análise de Vendas

| Fonte: Elaboração Própria (Microsoft Power BI, 2024)

Dashboard: Correlação entre Clima e Vendas

O dashboard de Correlação entre Clima e Vendas responde aos requisitos da Área 2 e destina-se a utilizadores com necessidade de compreender o impacto das condições meteorológicas na procura. A matriz de Sensibilidade Térmica por Categoria cruza faixas de temperatura com intensidade de precipitação e apresenta o volume médio diário por categoria em cada combinação, respondendo diretamente aos requisitos de correlação temperatura-vendas e precipitação-vendas. O visual de Impacto da Chuva nas Vendas por Categoria compara o volume médio de cada categoria em três cenários de precipitação. O gráfico de Impacto da Temperatura Máxima nas Vendas de Água e Refrigerantes apresenta a relação entre temperatura e volume para as categorias mais sensíveis ao calor. O Perfil de Sensibilidade Climática por Região permite identificar quais os meses e regiões onde a correlação clima-vendas é mais pronunciada, respondendo ao último requisito da Área 2.

- **Como funciona:**

- Apostámos nos **Gráficos de Dispersão (Scatter plots)** com linha de tendência porque mostram imediatamente, pela inclinação da linha, se o calor puxa ou não pelas vendas de águas e refrigerantes.
- Criámos uma **Matriz (Mapa de Calor)** para cruzar as categorias com as temperaturas, onde as cores mais fortes mostram logo os picos de procura.
- Para a chuva, o **Gráfico de Colunas Agrupadas** foi a melhor solução para comparar o comportamento de compra entre os dias secos e os dias de chuva de uma forma limpa.




Figura 9 - Dashboard da correlação clima-vendas

| Fonte: Elaboração Própria (Microsoft Power BI, 2024)

Dashboard: Análise de Sentimento Social

O dashboard de Análise de Sentimento Social responde aos requisitos da Área 3 e destina-se a utilizadores com necessidade de monitorizar a opinião pública sobre os produtos da distribuidora. O visual de Sentimento Negativo como Indicador Avançado sobrepõe o volume de tweets negativos com o volume de vendas ao longo do tempo, permitindo verificar se o sentimento negativo antecede quedas de vendas. O visual de Vendas vs. Sentimento Público cruza o volume de vendas mensal com o score médio de sentimento, respondendo ao requisito de correlação temporal entre sentimento e vendas. O visual de Análise de Potencial Inexplorado por Produto identifica produtos com score de sentimento positivo elevado mas volume de vendas ainda abaixo do esperado, respondendo diretamente ao requisito de identificação de produtos com sentimento positivo crescente mas vendas estagnadas. O dashboard inclui um filtro por produto que permite focar a análise num produto específico.

- **Como funciona:**

- Como queríamos comparar unidades vendidas (que chegam aos milhares) com scores de sentimento (que são decimais), tivemos de usar **Gráficos com Eixo Y Duplo**.
- Ao cruzar estas linhas no tempo, conseguimos ver muito bem o "efeito de atraso", ou seja, identificar os momentos em que as queixas sobem e as vendas caem umas semanas depois.
- O filtro por produto ao lado é essencial, porque as crises de imagem costumam atacar marcas específicas e não o negócio todo por igual.




Figura 10 - Dashboard de análise de sentimento Social

| Fonte: Elaboração Própria (Microsoft Power BI, 2024)

Dashboard: Previsão de Procura e Análise de Tendências

O dashboard de Previsão de Procura e Análise de Tendências responde aos requisitos da Área 4 e destina-se a utilizadores com necessidade de suportar decisões de planeamento de stocks e gestão de clientes. A Matriz de Previsão apresenta as quantidades previstas para os doze meses seguintes por produto e região, permitindo ao utilizador identificar de forma imediata as combinações com maior procura esperada. O gráfico de Evolução Temporal da Procura Prevista apresenta a trajetória mensal das previsões com a margem de confiança de 80%, tornando visível a incerteza associada a cada previsão. Os Indicadores de Risco de Churn apresentam em cartões de destaque o número de clientes em risco alto, o número de clientes inativos há mais de quatro meses, o número de clientes simultaneamente em risco alto e inativos, e a média de dias de abandono. O dashboard inclui um filtro por estação do ano que atualiza a matriz de previsão para o horizonte temporal selecionado.

- **Como funciona:**

- O **Gráfico de Linhas com Margem de Confiança** é a peça central. Não mostra apenas o que o modelo prevê, mas também desenha uma "sombra" com a margem de erro. Isto dá muita segurança a quem gere o *stock*.
- A **Matriz de Previsão** detalha estes números por região e produto para ajudar na logística fina.
- Por fim, para o *churn*, usámos **Cartões de KPI** e uma tabela para monitorização da atividade dos clientes .Eles mostram diretamente os números que interessam (ex: Clientes Inativos > 4 meses), criando um painel de alerta focado na ação rápida da equipa de retenção.




Figura 11- Dashboard de previsão e análise de tendências

| Fonte: Elaboração Própria (Microsoft Power BI, 2024)

5. O Sistema de Análise de Tendências de Aquisição de Produtos

5.1 Definição do problema e compreensão dos elementos de análise envolvidos.

A BKLP Supply & Distribution opera num mercado onde a procura de bebidas é fortemente condicionada por fatores externos dinâmicos que o histórico de transações isolado não consegue capturar. Como referido no capítulo 1, vagas de calor podem disparar exponencialmente a procura por águas e refrigerantes, enquanto períodos de frio podem favorecer o consumo de vinhos e bebidas destiladas. A incapacidade de antecipar estes padrões resulta em possíveis ruturas de *stock* com perda direta de receita ou em excesso de inventário com custos de armazenamento acrescidos. Paralelamente, a acumulação de clientes inativos não identificados representa um risco crescente de erosão da base comercial da empresa.

O sistema de análise de tendências de aquisição de produtos tem como objetivo resolver dois problemas distintos mas complementares. O primeiro consiste na previsão quantitativa da procura por produto e região para os doze meses seguintes, permitindo ao sistema antecipar com antecedência suficiente as necessidades em cada um dos Bundesländer.

O segundo consiste na identificação automática de clientes em risco de churn, suportando decisões proativas de retenção antes que o abandono se consolide.

Para resolver o problema de previsão de procura foram desenvolvidos dois modelos distintos, ambos baseados no algoritmo *Random Forest Regressor*. O primeiro modelo, designado Modelo 1A, utiliza exclusivamente variáveis temporais e comerciais como preditores. O segundo modelo, designado Modelo 1B, incorpora adicionalmente variáveis climáticas, nomeadamente a temperatura máxima mensal e a precipitação acumulada mensal, como *features* adicionais, testando a hipótese de que a inclusão de informação meteorológica melhora a capacidade preditiva do modelo. Ambos os modelos são treinados sobre os mesmos dados históricos e avaliados com as mesmas métricas, permitindo uma comparação direta e objetiva do contributo das variáveis climáticas para a qualidade da previsão. O melhor modelo, determinado pelo MAE de *cross-validation*, é automaticamente selecionado para gerar as previsões escritas no Data Warehouse.

Para resolver o problema de identificação de churn foi desenvolvido um modelo de classificação, também baseado no algoritmo *Random Forest Classifier*, que classifica cada cliente como ativo ou em risco de churn com base no seu perfil comportamental histórico. O modelo utiliza features que capturam a recência, frequência e valor das compras de cada cliente, sem recorrer diretamente ao número de dias desde a última compra para evitar *data leakage*, conforme discutido na secção 5.2.

Os três modelos são treinados, validados e persistidos em ficheiros pickle no MinIO, sendo posteriormente carregados para geração das previsões e classificações que alimentam os *dashboards* do Power BI através das tabelas *t_previsoes* e *t_churn* no PostgreSQL.

5.2 Seleção e preparação dos dados.

Os dados utilizados nos modelos de análise de tendências são provenientes de duas tabelas da camada *Gold* do Data Lakehouse, nomeadamente o *serving_vendas* e o *serving_clima*, ambas materializadas em formato Delta no MinIO e resultantes do processo de integração descrito no capítulo 3. Não foi necessário desenvolver um processo de preparação de dados adicional de raiz, uma vez que a limpeza, normalização e enriquecimento dos dados já foram realizados nas camadas *Silver* e *Gold* do pipeline. A preparação descrita nesta secção refere-se exclusivamente às transformações aplicadas sobre estas tabelas para adequar os dados ao formato exigido pelos algoritmos de machine learning utilizados.

Seleção das Fontes

Para os modelos de previsão de procura, o Modelo 1A utiliza exclusivamente o *serving_vendas*, que contém as colunas de data, mês, estação do ano, região, produto, categoria, cliente, quantidade, preço total e preço unitário. O Modelo 1B utiliza o *serving_clima*, que estende o *serving_vendas* com as colunas de temperatura máxima diária e precipitação diária provenientes da integração com a API Open-Meteo. Para o modelo de churn, a fonte utilizada é igualmente o *serving_vendas*, a partir do qual são calculadas as features comportamentais por cliente.

Agregação Temporal

O *serving_vendas* contém múltiplos registos diários para a mesma combinação de produto e região, correspondendo a transações de clientes distintos. Para os modelos de procura, os dados

foram agregados ao nível mensal por combinação de ano, mês, estação do ano, região, produto e categoria. Esta decisão justifica-se por dois motivos. Em primeiro lugar, a granularidade diária introduz elevada variabilidade aleatória que dificulta a aprendizagem de padrões estáveis pelo modelo. Em segundo lugar, a agregação mensal é mais alinhada com os ciclos de planeamento de inventário da distribuidora, que opera em horizontes de semanas a meses e não de dias. No caso do Modelo 1B, a temperatura máxima é agregada como média mensal e a precipitação como soma acumulada mensal, dado que a precipitação acumulada é mais informativa do que a média diária para caracterizar o clima de um período.

Codificação de Variáveis Categóricas

As variáveis categóricas presentes nos dados, nomeadamente a estação do ano, a região, o produto e a categoria, não podem ser utilizadas diretamente pelos algoritmos de *machine learning* por serem texto. Cada uma destas variáveis foi codificada numericamente através de *LabelEncoder*, que atribui um inteiro único a cada valor distinto. Os *encoders* são treinados durante a fase de treino e persistidos no MinIO juntamente com os modelos, sendo carregados pelo *script* de previsão para garantir que a codificação aplicada aos dados futuros é consistente com a utilizada no treino.

Preparação das Features de Churn

Para o modelo de churn, a preparação dos dados envolveu a construção de *features* comportamentais por cliente a partir do histórico de transações. Foram calculadas sete *features*: o total de compras realizadas, o *ticket* médio, o valor total gasto pelo cliente ao longo do histórico, o número de categorias distintas de produtos adquiridos, o número de compras nos últimos três meses, o número de compras entre os três e os seis meses anteriores, e a tendência calculada como a diferença entre as compras recentes e as compras do período intermédio. Esta última *feature* é particularmente relevante porque captura de forma indireta a recência do cliente sem introduzir *data leakage*: um valor negativo indica que o cliente está a comprar menos recentemente do que no período anterior, o que constitui um sinal de risco de abandono. O *target* binário do modelo foi definido com base no número de dias desde a última compra de cada cliente, sendo classificado como em churn todo o cliente com mais de 120 dias sem registos de compra. A variável de dias desde a última compra é utilizada exclusivamente para definir o *target* e não é incluída como *feature* de *input* do modelo, precisamente para evitar *data leakage*, situação em que a resposta estaria diretamente contida nos dados de entrada.

5.3 Identificação e fundamentação da técnica de análise.

Seleção do Algoritmo

O algoritmo selecionado para os três modelos desenvolvidos foi o *Random Forest*, implementado através da biblioteca *scikit-learn*. Para os modelos de previsão de procura foi utilizado o *Random Forest Regressor* e para o modelo de churn foi utilizado o *Random Forest Classifier*. A escolha deste algoritmo foi fundamentada num conjunto de características que o tornam particularmente adequado ao problema e aos dados disponíveis.

Fundamentação da Escolha

O *Random Forest* é um algoritmo de ensemble que constrói múltiplas árvores de decisão independentes sobre subamostras aleatórias dos dados de treino e agrega os seus resultados, calculando a média das previsões no caso da regressão e a maioria de votos no caso da

classificação. Esta abordagem confere ao algoritmo um conjunto de propriedades relevantes para o presente problema.

Em primeiro lugar, o *Random Forest* é robusto à presença simultânea de variáveis de natureza distinta, nomeadamente variáveis numéricas contínuas como o preço unitário, a temperatura e a precipitação, variáveis numéricas discretas como o ano e o mês, e variáveis categóricas codificadas como a região, o produto e a estação do ano. Esta heterogeneidade de tipos de dados está presente em ambas as fontes utilizadas.

Em segundo lugar, o algoritmo não requer normalização ou estandardização das variáveis, o que simplifica a preparação dos dados e elimina o risco de introduzir transformações que distorçam as relações entre as *features* e o *target*.

Em terceiro lugar, o *Random Forest* fornece nativamente um indicador de importância de cada feature para a previsão, o que permite analisar o contributo relativo de cada variável e validar se o modelo está a aprender relações com significado de negócio ou padrões espúrios nos dados.

Otimização de Hiperparâmetros

Os três modelos foram submetidos a um processo de otimização de hiperparâmetros através do algoritmo *RandomizedSearchCV* com 50 iterações e validação cruzada a 5-fold. O espaço de pesquisa definido incluiu o número de estimadores, a profundidade máxima das árvores, o número mínimo de amostras por folha e o número de features consideradas em cada *split*. Para os modelos de regressão, a métrica de otimização foi o MAE negativo, e para o modelo de classificação foi o ROC-AUC. A utilização do *RandomizedSearchCV* em detrimento do *GridSearchCV* justifica-se pela maior eficiência computacional, dado que pesquisa aleatoriamente 50 combinações do espaço de hiperparâmetros em vez de testar exaustivamente todas as combinações possíveis, mantendo uma cobertura suficiente do espaço de pesquisa para identificar configurações de desempenho superior.

5.4 Construção do modelo de análise.

Visão Geral do Processo

A construção dos modelos de análise foi implementada no *script* `ml_train.py`, que executa sequencialmente o treino, a otimização e a validação dos três modelos, guardando todos os artefactos resultantes no MinIO para utilização posterior pelo *script* `ml_predict.py`.

Modelo 1A: Previsão de Procura sem Variáveis Climáticas

O Modelo 1A foi construído a partir dos dados do `selling_vendas` agregados ao nível mensal por combinação de ano, mês, estação do ano, região, produto e categoria. Após a codificação das variáveis categóricas através de *LabelEncoder*, o conjunto de features utilizado foi composto por sete variáveis: ano, mês, estação codificada, região codificada, produto codificado, categoria codificada e preço unitário. A variável *target* é a quantidade total vendida por combinação (mês * produto * região).

Os dados foram ordenados cronologicamente por ano e mês antes da divisão, sendo os primeiros 80% do histórico, correspondentes ao período de Janeiro de 2021 a Abril de 2025, utilizados para treino, e os restantes 20% mais recentes utilizados para teste. Esta divisão temporal simula o

cenário real de utilização do modelo, onde o sistema aprende com o passado e é avaliado na sua capacidade de prever períodos futuros. O processo de otimização de hiperparâmetros foi conduzido através do *RandomizedSearchCV* com 50 iterações e validação cruzada *TimeSeriesSplit* a 5 folds aplicada ao conjunto de treino, garantindo que em cada *fold* o conjunto de validação é sempre temporalmente posterior ao conjunto de treino. Os melhores hiperparâmetros encontrados foram 100 estimadores, profundidade máxima de 10, número mínimo de amostras por folha de 8 e seleção de *features* por raiz quadrada.

Modelo 1B: Previsão de Procura com Variáveis Climáticas

O Modelo 1B seguiu o mesmo processo de construção do Modelo 1A, com a diferença de que os dados de base foram o *serving_clima* e o conjunto de *features* foi estendido com duas variáveis climáticas adicionais: a temperatura máxima média mensal e a precipitação acumulada mensal. O espaço de pesquisa de hiperparâmetros foi idêntico ao do Modelo 1A para garantir comparabilidade. A divisão temporal seguiu o mesmo critério, com o corte em Abril de 2025. Os melhores hiperparâmetros encontrados foram 400 estimadores, profundidade máxima de 8, número mínimo de amostras por folha de 8 e seleção de *features* por logaritmo base 2.

Após o treino e avaliação de ambos os modelos, foi realizada uma comparação direta com base no MAE de cross-validation. O Modelo 1B obteve um MAE de *cross-validation* de 36.67 unidades face a 37.36 unidades do Modelo 1A, sendo automaticamente selecionado como o melhor modelo de procura. Esta decisão é persistida no ficheiro *metricas_treino.json* no MinIO, sendo lida pelo *script ml_predict.py* para determinar qual o modelo a carregar para geração das previsões.

Modelo 2: Classificação de Churn

O modelo de churn foi construído a partir das *features* comportamentais calculadas por cliente sobre o *serving_vendas*, conforme descrito na secção 5.2. O conjunto de *features* utilizado foi composto por sete variáveis: total de compras, ticket médio, valor total gasto, número de categorias distintas adquiridas, compras nos últimos três meses, compras entre os três e seis meses anteriores e tendência de compra. O *target* binário foi definido como 1 para clientes com mais de 120 dias sem compras e 0 para os restantes.

A divisão treino e teste seguiu a proporção de 80% e 20%, com estratificação pela variável *target* através do parâmetro *stratify*. Esta estratificação garante que a proporção de clientes em churn é igual nos dois conjuntos, evitando avaliações enganosas resultantes de um desequilíbrio accidental entre as classes. O classificador foi configurado com *class_weight* igual a *balanced*, que ajusta automaticamente os pesos das classes inversamente proporcionais à sua frequência, corrigindo o desequilíbrio existente entre os 89.7% de clientes em churn e os 10.3% de clientes ativos. O processo de otimização utilizou o ROC-AUC como métrica, sendo mais adequado do que a *accuracy* para problemas com classes desequilibradas. Os melhores hiperparâmetros encontrados foram 100 estimadores, profundidade máxima sem limite, número mínimo de amostras por folha de 2 e seleção de *features* por raiz quadrada.

Persistência dos Artefactos

No final do processo de treino, todos os artefactos necessários para a fase de previsão são serializados em formato *pickle* e guardados no MinIO na pasta *gold/ml_models/*. Os artefactos guardados incluem os três modelos treinados, os encoders de cada modelo de procura com as

respetivas listas de *features*, o dicionário de *features* do modelo de churn e o ficheiro *metricas_treino.json* com todas as métricas de avaliação e a identificação do melhor modelo de procura.

5.5 Validação do desempenho do modelo.

A validação do desempenho dos modelos desenvolvidos foi realizada com recurso a técnicas distintas consoante o tipo de modelo, dado que os modelos de regressão e o modelo de classificação requerem métricas de avaliação diferentes.

Modelos de Previsão de Procura (1A e 1B)

Para os modelos de regressão, a validação foi realizada com base em três métricas complementares calculadas sobre o conjunto de teste temporal, correspondente aos 20% de dados mais recentes do histórico que o modelo nunca viu durante o treino.

O MAE de 36.36 unidades no Modelo 1A e de 35.49 unidades no Modelo 1B representa o erro médio por previsão mensal de uma combinação produto-região. O RMSE de 48.07 e 46.79 unidades respectivamente é sistematicamente superior ao MAE, o que indica a presença de alguns erros de maior magnitude, sendo esta diferença esperada e não indicativa de anomalia. O R^2 de 0.099 no Modelo 1A e 0.146 no Modelo 1B indica que os modelos explicam respetivamente 9.9% e 14.6% da variância total das quantidades vendidas.

A estabilidade dos modelos foi avaliada através do *TimeSeriesSplit* com 5 *folds*, que treina e valida o modelo em cinco janelas temporais consecutivas distintas, garantindo que em cada *fold* o conjunto de validação é sempre posterior ao conjunto de treino. O MAE médio de *cross-validation* foi de 37.36 unidades para o Modelo 1A e 36.67 unidades para o Modelo 1B. A proximidade entre os valores de MAE de teste e de *cross-validation*, com uma diferença inferior a 3% em ambos os modelos, confirma que os modelos generalizam de forma consistente e não estão sobreajustados ao conjunto de treino.

Modelo de Classificação de Churn

Para o modelo de classificação, a validação foi realizada com base em métricas adequadas a problemas com classes desequilibradas. O ROC-AUC de 0.9916, num intervalo onde 0.5 corresponde a classificação aleatória e 1.0 a classificação perfeita, indica uma capacidade discriminativa muito elevada. A precisão de 0.98 e o recall de 0.97 para a classe Churned, com um F1-score de 0.98, confirmam o desempenho equilibrado do modelo na identificação dos casos positivos. Para a classe Ativo, a precisão de 0.78 e o recall de 0.87 são naturalmente inferiores dado o desequilíbrio entre as duas classes, sendo considerados aceitáveis no contexto do problema.

5.6 Avaliação dos Resultados

Modelos de Previsão de Procura

Os valores de R^2 baixos obtidos pelos modelos de procura não refletem uma inadequação do algoritmo ou da metodologia, mas sim uma limitação inerente aos dados sintéticos utilizados. Os dados de vendas foram gerados artificialmente, o que implica que as relações entre temperatura,

precipitação e volume de vendas foram introduzidas com ruído aleatório que dilui o sinal real. Num contexto de dados reais, os valores de R^2 seriam em princípio significativamente superiores.

O resultado mais relevante desta análise é a confirmação consistente de que o Modelo 1B supera o Modelo 1A em todas as métricas avaliadas, com uma melhoria de 1.8% no MAE de *cross-validation*. Este resultado confirma a hipótese central da Área 4 dos requisitos, demonstrando que a incorporação de variáveis climáticas melhora a capacidade preditiva do modelo mesmo em dados sintéticos. Em dados reais, onde estas relações são genuínas, o contributo do clima seria expectavelmente mais expressivo.

A análise da importância das features do Modelo 1B reforça esta conclusão: as duas variáveis climáticas representam em conjunto 50% da importância total do modelo, com a precipitação acumulada mensal a liderar com 37.6%. Este resultado tem significado de negócio directo, indicando que o volume de precipitação num determinado mês é o factor mais determinante para a previsão da procura, acima do próprio produto ou da região.

Em termos práticos, as previsões para os doze meses seguintes escritas na tabela `t_previsoes` do PostgreSQL incluem um intervalo de confiança de 80%, definido pelos percentis 10 e 90 das previsões individuais de cada árvore. Este intervalo permite aos decisores distinguir entre cenários pessimistas e optimistas de procura, tornando as previsões acionáveis para o planeamento de *stocks* mesmo na presença de incerteza.

Modelo de Classificação de Churn

O modelo de churn produz resultados genuinamente sólidos e directamente acionáveis. A taxa de 89.7% de clientes em risco de churn identificada reflete a estrutura dos dados sintéticos e não seria representativa de um contexto real, onde esta taxa seria significativamente inferior. Ainda assim, o modelo demonstra que a metodologia de deteção baseada em *features* de recência comportamental é eficaz, com resultados que seriam directamente aplicáveis a dados reais.

Os resultados são escritos na tabela `t_churn` com a probabilidade de churn e o nível de risco categorizado em Baixo(Abaixo de 0.30), Médio(entre 0.30 e 0.59) e Alto(igual ou acima de 0.60) para cada cliente, suportando directamente as decisões de gestão de clientes identificadas nos requisitos da Área 4.

6. Conclusões e Trabalho Futuro

6.1 Conclusões

O trabalho desenvolvido resultou na conceção e implementação de um sistema de análise de dados de grande escala para suporte à decisão no contexto da distribuição especializada de bebidas, materializado na empresa fictícia BKLP Supply & Distribution. O sistema integra dados de três fontes heterogéneas, processa-os numa arquitectura Data Lakehouse organizada em camadas *Bronze*, *Silver* e *Gold*, e disponibiliza os resultados através de dashboards analíticos em Power BI e modelos preditivos de machine learning ligados ao PostgreSQL.

Do ponto de vista técnico, os principais aspetos positivos identificados são os seguintes. A arquitectura *Medallion* implementada com PySpark, Delta Lake e MinIO demonstrou ser robusta e adequada ao processamento de dados heterogéneos em ambiente de simulação *Big Data*, com mecanismos de qualidade, tolerância a falhas e idempotência implementados em cada camada.

O mecanismo de Change Data Capture baseado em *timestamps* e o sistema de *checkpointing* granular com várias fases garantem que o pipeline pode ser retomado em caso de falha sem reprocessar o histórico completo, o que é uma propriedade fundamental em sistemas de produção. A integração de três fontes de dados de natureza distinta, nomeadamente dados transacionais e dados meteorológicos semiestruturados e dados de redes sociais não estruturados com análise de sentimento NLP, demonstra a capacidade da arquitetura de acolher a heterogeneidade característica de ambientes de *Big Data* real.

Relativamente aos modelos de *machine learning*, a comparação sistemática entre o Modelo 1A e o Modelo 1B confirmou que a incorporação de variáveis climáticas melhora a capacidade preditiva do modelo de procura, com uma redução de 1.8% no MAE de *cross-validation*. O modelo de churn demonstrou resultados genuinamente sólidos com um ROC-AUC de 0.9916, validando a abordagem de engenharia de *features* baseada em recência comportamental sem *data leakage*.

Os principais aspectos negativos identificados prendem-se essencialmente com as limitações impostas pela natureza sintética dos dados. Os modelos de procura obtiveram valores de R^2 baixos, entre 0.099 e 0.146, reflexo direto da ausência de correlações genuínas nos dados gerados artificialmente. A taxa de churn de 89.7% é irrealisticamente elevada para um contexto real e resulta da estrutura temporal dos dados sintéticos. Estas limitações não invalidam a metodologia desenvolvida mas condicionam a interpretação dos resultados quantitativos obtidos.

6.2 Trabalho Futuro

No que respeita aos dados, a principal evolução identificada consiste na substituição dos dados sintéticos por dados reais de um retalhista de bebidas. Esta substituição permitiria validar a metodologia desenvolvida em condições reais, onde as correlações entre variáveis climáticas, sentimento social e volume de vendas são genuínas e não introduzidas artificialmente, produzindo métricas de desempenho dos modelos mais representativas e defensáveis. Complementarmente, a integração de fontes de dados adicionais, como dados de pesquisa online por produto ou dados de inventário em tempo real, enriqueceria o sistema com sinais de procura complementares aos atualmente disponíveis, permitindo identificar tendências emergentes antes de se refletirem nos dados transacionais.

No que respeita à arquitetura, o sistema foi desenvolvido e validado num ambiente local de simulação Big Data. A evolução natural seria a expansão para um ambiente verdadeiramente distribuído com um cluster Spark multi-nó com múltiplas máquinas, que permitiria processar volumes de dados de escala real. Para além disso

No que respeita ao modelo dimensional, a dimensão cliente foi implementada com SCD Tipo 2, permitindo rastrear historicamente as alterações ao tipo de cliente ao longo do tempo. Contudo, os requisitos de análise definidos no âmbito deste trabalho não exploram esta capacidade de forma aprofundada. Uma evolução natural seria a definição de requisitos de negócio adicionais que tirassem partido do histórico de variação do tipo de cliente, como por exemplo a análise da taxa de conversão de clientes B2C para B2B ao longo do tempo, a identificação de padrões sazonais nessas transições, ou a correlação entre a mudança de tipo de cliente e variações no volume e valor das compras. Esta análise poderia enriquecer significativamente o sistema de suporte à decisão, fornecendo à gestão comercial da BKLP informação quantitativa sobre a evolução do perfil da sua base de clientes.

7. Bibliografia

Referências Académicas:

Golfarelli, M., Maio, D., & Rizzi, S. (1998). The dimensional fact model: A conceptual model for data warehouses. *International Journal of Cooperative Information Systems*, 7(2-3), 215-247.

Oliveira, B., Oliveira, O., & Belo, O. (s.d.). Using BPMN for ETL conceptual modelling: A case study. CIICESI, School of Management and Technology, Porto Polytechnic; ALGORITMI R&D Centre, University of Minho.

White, S. A. (2006). *Introduction to BPMN*. IBM.

Belo, O. (2015). *Modelação dimensional de dados* (Notas de Leitura em Business Intelligence, n.º 03). Departamento de Informática, Escola de Engenharia, Universidade do Minho.

Belo, O. (2025). *Sistemas de dados de grande dimensão - Big data* [Notas de leitura em Business Intelligence]. Departamento de Informática, Escola de Engenharia, Universidade do Minho.

Belo, O. (2025). *Pipelining de dados* [Notas de leitura em Business Intelligence]. Departamento de Informática, Escola de Engenharia, Universidade do Minho.

Belo, O. (2026). *Analytical sandboxes* [Notas de leitura em Business Intelligence]. Departamento de Informática, Escola de Engenharia, Universidade do Minho.

Belo, O. (2026). *Integração de dados* [Notas de leitura em Business Intelligence]. Departamento de Informática, Escola de Engenharia, Universidade do Minho.

Belo, O. (2026). *Lakehouses* [Notas de leitura em Business Intelligence]. Departamento de Informática, Escola de Engenharia, Universidade do Minho.

Ferramentas e Tecnologias:

Apache Software Foundation. (2024). *Apache Spark documentation*. <https://spark.apache.org/docs/latest/>

Databricks. (2024). *Delta Lake documentation*. <https://docs.delta.io/latest/index.html>

Prefect Technologies. (2024). *Prefect documentation*. <https://docs.prefect.io/>

MinIO. (2024). *MinIO documentation*. <https://min.io/docs/minio/linux/index.html>

The PostgreSQL Global Development Group. (2024). *PostgreSQL documentation*. <https://www.postgresql.org/docs/>

Microsoft. (2024). *Power BI documentation*. <https://learn.microsoft.com/en-us/power-bi/>

YData. (2024). *YData Profiling documentation*. <https://docs.profiling.ydata.ai/>

Open-Meteo. (2024). *Open-Meteo API documentation*. <https://open-meteo.com/en/docs>

Bizagi. (2024). *Bizagi Modeler documentation*. <https://www.bizagi.com/en/platform/modeler>

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <https://jmlr.org/papers/v12/pedregosa11a.html>

SQLAlchemy authors. (2024). *SQLAlchemy documentation*. <https://docs.sqlalchemy.org/>

Lista de Siglas e Acrônimos

BD - Base de Dados
DW - *Data Warehouse*
B2B - *Business-to-Business*
B2C - *Business-to-Consumer*
API - *Application Programming Interface*
CSV - *Comma-Separated Values*
JSON - *JavaScript Object Notation*
TXT- texto
NLP - *Natural Language Processing*
CDC - *Change Data Capture*
MAPE - *Mean Absolute Percentage Error*
RMSE - *Root Mean Square Error*
BPMN - *Business Process Model and Notation*
SCD - *Slowly Changing Dimension*
JDBC - *Java Database Connectivity*
GPU - *Graphics Processing Unit*
AWS - *Amazon Web Services*
S3 - *Simple Storage Service*
S3A - *protocolo de acesso S3 da Amazon*
SQL - *Structured Query Language*
ML - *Machine learning*

Anexo 1 - Profiling da fonte “vendas”

Text

ord2212 ord2249 ord2240 ord2253 ord2238 ord2244 ord2218 ord2242 ord2241 ord2243

[More details](#)Customer_ID


Text

[illegible][More details](#)71

Customer_Type

Categorical

Distinct	2
Distinct (%)	< 0.1%
Missing	0
Missing (%)	0.0%
Memory size	1.7 MiB



More details

OverviewCategoriesWordsCharacters

Length

Max length	3
Median length	3
Mean length	3
Min length	3

Characters and Unicode

Total characters	100659
Distinct characters	3
Distinct categories	1 ?
Distinct scripts	1 ?
Distinct blocks	1 ?

Unique

Unique	0 ?
Unique (%)	0.0%

Sample


1st row	B2C
2nd row	B2C
3rd row	B2C
4th row	B2C
5th row	B2C

Product

Categorical

High correlation

Distinct	47
Distinct (%)	0.1%
Missing	0
Missing (%)	0.0%
Memory size	2.0 MiB



More details

OverviewCategoriesWordsCharacters

Length

Max length	19
Median length	15
Mean length	10.631866
Min length	5

Characters and Unicode

Total characters	356731
Distinct characters	50
Distinct categories	1 ?
Distinct scripts	1 ?
Distinct blocks	1 ?

Unique

Unique	0 ?
Unique (%)	0.0%

Sample


1st row	Sauvignon Blanc
2nd row	Rotkäppchen Sekt
3rd row	Veuve Clicquot
4th row	Coca-Cola
5th row	Merlot

Category

Categorical

High correlation

Distinct	4
Distinct (%)	< 0.1%
Missing	0
Missing (%)	0.0%
Memory size	2.0 MiB



More details

Overview Categories Words Characters

Length

Max length	19
Median length	11
Mean length	11.986052
Min length	5

Characters and Unicode

Total characters	402168
Distinct characters	23
Distinct categories	1 ?
Distinct scripts	1 ?
Distinct blocks	1 ?

Unique

Unique	0 ?
Unique (%)	0.0%

Sample


1st row	Alcoholic Beverages
2nd row	Alcoholic Beverages
3rd row	Alcoholic Beverages
4th row	Soft Drinks
5th row	Alcoholic Beverages

Unit_Price

Real number (R)

High correlation

Distinct	5241	Minimum	0.32
Distinct (%)	15.6%	Maximum	169.44
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	10.774792	Memory size	262.3 KiB



More details

Statistics Histogram Common values Extreme values

Quantile statistics

Minimum	0.32
5-th percentile	0.66
Q1	1.37
median	2.35
Q3	4.8
95-th percentile	55.718
Maximum	169.44


Descriptive statistics

Standard deviation	23.60493
Coefficient of variation (CV)	2.1907551
Kurtosis	15.216212
Mean	10.774792
Median Absolute Deviation (MAD)	1.24
Skewness	3.7260794
Sum	361526.59

Discount

Categorical

Distinct	4
Distinct (%)	< 0.1%
Missing	0
Missing (%)	0.0%
Memory size	1.7 MiB



More details

Overview	Categories	Words	Characters
----------	------------	-------	------------


Length		Characters and Unicode		Unique		Sample	
Max length	4	Total characters	114912	Unique	0	1st row	0.0
Median length	3	Distinct characters	4	Unique (%)	0.0%	2nd row	0.05
Mean length	3.4247906	Distinct categories	1			3rd row	0.0
Min length	3	Distinct scripts	1			4th row	0.0
		Distinct blocks	1			5th row	0.1

Quantity

Real number (R)

High correlation

Distinct	100	Minimum	1
Distinct (%)	0.3%	Maximum	100
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	50.491789	Memory size	262.3 KiB



More details

Statistics	Histogram	Common values	Extreme values
------------	-----------	---------------	----------------


Quantile statistics		Descriptive statistics	
Minimum	1	Standard deviation	28.833871
5-th percentile	6	Coefficient of variation (CV)	0.57106059
Q1	26	Kurtosis	-1.1994722
median	50	Mean	50.491789
Q3	76	Median Absolute Deviation (MAD)	25
95-th percentile	95	Skewness	0.004721031
Maximum	100	Sum	1694151

Total_Price

Real number (R)

High correlation

Distinct	20006	Minimum	0.35
Distinct (%)	59.6%	Maximum	16175.04
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	516.23932	Memory size	262.3 KiB



More details

Statistics Histogram Common values Extreme values

Quantile statistics

Minimum	0.35
5-th percentile	9.88
Q1	45.54
median	106.02
Q3	265.5
95-th percentile	2738.996
Maximum	16175.04


Descriptive statistics

Standard deviation	1338.1707
Coefficient of variation (CV)	2.5921518
Kurtosis	32.173745
Mean	516.23932
Median Absolute Deviation (MAD)	75.86
Skewness	5.1088039
Sum	17321378

Region

Categorical

Distinct	16
Distinct (%)	< 0.1%
Missing	0
Missing (%)	0.0%
Memory size	2.1 MiB



More details

Overview Categories Words Characters

Length

Max length	22
Median length	17
Mean length	11.422704
Min length	6

Characters and Unicode

Total characters	383266
Distinct characters	35
Distinct categories	1 ?
Distinct scripts	1 ?
Distinct blocks	1 ?

Unique

Unique	0 ?
Unique (%)	0.0%


Sample

1st row	Saarland
2nd row	Saarland
3rd row	Mecklenburg-Vorpommern
4th row	Mecklenburg-Vorpommern
5th row	Mecklenburg-Vorpommern

Order_Date


Date

Distinct	1926	Minimum	2021-01-04 00:00:00
Distinct (%)	5.7%	Maximum	2026-04-30 00:00:00
Missing	0	Invalid dates	0
Missing (%)	0.0%	Invalid dates (%)	0.0%
Memory size	262.3 KiB		



More details

Histogram



Histogram with fixed size bins (bins=50)

Anexo 2 - Profiling da fonte “meteorologia”

Regiao

Categorical

Uniform

Distinct	16
Distinct (%)	0.1%
Missing	0
Missing (%)	0.0%
Memory size	1.9 MiB

Baden-Württ...

Bayern

Berlin

Brandenburg

Bremen

Other values ...

1943

1943

1943

1943

1943

21373

More details

OverviewCategoriesWordsCharacters

Length

Characters and Unicode

Unique

Sample

Max length	22	Total characters	357512	Unique	0	1st row	Baden-Württemberg
Median length	16	Distinct characters	35	Unique (%)	0.0%	2nd row	Baden-Württemberg
Mean length	11.5	Distinct categories	1			3rd row	Baden-Württemberg
Min length	6	Distinct scripts	1			4th row	Baden-Württemberg
		Distinct blocks	1			5th row	Baden-Württemberg


Data

Date

Distinct	1943	Minimum	2021-01-04 00:00:00
Distinct (%)	6.2%	Maximum	2026-04-30 00:00:00
Missing	0	Invalid dates	0
Missing (%)	0.0%	Invalid dates (%)	0.0%
Memory size	243.0 KiB		

More details


Histogram



Temp_Max_C

Real number (R)

Distinct	445	Minimum	-10.5
Distinct (%)	1.4%	Maximum	38.8
Missing	0	Zeros	29
Missing (%)	0.0%	Zeros (%)	0.1%
Infinite	0	Negative	827
Infinite (%)	0.0%	Negative (%)	2.7%
Mean	14.084911	Memory size	243.0 KiB



[More details](#)

[Statistics](#) [Histogram](#) [Common values](#) [Extreme values](#)

Quantile statistics

Minimum	-10.5
5-th percentile	1.3
Q1	7.8
median	13.9
Q3	20.4
95-th percentile	27.2
Maximum	38.8
Range	49.3

Descriptive statistics


Standard deviation	8.0770694
Coefficient of variation (CV)	0.57345549
Kurtosis	-0.74224753
Mean	14.084911
Median Absolute Deviation (MAD)	6.3
Skewness	0.058132839
Sum	437871.7
Variance	65.239049

Precipitacao_mm

Real number (R)

Zeros

Distinct	328	Minimum	0
Distinct (%)	1.1%	Maximum	59.4
Missing	0	Zeros	11952
Missing (%)	0.0%	Zeros (%)	38.4%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	2.2139539	Memory size	243.0 KiB



[More details](#)

[Statistics](#) [Histogram](#) [Common values](#) [Extreme values](#)

Quantile statistics

Minimum	0
5-th percentile	0
Q1	0
median	0.4
Q3	2.7
95-th percentile	10.465
Maximum	59.4

Descriptive statistics

Standard deviation	4.0869486
Coefficient of variation (CV)	1.8459953
Kurtosis	17.455218
Mean	2.2139539
Median Absolute Deviation (MAD)	0.4
Skewness	3.4017522
Sum	68827.4

Anexo 3 - Sistema de armazenamento minIO

raw

Created on: Thu, Apr 18 2028 18:00:40 (GMT+1) | Access: PRIVATE | 5.9 MB - 22 Objects

RewindRefreshUpload

<raw

Create new path

☐	Name	Last Modified	Size
☐	cdc		-
☐	meteo		-
☐	rejected		-
☐	social		-
☐	vendas		-

silver

Created on: Thu, Apr 18 2028 18:09:49 (GMT+1) | Access: PRIVATE | 2.7 MB - 24 Objects

RewindRefreshUpload

<silver

Create new path

☐	Name	Last Modified	Size
☐	meteo		-
☐	social		-
☐	vendas		-

gold

Created on: Thu, Apr 30 2028 21:28:37 (GMT+1) | Access: PRIVATE | 63.5 KiB - 42 Objects

RewindRefreshUpload

<gold

Create new path

☐	Name	Last Modified	Size
☐	dim_calendario		-
☐	dim_cliente		-
☐	dim_produto		-
☐	dim_regiao		-
☐	servico_clima		-
☐	servico_vendas		-
☐	tf_meteorologia		-
☐	tf_tweets		-
☐	tf_vendas		-