



Análise do mercado cinematográfico global: produção, sucesso e impacto do *streaming*

| **Unidade Curricular:** Engenharia de Dados e Suporte à Tomada de Decisão

| **Curso:** Licenciatura em Ciência de Dados

| **Ano Letivo:** 2025/2026

Grupo 4

Alexandre Almeida, A106862

Dean Kuijf, A106832

Filipa Barroso Teixeira, A106864

Lorenzo Perry, A106865

Conteúdo

Sumário	3
Âmbito de Negócio	4
Identificação e motivação do tema	4
Objetivos do projeto	4
Questões Analíticas	6
Key Performance Indicators (KPI)	7
Análise da Qualidade dos Dados	8
Arquitetura Data Lakehouse	10
Camadas da Arquitetura	10
Infraestrutura Tecnológica e Modelo de Processamento	11
Fase <i>Bronze</i>	12
Fase <i>Silver</i>	12
Fase <i>Gold</i>	14
Dashboards	18
Questão Analítica 1	18
Questão Analítica 2	19
Questão Analítica 3	20
Questão Analítica 4	21
Conclusão	22
Anexo 1 – Relatório de <i>Data Profiling</i>	23
“The Oscar Award”	23
“Disney+ TV Shows And Movies”	25
“Netflix TV Shows and Movies”	29
“Amazon Prime TV Shows and Movies”	31
“Actors_Films – IMDB”	35
“boxoffice_data_2024”	38
“Rotten Tomatoes Movie Rating”	39
“TMDB API – Filmes”	43
“TMDB API – Séries”	44

Sumário

Este relatório analisa o mercado cinematográfico global, com foco na evolução da produção de filmes, identificação de fatores críticos de sucesso e impacto das plataformas de *streaming* no desempenho comercial e cultural.

O objetivo é disponibilizar insights acionáveis para produtores, investidores e plataformas de *streaming*, através da criação de mecanismos analíticos, indicadores de performance (KPIs) e *dashboards* interativos baseados num ecossistema de *Big Data* e *Data Lakehouse*.

Âmbito de Negócio

Identificação e motivação do tema

O mercado cinematográfico caracteriza-se por elevada competitividade, forte evolução tecnológica e crescente influência das plataformas de *streaming*. A digitalização dos conteúdos e a diversificação dos canais de distribuição tornaram crítica a utilização de dados para suportar decisões estratégicas relacionadas com investimento, *marketing*, *casting* e planeamento de estreias.

Neste contexto, o presente projeto surge com o objetivo de analisar dados históricos e atuais da indústria cinematográfica, permitindo identificar padrões, tendências e fatores de sucesso que apoiem a tomada de decisão baseada em dados.

Descrição do projeto

Missão:

Desenvolver um sistema analítico de suporte à tomada de decisão que permita avaliar o desempenho financeiro e qualitativo da indústria cinematográfica, bem como o impacto das plataformas de *streaming* nas dinâmicas de produção, distribuição e consumo.

Ambiente:

O projeto será implementado num ecossistema de *Big Data*, justificado pela dimensão, diversidade e complexidade dos dados analisados. Estes incluem dados estruturados (ficheiros CSV) e semi-estruturados (dados provenientes de APIs em formato JSON), abrangendo múltiplas fontes da indústria cinematográfica.

A solução baseia-se numa arquitetura *Data Lakehouse*, combinando a flexibilidade de armazenamento do *Data Lake* com as capacidades analíticas do *Data Warehouse*, permitindo análises descritivas e comparativas de forma escalável e eficiente.

Principais Processos de Negócio:

Foram identificados os seguintes processos de negócio com impacto direto na tomada de decisão:

1. Performance Financeira (Cinema): análise de orçamentos, receitas de bilheteira e rentabilidade, suportando decisões de investimento e produção.
2. Avaliação e Qualidade: monitorização da receção crítica e da popularidade junto do público, com base em plataformas como “Rotten Tomatoes”, “IMDb” e “TMDB”.
3. Inventário e Disponibilidade (*Streaming*): análise do catálogo disponível nas plataformas de *streaming*, incluindo características dos conteúdos e padrões de distribuição.
4. Reconhecimento (Prémios): registo e análise de nomeações e prémios atribuídos em cerimónias relevantes, como os Óscares.

Objetivos do projeto

O projeto tem como objetivo geral o desenvolvimento de um sistema de *Big Data* orientado para a análise da indústria cinematográfica e do impacto das plataformas de *streaming*.

Como objetivos específicos, pretende-se:

- Desenvolver um sistema de *Big Data* com foco na produção cinematográfica, desempenho financeiro, receção do público e reconhecimento por prémios;

- Implementar mecanismos analíticos que suportem processos de decisão nas áreas de investimento, *marketing*, *casting* e gestão de catálogo;
- Disponibilizar uma componente de visualização de dados interativa e eficiente, permitindo a análise do setor segundo múltiplas dimensões, como géneros, atores, países e plataformas.

Este projeto visa, assim, gerar *insights* relevantes sobre fatores de sucesso e tendências emergentes da indústria cinematográfica, contribuindo para uma gestão mais informada, competitiva e orientada a dados.

Questões Analíticas

As questões analíticas foram definidas com o objetivo de suportar decisões estratégicas no setor cinematográfico, respondendo às necessidades dos principais *stakeholders* ao longo da cadeia de valor. Estas questões orientam o desenho do modelo analítico, a definição das tabelas *Silver* e *Gold* e a construção dos indicadores de desempenho, garantindo alinhamento entre dados, análise e tomada de decisão.

Questão	Business Users/Stakeholders	Planeamento de execução
1. Qual a evolução da produção de filmes ao longo do tempo?	Produtoras & Investidores	Agregação temporal por ano
2. Que fatores explicam o sucesso comercial dos filmes?	Plataformas & Estratégia de catálogo	Cruzamento de receita, <i>rating</i> , prémios e <i>streaming</i>
3. Quais atores, géneros e países geram mais retorno?	RH (<i>casting</i>), <i>Marketing</i> & Internacionalização	<i>Ranking</i> de receita e prémios, mapa por país
4. Como o <i>streaming</i> alterou o sucesso comercial e cultural?	Plataformas de <i>streaming</i> , Distribuidores, Investidores	Comparação de originais VS não originais e distribuição de géneros

Tabela 1

Justificação das Questões Analíticas:

1. Permite analisar a evolução histórica da produção cinematográfica, identificar ciclos de crescimento ou retração e apoiar decisões de investimento.
2. Avalia o impacto de fatores qualitativos (*ratings* e prémios) e de distribuição (*streaming*) no desempenho financeiro, apoiando estratégias de investimento e aquisição de conteúdos.
3. Identifica talentos, géneros e mercados geográficos com maior retorno económico e reconhecimento, suportando decisões de *casting*, *marketing* e internacionalização.
4. Analisa o efeito do *streaming* na rentabilidade, diversidade e sucesso dos conteúdos, permitindo avaliar o valor estratégico de produções exclusivas.

Key Performance Indicators (KPI)

Os *Key Performance Indicators* (KPIs) constituem a base quantitativa do sistema analítico, permitindo medir o desempenho, identificar tendências e avaliar o impacto das variáveis críticas da indústria cinematográfica.

Cada KPI está diretamente associado a uma questão analítica, assegurando coerência entre os objetivos do projeto, os dados modelados e os resultados obtidos. O conjunto de indicadores abrange dimensões de produção, rentabilidade, reconhecimento crítico, impacto do *streaming* e desempenho por ator, género e país.

KPI	Cálculo	Target	Business Users/Stakeholders
1.1 N° de filmes lançados por ano	Contagem de filmes agrupados por ano	Crescimento anual positivo	Produtoras & Investidores
1.2 Receita média anual	Média da receita de filmes por ano	Aumentar ano a ano	Produtoras & Investidores
1.3 Distribuição por género	Percentagem de filmes por género	Identificar géneros emergentes	Produtoras & Investidores
2.1 Rácio entre Receita e Rating	Quociente de receita por <i>rating</i>	Maximizar (Identificar os filmes de maior eficiência para análise.)	Plataformas & Estratégia de catálogo
2.2 % de filmes disponíveis em <i>streaming</i>	(Filmes em <i>streaming</i> / Total filmes) * 100	Crescimento contínuo	Plataformas & Estratégia de catálogo
2.3 Receita média filmes premiados vs não premiados	Média de receita por grupo	Filmes premiados > não premiados	Plataformas & Estratégia de catálogo
2.4 % de prémios ganhos por género	Percentagem de prémios por género	Identificar géneros com mais retorno	Marketing & Produção
3.1 Receita média por ator	Média de receita por ator	Top 10 gera +50% da receita	RH (<i>casting</i>)
3.2 Receita média por diretor	Média de receita por diretor	Top 10 gera +50% da receita	RH (<i>casting</i>)
3.3 Receita média por país	Média de receita por país	Identificar mercados prioritários	Marketing & Internacionalização
4.1 % de filmes/series originais por plataforma	Percentagem anual de conteúdos originais	Crescimento contínuo	Plataformas de <i>streaming</i>
4.2 Receita média de filmes exclusivos vs não exclusivos	Média de receita por grupo	Exclusivos > não exclusivos	Plataformas, Distribuidores, Investidores
4.3 Distribuição de géneros por plataforma	Percentagem de géneros por plataforma	Identificar tendências de produção	Plataformas de <i>streaming</i>

Tabela 2

Análise da Qualidade dos Dados

O presente projeto integra múltiplos *datasets* provenientes de diferentes fontes, cobrindo diversas dimensões da indústria cinematográfica, nomeadamente produção, desempenho financeiro, reconhecimento por prémios, avaliações críticas e disponibilidade em plataformas de *streaming*. A heterogeneidade das fontes e formatos torna a análise da qualidade dos dados um passo fundamental para garantir consistência, fiabilidade e adequação à tomada de decisão.

Os *datasets* utilizados apresentam formatos estruturados (CSV) e semi-estruturados (JSON via API), contendo atributos temporais, financeiros, categóricos, identificadores e métricas de popularidade e avaliação. De forma geral, os dados incluem informações sobre filmes e séries, profissionais do setor (atores e realizadores), receitas de bilheteira, prémios, *ratings* e características de catálogo das plataformas de *streaming*.

A **Tabela 3** apresenta uma visão global dos *datasets* utilizados, identificando a sua origem, tipologia e dimensão. A descrição detalhada dos atributos é intencionalmente mantida a um nível genérico, uma vez que a análise exhaustiva do perfil dos dados é realizada através de uma ferramenta de *data profiling*.

<i>Dataset</i>	<i>Fonte</i>	<i>Formato</i>	<i>Nº Registos</i>	<i>Tipo de Informação</i>	<i>Quem Pertence</i>
“The Oscar Award”	<i>Kaggle</i>	CSV	~ 11 000	Prémios, categorias, vencedores	A106864
“Disney+ TV Shows and Movies”	<i>Kaggle</i>	CSV	~ 1 500	Catálogo streaming, ratings, géneros	A106864
“Netflix TV Shows and Movies”	<i>Kaggle</i>	CSV	~ 5 800	Catálogo streaming, ratings, géneros	A106865
“Amazon Prime TV Shows and Movies”	<i>Kaggle</i>	CSV	~9 800	Catálogo streaming, ratings, géneros	A10686
“IMDb Films by Actor”	<i>Kaggle</i>	CSV	~192 000	Atores, filmes, ratings, votos	A106832
“Box Office Data”	<i>Kaggle</i>	CSV	~ 8 100	Receitas de bilheteira	A106832
“Rotten Tomatoes Movie Ratings”	<i>Kaggle</i>	CSV	~ 16 600	Avaliações críticas e do público	A106862
“TMDB API Data”	TMDB API	JSON	~ 54 000	Orçamentos, receitas, elenco, popularidade	A106862

Tabela 3

A análise detalhada da qualidade dos dados foi realizada com recurso à ferramenta *YData Profiling*, permitindo identificar valores ausentes, duplicados, inconsistências de tipos de dados e padrões estatísticos relevantes. Foram igualmente analisadas distribuições, correlações entre variáveis numéricas e a dispersão de atributos categóricos.

No entanto, a validação dos dados provenientes da API do TMDB foi realizada através de operações de análise exploratória em *Apache Spark*, sendo os resultados apresentados sob a forma de outputs textuais resultantes diretamente pela *framework*.

Os resultados desta análise permitiram definir estratégias de limpeza e normalização, incluindo tratamento de valores em falta, padronização de campos textuais, conversão de tipos de dados e validação cruzada entre fontes. O relatório completo de *data profiling* encontra-se documentado no **Anexo 1 – Relatório de Data Profiling**, servindo de base técnica para a integração e transformação dos dados nas camadas *Bronze*, *Silver* e *Gold* da arquitetura *Data Lakehouse*.

Arquitetura Data Lakehouse

O projeto foi implementado segundo uma arquitetura *Data Lakehouse*, combinando a flexibilidade do paradigma *schema-on-read* do *Data Lake* com as garantias de consistência, governação e desempenho analítico típicas de um *Data Warehouse*. Esta abordagem permite lidar com dados heterogêneos e em grande volume, assegurando simultaneamente fiabilidade transacional (ACID) e suporte eficiente a análises avançadas.

A arquitetura suporta ingestão de dados em modo *batch*, bem como a possibilidade de extensão futura para *streaming*, garantindo que os dados brutos são obtidos, processados e disponibilizados de forma escalável e controlada.

A organização dos dados segue a estrutura de três camadas lógicas: *Bronze*, *Silver* e *Gold*, conforme ilustrado na **Figura 1**.




Figura 1

Camadas da Arquitetura

A camada *Bronze* armazena os dados brutos provenientes das diversas fontes externas (*datasets* de prêmios, plataformas de *streaming*, receitas, *ratings* e APIs). Nesta fase, os dados são carregados sem transformações significativas, preservando o formato original e garantindo a integridade e o histórico completo da informação. Esta camada funciona como a base imutável do sistema, permitindo reprocessamentos futuros e auditoria dos dados de origem.

A camada *Silver* é responsável pela limpeza, normalização e enriquecimento dos dados. Nesta fase são aplicadas transformações como:

- remoção de duplicados;
- tratamento de valores nulos e inconsistências;
- padronização de formatos e atributos;

- integração entre fontes distintas.

O objetivo é disponibilizar dados coerentes, integrados e semanticamente consistentes, prontos para análises mais refinadas e para a modelação dimensional da camada *Gold*.

A camada Gold contém os dados altamente refinados e orientados ao consumo analítico. Aqui são criadas tabelas agregadas, métricas-chave e estruturas otimizadas para responder diretamente às questões analíticas e KPIs definidos no projeto. Esta camada suporta *dashboards* interativos, relatórios de negócio e análises exploratórias avançadas, sendo a principal interface entre o sistema de dados e os utilizadores de negócio.

Infraestrutura Tecnológica e Modelo de Processamento

A infraestrutura tecnológica assenta num ambiente de computação distribuída em *cluster*, configurado segundo o paradigma *Master-Slave*, fundamental para garantir escalabilidade e desempenho no processamento de grandes volumes de dados.

Neste modelo:

- o nó *Master* é responsável pela orquestração das tarefas, gestão de recursos, planeamento de execução e manutenção de metadados;
- os nós *Slaves* executam o processamento distribuído, realizando as operações de transformação e armazenamento dos dados de forma paralela.

Esta arquitetura permite escalar horizontalmente o sistema, distribuindo o processamento por múltiplos nós, mantendo simultaneamente um ponto central de controlo e coordenação.

As principais tecnologias utilizadas são:

- HDFS (*Hadoop Distributed File System*): armazenamento distribuído e redundante dos dados nas camadas *Bronze*, *Silver* e *Gold*;
- PySpark: motor de processamento distribuído *in-memory*, responsável pela execução do *pipeline* ETL;
- *Hive Metastore* / *Trino*: abstração SQL e gestão de metadados sobre os dados distribuídos;
- *Tableau*: ferramenta de visualização conectada à camada *Gold* para criação de *dashboards* interativos de suporte à decisão.

Desenvolvimento *Data Lakehouse*

O desenvolvimento do *Data Lakehouse* seguiu um processo ETL (*Extract, Transform, Load*) estruturado por camadas, garantindo consistência, rastreabilidade e controlo de dependências ao longo de todo o *pipeline*. O objetivo foi transformar dados brutos provenientes de múltiplas fontes em informação estruturada, integrada e orientada à tomada de decisão.

Fase *Bronze*

O ETL começou com a recolha e carregamento de 8 ficheiros de dados distintos provenientes de diversas fontes de dados (*Kaggle* e *API*) para a camada *Bronze*, assegurando que todas as tabelas eram importadas na sua forma original e completas antes de qualquer transformação. O carregamento foi realizado em modo *batch*, respeitando as dependências entre tabelas, de modo a que os *datasets* fundamentais estivessem disponíveis antes de iniciar o processamento da camada *Silver*. Nesta fase, o foco foi manter a integridade e o histórico completo dos dados, garantindo uma base sólida para as etapas seguintes. O *pipeline* foi desenhado com dependências estritas: as tabelas *Silver* só são processadas após a validação da ingestão completa das tabelas *Bronze* correspondentes, garantindo que não há propagação de dados incompletos.

Fase *Silver*

Na camada *Silver*, os dados provenientes da camada *Bronze* seguiram um método iterativo de tratamento de dados onde cada passo originava uma nova versão do *dataset* (ex: *v1.0* a *v4.0*), garantindo rastreabilidade e a possibilidade de auditar o impacto de cada transformação.

Deste modo, as transformações específicas de cada *dataset* foram as seguintes:

- “The Oscar Award”:
 - Iteração 1 (Seleção): Foram removidas as colunas redundantes ou desnecessárias (*ceremony*, *category*, *year_ceremony*), mantendo-se a *canon_category* para garantir consistência histórica na classificação dos prémios.
 - Iteração 2 (Deduplicação): Remoção integral de linhas duplicadas.
 - Iteração 3 (Limpeza): Tratamento de valores nulos nas colunas de texto (substituídos por "Desconhecido") e aplicação de *Trim* para remover espaços em branco no início e fim dos nomes e títulos.
 - Iteração 4 (Lógica de Negócio): Realizaram-se três transformações críticas para a modelação dimensional:
 1. Conversão de Métricas: A coluna *winner* foi convertida de booleano (*True/False*) para binário (1/0) para permitir funções de agregação (somas) na camada *Gold*.
 2. Identificação de Equipas (*flag_equipa*): Antes da separação dos nomes, foi implementada uma regra lógica para identificar nomeações coletivas. Se a lista de nomes continha mais de um elemento, foi criada uma *flag* (T / F) preservando o contexto de "trabalho de equipa" que de outra forma se perderia na desnormalização.
 3. Normalização de Granularidade: A coluna *name* foi sujeita a uma operação de *Split* e *Explode*. Isto alterou a granularidade de "uma linha por nomeação" para "uma linha por indivíduo", permitindo a ligação direta à futura tabela Dimensão Pessoa sem a necessidade de criar *bridge tables* complexas para grupos.
- “Disney+”, “Netflix” e “Amazon Prime”:
 - Iteração 1 (Seleção): Foi removida apenas a coluna *id* (identificador interno da fonte), mantendo-se todas as outras colunas descritivas e métricas (como *description* e *scores*) para enriquecimento visual nos *dashboards* e redundância.
 - Iteração 2 (Deduplicação): Verificação e remoção de registos duplicados.

- Iteração 3 (Limpeza e Nulos): Preenchimento de valores nulos em colunas de texto (*description*, *age_certification*, *imdb_id*) com a label "Desconhecido". As colunas numéricas mantiveram-se como *NULL* para não enviesar médias. Foi aplicado *Trim* nas colunas de texto principais.
 - Iteração 4 (Padronização e Enriquecimento): Nesta etapa final, executou-se uma sequência lógica de transformações:
 1. Listas: Limpeza de caracteres especiais ([,]) nas colunas *genres* e *production_countries*.
 2. Idades: Mapeamento e normalização da coluna *age_certification* (ex: "TV-MA", "PG-13") para categorias de negócio uniformes ("Livre", "M/10", "M/12", "M/18")
 3. Tipos e Seasons: Normalização da coluna *type* (tradução para "filme"/"serie") e correção da coluna *seasons* (atribuição forçada de 0 temporadas sempre que o tipo é "Filme").
 4. Origem: Adição da coluna *platform* para identificar a proveniência do conteúdo no modelo unificado.
- “Box Office Data”:
 - Iteração 1 (Seleção): Foram mantidas todas as colunas originais (*Year*, *Title*, *Gross*), uma vez que cada atributo é essencial para o cálculo dos KPIs financeiros.
 - Iteração 2 (Deduplicação): Verificação de integridade para garantir a unicidade dos registos por filme e ano, evitando a duplicação de valores nas agregações.
 - Iteração 3 (Limpeza e Conversão): Tratamento crítico da coluna métrica *Gross*. Originalmente formatada como texto com símbolos monetários e pontuação (ex: "\$234,760,478"), foi submetida a uma limpeza de caracteres (\$, ,) e convertida explicitamente para o tipo numérico (*Double*) para permitir operações matemáticas.
 - Iteração 4 (Padronização e Enriquecimento): Criação da coluna auxiliar *Clean_Title*. Foi aplicado um processamento de *strings* para remover pontuação e caracteres especiais dos títulos originais, gerando uma chave de ligação robusta para facilitar futuros *joins* com *datasets* de grafia heterogênea (como os de *Streaming* ou *Óscares*).
 - “Actors & Films - IMDb”:
 - Iteração 1 (Seleção): Seleção integral dos atributos de identificação (*ActorID*, *FilmID*), descritivos (*Actor*, *Film*) e métricos (*Votes*, *Rating*), preservando a granularidade de "uma linha por ator por filme".
 - Iteração 2 (Deduplicação): Como o *dataset* original é uma matriz densa, foi necessário garantir que, ao extrair os *datasets*, cada Ator e cada Filme fossem registados apenas uma vez.
 - Iteração 3 (Limpeza e Nulos): Validação dos tipos de dados, garantindo que as colunas *Year*, *Votes* e *Rating* fossem tratadas como numéricas para a correta ordenação temporal e cálculo de médias ponderadas na camada seguinte.
 - “Rotten Tomatoes Movie Rating”:
 - Iteração 1 (Seleção e Normalização Inicial): Foram selecionadas apenas as colunas relevantes para a modelação, renomeando atributos para a nomenclatura canónica (ex.: *movie_title* → *titulo*, *rating* → *classificacao_etaria*). Procedeu-se à normalização textual, removendo caracteres inválidos (ex.: parênteses em "PG-13") e ao tratamento de valores nulos, substituindo-os por valores controlados ("Desconhecido") para garantir consistência.
 - Iteração 2 (Limpeza de Dados Numéricos): Aplicação de regras de validade de domínio à duração dos filmes, mantendo apenas valores realistas (entre 10 e 400 minutos). Esta filtragem remove *outliers* que comprometeriam as métricas de tempo médio na camada Gold.
 - Iteração 3 (Deduplicação): Remoção de duplicados exatos com base na chave lógica de negócio (*titulo*, *data_cinema*), assegurando que cada estreia é representada apenas uma vez.
 - Iteração 4 (Transformação de Géneros): A coluna de géneros foi reestruturada para eficiência analítica através de dois passos:
 1. Limpeza Semântica: Substituição do separador "&" por vírgula.

- Normalização: Aplicação de *Split* para criar um *array* normalizado, preparando os dados para o *Explode* na *Gold*.
- “API Filmes (TMDB)”
 - Iteração 1 (Seleção Dirigida): Seleção dos atributos para enriquecimento (tempo, país, estúdio, gênero) e aplicação de restrição explícita aos *providers* portugueses, garantindo alinhamento com o contexto nacional.
 - Iteração 2 (Deduplicação): Realizada com base no identificador global (*tmdb_id*), excluindo registos sem identificador válido para preservar a integridade referencial
 - Iteração 3 (Limpeza Final e Padronização):
 1. Conversão de Nulos: Valores monetários e de duração iguais a 0 foram convertidos para NULL.
 2. Preenchimento: Campos textuais críticos receberam *defaults* controlados (“Sinopse indisponível”).
 3. *Placeholders*: Normalização de URLs de posters inexistentes.
- “API Séries (TMDB)”
 - Iteração 1 (Seleção Dirigida): Seleção de colunas temporais, métricas de popularidade, equipa e *content_ratings*, restringindo novamente os *providers* ao mercado PT.
 - Iteração 2 (Deduplicação Técnica): Executada via *tmdb_id*, assegurando uma linha única por série e evitando duplicações por recolhas múltiplas da API.
 - Iteração 3 (Limpeza Final e Padronização): Aplicação de regras transversais de qualidade:
 1. Validação Numérica: Conversão de zeros para NULL em métricas estruturais.
 2. Normalização: Preenchimento de textos essenciais e padronização de URLs, preparando a tabela para análises.

No final desta fase, cada tabela *Silver* apresentava dados limpos, coerentes e prontos para integração, servindo como base sólida para a camada *Gold* e para as análises exploratórias subsequentes.

Uma mudança estrutural fundamental nesta fase foi a conversão do formato de armazenamento. Enquanto na camada *Bronze* os dados residiam em formatos de texto (CSV/JSON), na camada *Silver* todos os dados foram convertidos e gravados em formato *Delta Lake*. Esta escolha garante transações ACID, versionamento de dados e melhor performance de leitura.

Fase Gold

A camada Gold representa o culminar do processo de engenharia de dados, onde os dados limpos da camada *Silver* foram reestruturados e otimizados para consulta analítica. O desenvolvimento desta fase não foi arbitrário; partiu-se da definição dos KPIs de negócio (ex: receita por diretor, atores mais rentáveis, filmes mais premiados) para determinar quais as dimensões e as tabelas de factos que deveriam ser originadas, capazes de responder às diversas questões analíticas. Além disso, a modelação incorporou atributos adicionais (ex: *tipo_acesso*, *diferenciar ano de lançamento* e *ano em que acabou*) para suportar questões futuras, garantindo flexibilidade sem comprometer a *performance* analítica.

Como ilustrado na figura abaixo (**figura 2**), a arquitetura central apoia-se em três Dimensões Conformes (Conteúdo, Tempo, Pessoa) que atuam como a espinha dorsal do sistema, garantindo a integração transversal entre diferentes domínios.




Figura 2

- “Conteúdo” Funciona como catálogo mestre, consolidando filmes e *séries* de todas as fontes (APIs, *streaming* e prémios). É essencial para garantir ligações consistentes com todas as *fact tables*, permitindo unir e normalizar dados de forma robusta para todas as métricas, desde financeiras a *ratings* e nomeações.
- “Tempo” desempenha um papel crucial ao normalizar a análise temporal, criando uma “régua” cronológica padronizada. Esta dimensão tem uma particularidade na sua relação com a *Fact Table* “Inventario”, pois desempenha o papel de uma *Dimension Role-Played*, devido à dupla ligação de ano de lançamento e ano de término.
- “Pessoa” Centraliza todos os indivíduos (atores, realizadores, vencedores de prémios). Permite calcular métricas como receita média por ator, número de prémios por pessoa ou colaboração em múltiplos filmes.

Orbitando estas dimensões, encontram-se as Tabelas de Factos que armazenam as métricas quantitativas:

- “Financeira” regista métricas financeiras por conteúdo (orçamento, receita). O lucro é calculado como $Lucro = Receita - Orçamento$. Todas as operações de soma ou média são feitas na granularidade do conteúdo, garantindo que cada filme contribui apenas uma vez para a métrica global. Para métricas como receita por género ou país, utilizam-se *Factless Tables* auxiliares para evitar duplicação de valores financeiros.
- “Rating” Consolida perceção de qualidade, unindo dados do IMDb, TMDb e *Rotten Tomatoes*. Funções de agregação permitem calcular média ponderada de rating por filme ou período.
- “Nomeacao” Contabiliza prémios e nomeações, permitindo análises de reconhecimento histórico. A ligação à dimensão Pessoa permite identificar prémios por ator ou diretor, enquanto a dimensão Conteudo relaciona o prémio ao filme ou série específico.

- “Inventario” Controla disponibilidade de conteúdos nas plataformas e o tipo de acesso (pago, gratuito ou aluguer). Fundamental para KPIs de distribuição e consumo, como número de conteúdos ativos por plataforma ou tempo total de catálogo disponível.

Fora as dimensões conforme, e as *fact tables* principais existem ainda 2 dimensões exclusivas da *fact table* inventario e nomeação respetivamente, sendo elas: “Plataforma”, que regista apenas os nomes de todas as plataformas de *streamings* existentes nos nossos dados e “Categoria”, que lista todas as categorias existentes nas nomeações dos Oscars. Cada uma respetivamente com o seu id.

Um dos desafios centrais foi o tratamento das relações "Muitos-para-Muitos" (N:M). A abordagem clássica implicaria duplicar registos na tabela de factos principal, o que corromperia qualquer métrica associada. Por exemplo, se o filme *Titanic* (Orçamento: 200M) fosse associado diretamente aos seus dois na tabela financeira, o orçamento seria contabilizado duas vezes nas agregações. Para evitar este erro, estas relações foram promovidas a *Factless Fact Tables* (“Genero”, “Pais”, “Estudio”, “Equipa”). Estas tabelas mantêm a associação entre atributos e conteúdos sem replicar as métricas das *fact tables* principais — seja orçamento, *ratings*, prémios ou contagens de inventário. Por exemplo, em “Financeira” o orçamento mantém-se único, enquanto a *Factless* “Genero” regista duas entradas distintas para o mesmo filme, permitindo analisar frequências de atributos sem distorcer as métricas. A escolha de tabelas "sem factos" (apenas chaves e contadores) em vez do conceito de *Bridge Tables* deve-se ao objetivo analítico de examinar a frequência e associação de atributos (ex.: "Quantos filmes de Drama foram produzidos em França?") sem duplicar indevidamente qualquer métrica principal.

Para garantir a performance em ambiente distribuído (*Spark*), o modelo evoluiu para uma abordagem Híbrida (figura 3).




Figura 3

Identificou-se que manter pequenas dimensões exclusivas de determinadas *fact tables* obrigaria o motor de processamento a realizar *joins* excessivos e dispendiosos. Consequentemente, procedeu-se à desnormalização estratégica de atributos de baixa cardinalidade diretamente para as tabelas de factos. Especificamente, a “Plataforma” foi absorvida pela *fact table* “Inventario” (coluna *nome_plataforma*) e a “Categoria” foi integrada em

“Nomeacao” (coluna nome_categoria). Esta lógica de desnormalização estendeu-se também às próprias *Factless Tables*, onde atributos como o nome do género ou do país foram persistidos internamente, eliminando a dependência de tabelas externas apenas para obter a designação. Esta decisão reduz a complexidade da *query* final, trocando um ligeiro aumento no armazenamento por ganhos significativos na velocidade de leitura.

A implementação técnica deste modelo no *PySpark* seguiu um fluxo sequencial rigoroso para assegurar a integridade referencial. O processo iniciou-se com a criação das Dimensões Conformes, onde se destaca a lógica complexa da dimensão “Conteudo”, que prioriza dados da API e preenche lacunas com dados de *Streaming* e *Rotten Tomatoes*, criando uma *Surrogate Key* única (id_conteudo). A implementação destas chaves substitutas é fundamental para isolar o *Data Lakehouse* das chaves operacionais das fontes (como IDs do IMDb ou TMDb). As SKs garantem a unicidade e a integridade referencial do sistema a longo prazo, protegendo o modelo contra alterações, formatos inconsistentes ou duplicados que possam surgir nos sistemas de origem.

Seguidamente, processaram-se as *Factless Tables*, recorrendo à função *explode* para transformar *arrays* de géneros e equipas técnicas em registos individuais, permitindo a granularidade fina necessária. Posteriormente, foram calculadas as Tabelas de Factos de Negócio, onde se aplicaram regras de consolidação de métricas financeiras.

Ainda, no seguimento de otimização de consultas e performance em ambiente distribuído (*Spark/Delta Lake*), todas as tabelas *Gold* foram projetadas com partições estratégicas e, quando necessário, *buckets*.

- Partições: cada tabela contém uma coluna-chave para segmentar os dados, facilitando filtragem eficiente e leitura seletiva. Por exemplo:
 - “Tempo” é particionada por década — consultas por períodos históricos são rápidas.
 - “Conteudo” por tipo (Filme/Série), permitindo filtragem direta em análises específicas.
 - “Pessoa” por género, útil para métricas por género de ator ou diretor.
 - *Factless tables* como “Genero”, “Pais” e “Estudio” são particionadas pelos atributos analíticos (genero, pais), enquanto “Equipa” usa *job* (ex: Acting, Director).
 - *Fact tables* usam partições que favorecem *queries* comuns: “Financeira” por fonte_receita, “Inventario” por tipo_acesso, e “Nomeacao” por categoria.
- *Buckets*: para tabelas com alta cardinalidade e joins frequentes (ex.: fact tables ligadas às dimensões), criaram-se buckets sobre as colunas de ligação (id_conteudo, id_pessoa). Isso reduz *shuffle* durante *joins* e melhora a *performance* de agregações complexas.

Esta combinação de partições para filtragem seletiva e *buckets* para *joins* eficientes garante que as tabelas *Gold* se comportam de forma escalável, mesmo quando se lidam com grandes volumes de dados e múltiplos tipos de métricas analíticas.

Com a estrutura final registada no *Hive Metastore*, o *Data Lakehouse* encontra-se validado, com chaves íntegras e granularidade correta, estando pronto para ser consumido pelo *Tableau* para a construção dos *Dashboards* de análise.

Dashboards

Os *dashboards* desenvolvidos têm como objetivo responder diretamente às questões analíticas definidas no início do projeto, operacionalizando os KPIs identificados e disponibilizando uma análise visual e interativa orientada aos diferentes *stakeholders* da indústria cinematográfica. Cada *dashboard* integra múltiplas visualizações que permitem explorar tendências temporais, relações entre variáveis e comparações entre grupos relevantes, suportando decisões estratégicas baseadas em dados.

Questão Analítica 1

Qual a evolução da produção de filmes ao longo do tempo?

Este *dashboard* (**figura 4**) analisa a evolução temporal da produção cinematográfica e da receita média ao longo dos anos, permitindo identificar padrões de crescimento, estagnação ou retração da indústria. A visualização da média de receita ao longo do tempo possibilita compreender períodos de maior rentabilidade e eventuais quebras associadas a mudanças estruturais do mercado.

Adicionalmente, é apresentada a distribuição da produção por gênero, permitindo identificar alterações no perfil da indústria e o surgimento de gêneros dominantes em determinados períodos. Esta análise é particularmente relevante para produtoras e investidores, ao apoiar decisões de planeamento estratégico e alocação de recursos com base em tendências históricas.




Figura 4

Questão Analítica 2

Que fatores explicam o sucesso comercial dos filmes?

Este *dashboard* (Figura 5 e 6) foi desenvolvido com o objetivo de identificar os principais fatores associados ao sucesso comercial dos filmes, medido essencialmente pela receita de bilheteira. A análise combina informação sobre desempenho financeiro, avaliação crítica, reconhecimento por prêmios e disponibilidade em plataformas de streaming.

O gráfico central é um *scatterplot* que relaciona o rating dos filmes com a receita obtida. Cada filme é representado por uma estrela, distinguindo-se visualmente filmes premiados e não premiados pela cor. Esta diferenciação permite observar que, em média, os filmes premiados tendem a concentrar-se em níveis mais elevados de rating e receita, sugerindo uma relação positiva entre reconhecimento institucional, qualidade percebida e desempenho comercial. Ainda assim, a existência de filmes não premiados com receitas elevadas demonstra que os prêmios não são o único fator explicativo do sucesso.

Complementarmente, um gráfico de barras compara a receita média dos filmes premiados com a dos não premiados, reforçando a evidência de que o reconhecimento por prêmios está associado a maior retorno financeiro. O *dashboard* inclui ainda um indicador da percentagem de filmes disponíveis em plataformas de streaming, permitindo contextualizar o sucesso comercial num mercado cada vez mais influenciado pela distribuição digital.

Para aprofundar a análise, foi construído um KPI de Prêmios por Género com uma visualização personalizada em formato de "Pódio". Fugindo aos gráficos de barras tradicionais, a implementação utilizou a função RANK_UNIQUE para classificar os géneros pelo total de vitórias e um algoritmo de "altura de pódio" para destacar visualmente o vencedor no topo. A visualização utiliza formas personalizadas de troféus com tamanhos proporcionais ao número de prêmios, segregando o "Top 3" no pódio e listando os restantes géneros numa tabela auxiliar.

Todas as visualizações são interativas e podem ser filtradas por rating, receita, ano de lançamento, género, país de produção e estatuto de prémio, possibilitando análises segmentadas e comparativas.



Figura 5




Figura 6

Questão Analítica 3

Quais atores, diretores, escritores, produtores e países geram mais retorno?

Este dashboard (**Figura 7 e 8**) analisa a relação entre a distribuição geográfica da receita cinematográfica e o impacto financeiro de atores e profissionais da indústria, combinando uma visualização espacial com um ranking de desempenho individual.

O mapa-mundo permite observar a concentração de receita por país de produção, evidenciando uma forte predominância dos Estados Unidos, que se destacam claramente como o principal polo económico da indústria cinematográfica. Ao interagir com o mapa, é possível analisar os filmes com maior contribuição para a receita total de cada país, verificando-se que os maiores valores estão associados a produções de grande escala e elevado orçamento, maioritariamente concentradas no mercado norte-americano. Países europeus surgem com contributos relevantes, mas significativamente inferiores, refletindo uma menor capacidade de gerar receitas globais.

Como complemento à análise geográfica, o *dashboard* inclui um gráfico de barras horizontais que apresenta o rendimento acumulado por carreira, permitindo comparar o desempenho financeiro de diferentes profissionais da indústria (atores, realizadores, argumentistas, entre outros). Este gráfico está ordenado do maior para o menor valor de receita, facilitando a identificação das figuras com maior impacto económico.

As barras são segmentadas, permitindo perceber se o sucesso financeiro de um profissional resulta de um número reduzido de grandes sucessos ou de uma carreira sustentada por vários projetos de menor escala. Esta distinção é relevante para compreender diferentes perfis de carreira dentro da indústria cinematográfica.

Adicionalmente, o dashboard apresenta indicadores de performance que contextualizam os resultados, como a média de receita por filme e a média de receita por carreira, permitindo uma leitura mais equilibrada entre volume total e eficiência individual. Estes indicadores ajustam-se dinamicamente consoante o tipo de profissional selecionado, reforçando a componente analítica da visualização.

Em conjunto, este dashboard evidencia que o sucesso financeiro no cinema resulta da combinação entre mercados geográficos dominantes e figuras-chave da indústria, oferecendo uma visão integrada sobre onde e por quem a receita cinematográfica é gerada.




Figura 7



Figura 8

Questão Analítica 4

Como o streaming alterou o sucesso comercial e cultural?

Este *dashboard* (**Figura 9**) foi concebido para analisar o impacto das plataformas de *streaming* no sucesso comercial e cultural dos filmes. A análise centra-se na comparação entre conteúdos exclusivos das plataformas e filmes não exclusivos, bem como na evolução da produção de conteúdos originais ao longo do tempo.

Um dos elementos centrais do *dashboard* é a comparação da receita média entre filmes exclusivos e não exclusivos, permitindo avaliar o impacto da exclusividade no desempenho financeiro. A análise da distribuição de géneros por plataforma evidencia ainda a diversidade de conteúdos disponibilizados, refletindo estratégias orientadas para públicos distintos e reforçando o papel do *streaming* na promoção da diversidade cultural.

Adicionalmente, a evolução temporal da percentagem de conteúdos originais mostra um crescimento consistente da produção própria das plataformas, indicando uma mudança estrutural no setor. As plataformas de *streaming* deixam de atuar apenas como distribuidores e passam a assumir um papel central enquanto produtoras de conteúdo, influenciando modelos de negócio, padrões de consumo e critérios de sucesso comercial e cultural.




Figura 9

Conclusão

Ao longo deste trabalho foi desenvolvido um processo completo de análise e visualização de dados aplicado à indústria do entretenimento, recorrendo a dados provenientes de APIs de filmes e séries. O principal objetivo foi transformar grandes volumes de dados brutos em *dashboards* interativos capazes de responder a questões analíticas relevantes sobre televisão, estrelas e prémios, distribuição geográfica da receita e plataformas de streaming.

Um dos principais pontos de aprendizagem foi o reforço das competências na preparação, limpeza e validação de dados, bem como na modelação analítica orientada a objetivos concretos. Destaca-se também o desenvolvimento de capacidades na criação de visualizações eficazes, com foco não apenas no aspeto técnico, mas sobretudo na clareza da informação, na interação com o utilizador e na extração de conclusões a partir dos dados.

Como aspetos positivos do desempenho da equipa, salienta-se a boa articulação entre os elementos, a divisão equilibrada de tarefas e a coerência visual e analítica entre os diferentes *dashboards*. A equipa demonstrou capacidade de integrar múltiplas fontes de dados, definir métricas relevantes e alinhar as visualizações com as questões analíticas propostas.

Como pontos menos positivos, destaca-se a complexidade associada à heterogeneidade dos dados, nomeadamente valores em falta, inconsistências temporais e limitações das APIs utilizadas, o que exigiu decisões de compromisso durante o processo de análise. Adicionalmente, a gestão de tempo revelou-se um desafio, especialmente na fase de refinamento visual e validação final dos *dashboards*.

Em síntese, o trabalho permitiu consolidar conhecimentos técnicos e analíticos, promover o trabalho colaborativo e demonstrar o potencial das ferramentas de visualização de dados como suporte à tomada de decisão, cumprindo de forma consistente os objetivos propostos.





Distribuição de Notas


Aluno	Nota
Alexandre Almeida	N
Dean Kuijf	N
Filipa Barroso Teixeira	N
Lorenzo Perry	N

Link vídeo: [youtube.com/watch?v=1f6J5PnyeT0&feature=youtu.be](https://www.youtube.com/watch?v=1f6J5PnyeT0&feature=youtu.be)


Anexo 1 – Relatório de *Data Profiling*

“The Oscar Award”

atributo	tipo	ejemplo	+info	Gráfico
Year_film	Nº real	1980	Distinct97 Minimum1927	
			Distinct (%)0.9% Maximum2024	
			Missing0 Zeros0	
			Missing (%)0.0% Zeros (%)0.0%	
			Infinite0 Negative0	
			Infinite (%)0.0% Negative (%)0.0%	
			Memory size43.5 KiB	
			Mean1977.1837	
Year_ceremony	Nº real	2000	Distinct97 Minimum1928	
			Distinct (%)0.9% Maximum2025	
			Missing0 Zeros0	
			Missing (%)0.0% Zeros (%)0.0%	
			Infinite0 Negative0	
			Infinite (%)0.0% Negative (%)0.0%	
			Memory size43.5 KiB	
			Mean1978.1837	
ceremony	Nº real	40	Distinct97 Minimum1	
			Distinct (%)0.9% Maximum97	
			Missing0 Zeros0	
			Missing (%)0.0% Zeros (%)0.0%	
			Infinite0 Negative0	
			Infinite (%)0.0% Negative (%)0.0%	
			Memory size43.5 KiB	
			Mean50.209271	
category	texto	actress	Distinct118	
			Distinct (%)1.1%	
			Missing0	
			Missing (%)0.0%	
			Memory size86.9 KiB	
Canon_category	texto	ACTOR IN A LEADING ROLE	Distinct58	
			Distinct (%)0.5%	
			Missing0	
			Missing (%)0.0%	
			Memory size86.9 KiB	

name	texto	Janet Gaynor	Distinct	6893	
			Distinct (%)	62.1%	
			Missing	7	
			Missing (%)	0.1%	
			Memory size	86.9 KiB	
film	texto	7th Heaven	Distinct	5116	
			Distinct (%)	47.6%	
			Missing	359	
			Missing (%)	3.2%	
			Memory size	86.9 KiB	
winner	Booleano	True	Distinct	2	
			Distinct (%)	< 0.1%	
			Missing	0	
			Missing (%)	0.0%	
			Memory size	11.0 KiB	

Matriz de Correlação:



1. Year Film vs Year Ceremony

a. Correlação fortíssima (≈ 1.0)

b. Interpretação: é praticamente linear — os filmes concorrem em cerimónias próximas ao ano de

lançamento.

c. Explicação: as cerimónias dos Óscares refletem a produção cinematográfica do ano anterior.

2. Ceremony vs Year Ceremony / Year Film

a. Correlação forte (≈ 1.0)

b. Interpretação: o número da edição da cerimónia está diretamente associado ao ano em que ocorreu.

c. Explicação: cada nova edição é sequencial e anual, mantendo a relação direta.


3. Winner vs Outras Variáveis






a. Correlação praticamente nula (≈ 0)




b. Interpretação: não há relação direta entre vencer e o ano ou a cerimónia.


c. Explicação: a vitória depende da votação e não de fatores temporais.

“Disney+ TV Shows And Movies”


atributo	tipo	exemplo	+info		gráfico
id	texto	tm74391	Distinct	1535	
			Distinct (%)	100.0%	
			Missing	0	
			Missing (%)	0.0%	
			Memory size	12.1 KiB	
title	texto	Bambi	Distinct	1500	
			Distinct (%)	97.7%	
			Missing	0	
			Missing (%)	0.0%	
			Memory size	12.1 KiB	
Type	texto	MOVIE	Distinct	2	
			Distinct (%)	0.1%	
			Missing	0	
			Missing (%)	0.0%	
			Memory size	12.1 KiB	
description	texto	Bambi's tale unfolds from season to season as the young prince of the forest...	Distinct	1528	
			Distinct (%)	99.9%	
			Missing	6	
			Missing (%)	0.4%	
			Memory size	12.1 KiB	

Released_year	Nº real	1940	<table><tr><td>Distinct</td><td>91</td><td>Minimum</td><td>1928</td></tr><tr><td>Distinct (%)</td><td>5.9%</td><td>Maximum</td><td>2022</td></tr><tr><td>Missing</td><td>0</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>2003.5779</td><td>Memory size</td><td>6.1 KiB</td></tr></table>	Distinct	91	Minimum	1928	Distinct (%)	5.9%	Maximum	2022	Missing	0	Zeros	0	Missing (%)	0.0%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	2003.5779	Memory size	6.1 KiB	
Distinct	91	Minimum	1928																													
Distinct (%)	5.9%	Maximum	2022																													
Missing	0	Zeros	0																													
Missing (%)	0.0%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	2003.5779	Memory size	6.1 KiB																													
Age_certification	texto	G	<table><tr><td>Distinct</td><td>9</td></tr><tr><td>Distinct (%)</td><td>0.7%</td></tr><tr><td>Missing</td><td>325</td></tr><tr><td>Missing (%)</td><td>21.2%</td></tr><tr><td>Memory size</td><td>12.1 KiB</td></tr></table>	Distinct	9	Distinct (%)	0.7%	Missing	325	Missing (%)	21.2%	Memory size	12.1 KiB																			
Distinct	9																															
Distinct (%)	0.7%																															
Missing	325																															
Missing (%)	21.2%																															
Memory size	12.1 KiB																															
runtime	Nº real	120.0	<table><tr><td>Distinct</td><td>157</td><td>Minimum</td><td>1</td></tr><tr><td>Distinct (%)</td><td>10.2%</td><td>Maximum</td><td>182</td></tr><tr><td>Missing</td><td>0</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>60.163518</td><td>Memory size</td><td>6.1 KiB</td></tr></table>	Distinct	157	Minimum	1	Distinct (%)	10.2%	Maximum	182	Missing	0	Zeros	0	Missing (%)	0.0%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	60.163518	Memory size	6.1 KiB	
Distinct	157	Minimum	1																													
Distinct (%)	10.2%	Maximum	182																													
Missing	0	Zeros	0																													
Missing (%)	0.0%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	60.163518	Memory size	6.1 KiB																													
Genres	texto	[‘family’, ‘action’]	<table><tr><td>Distinct</td><td>621</td></tr><tr><td>Distinct (%)</td><td>40.5%</td></tr><tr><td>Missing</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>12.1 KiB</td></tr></table>	Distinct	621	Distinct (%)	40.5%	Missing	0	Missing (%)	0.0%	Memory size	12.1 KiB																			
Distinct	621																															
Distinct (%)	40.5%																															
Missing	0																															
Missing (%)	0.0%																															
Memory size	12.1 KiB																															
Production_count ries	texto	[‘GB’, ‘US’]	<table><tr><td>Distinct</td><td>70</td></tr><tr><td>Distinct (%)</td><td>4.6%</td></tr><tr><td>Missing</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>12.1 KiB</td></tr></table>	Distinct	70	Distinct (%)	4.6%	Missing	0	Missing (%)	0.0%	Memory size	12.1 KiB																			
Distinct	70																															
Distinct (%)	4.6%																															
Missing	0																															
Missing (%)	0.0%																															
Memory size	12.1 KiB																															
Seasons	Nº real	1	<table><tr><td>Distinct</td><td>15</td><td>Minimum</td><td>1</td></tr><tr><td>Distinct (%)</td><td>3.6%</td><td>Maximum</td><td>34</td></tr><tr><td>Missing</td><td>1120</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>73.0%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>2.5831325</td><td>Memory size</td><td>12.1 KiB</td></tr></table>	Distinct	15	Minimum	1	Distinct (%)	3.6%	Maximum	34	Missing	1120	Zeros	0	Missing (%)	73.0%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	2.5831325	Memory size	12.1 KiB	
Distinct	15	Minimum	1																													
Distinct (%)	3.6%	Maximum	34																													
Missing	1120	Zeros	0																													
Missing (%)	73.0%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	2.5831325	Memory size	12.1 KiB																													

Imdb_id	texto	tt0032910	<table><tr><td>Distinct</td><td>1133</td></tr><tr><td>Distinct (%)</td><td>100.0%</td></tr><tr><td>Missing</td><td>402</td></tr><tr><td>Missing (%)</td><td>26.2%</td></tr><tr><td>Memory size</td><td>12.1 KiB</td></tr></table>	Distinct	1133	Distinct (%)	100.0%	Missing	402	Missing (%)	26.2%	Memory size	12.1 KiB																			
Distinct	1133																															
Distinct (%)	100.0%																															
Missing	402																															
Missing (%)	26.2%																															
Memory size	12.1 KiB																															
Imdb_score	Nº real	7.7	<table><tr><td>Distinct</td><td>66</td><td>Minimum</td><td>1.6</td></tr><tr><td>Distinct (%)</td><td>6.0%</td><td>Maximum</td><td>9.6999</td></tr><tr><td>Missing</td><td>427</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>27.8%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>6.6051444</td><td>Memory size</td><td>6.1 KiB</td></tr></table>	Distinct	66	Minimum	1.6	Distinct (%)	6.0%	Maximum	9.6999	Missing	427	Zeros	0	Missing (%)	27.8%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	6.6051444	Memory size	6.1 KiB	
Distinct	66	Minimum	1.6																													
Distinct (%)	6.0%	Maximum	9.6999																													
Missing	427	Zeros	0																													
Missing (%)	27.8%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	6.6051444	Memory size	6.1 KiB																													
Imdb_votes	Nº real	94681	<table><tr><td>Distinct</td><td>1003</td><td>Minimum</td><td>5</td></tr><tr><td>Distinct (%)</td><td>90.8%</td><td>Maximum</td><td>135390</td></tr><tr><td>Missing</td><td>430</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>28.0%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>76350.042</td><td>Memory size</td><td>12.1 KiB</td></tr></table>	Distinct	1003	Minimum	5	Distinct (%)	90.8%	Maximum	135390	Missing	430	Zeros	0	Missing (%)	28.0%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	76350.042	Memory size	12.1 KiB	
Distinct	1003	Minimum	5																													
Distinct (%)	90.8%	Maximum	135390																													
Missing	430	Zeros	0																													
Missing (%)	28.0%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	76350.042	Memory size	12.1 KiB																													
Tmdb_popularity	Nº real	57.75	<table><tr><td>Distinct</td><td>1445</td><td>Minimum</td><td>0.6000</td></tr><tr><td>Distinct (%)</td><td>94.8%</td><td>Maximum</td><td>9323.8</td></tr><tr><td>Missing</td><td>11</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.7%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>40.238486</td><td>Memory size</td><td>6.1 KiB</td></tr></table>	Distinct	1445	Minimum	0.6000	Distinct (%)	94.8%	Maximum	9323.8	Missing	11	Zeros	0	Missing (%)	0.7%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	40.238486	Memory size	6.1 KiB	
Distinct	1445	Minimum	0.6000																													
Distinct (%)	94.8%	Maximum	9323.8																													
Missing	11	Zeros	0																													
Missing (%)	0.7%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	40.238486	Memory size	6.1 KiB																													

Tmdb_score	Nº real	107.137	Distinct 62	Minimum 1	
			Distinct (%) 4.3%	Maximum 10	
			Missing 109	Zeros 0	
			Missing (%) 7.1%	Zeros (%) 0.0%	
			Infinite 0	Negative 0	
			Infinite (%) 0.0%	Negative (%) 0.0%	
			Mean 6.9163394	Memory size 6.1 KiB	

Matriz de Correlação:



1. IMDb Score vs IMDb Votes

- Correlação positiva moderada ($\approx 0.4-0.5$)
- Interpretação: produções com mais votos tendem a ter pontuações ligeiramente mais altas no IMDb.
- Explicação: filmes e séries populares normalmente atraem mais espectadores e, consequentemente, mais avaliações. O efeito de popularidade tende a elevar a média dos ratings.





2. IMDb Score vs TMDb Score

- Correlação positiva forte ($\approx 0.7-0.8$)
- Interpretação: há coerência nas avaliações entre as plataformas IMDb e TMDb.
- Explicação: ambas as plataformas refletem percepções semelhantes do público. Indica consistência na avaliação da qualidade das produções.

3. Release Year vs IMDb Votes

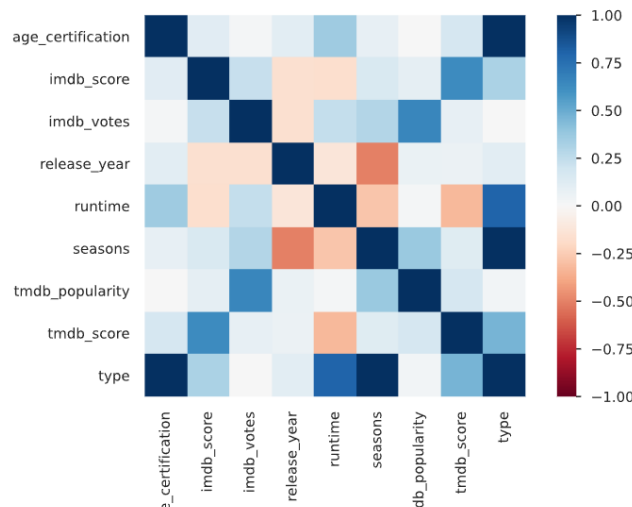
- Correlação positiva fraca ($\approx 0.25-0.50$)
- Interpretação: produções mais recentes tendem a ter mais votos.
- Explicação: maior exposição digital e aumento da base de utilizadores das plataformas. Produções antigas podem ter menos registos e *engagement* online.

“Netflix TV Shows and Movies”

atributo	tipo	Exemplo	+info	gráfico																												
id	texto	ts300399	<table><tr><td>Distinct</td><td>5850</td></tr><tr><td>Distinct (%)</td><td>100.0%</td></tr><tr><td>Missing</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>45.8 KiB</td></tr></table>	Distinct	5850	Distinct (%)	100.0%	Missing	0	Missing (%)	0.0%	Memory size	45.8 KiB																			
Distinct	5850																															
Distinct (%)	100.0%																															
Missing	0																															
Missing (%)	0.0%																															
Memory size	45.8 KiB																															
title	texto	“Five Came Back: The Reference Films”	<table><tr><td>Distinct</td><td>5798</td></tr><tr><td>Distinct (%)</td><td>99.1%</td></tr><tr><td>Missing</td><td>1</td></tr><tr><td>Missing (%)</td><td>< 0.1%</td></tr><tr><td>Memory size</td><td>45.8 KiB</td></tr></table>	Distinct	5798	Distinct (%)	99.1%	Missing	1	Missing (%)	< 0.1%	Memory size	45.8 KiB																			
Distinct	5798																															
Distinct (%)	99.1%																															
Missing	1																															
Missing (%)	< 0.1%																															
Memory size	45.8 KiB																															
type	texto	“MOVIE”	<table><tr><td>Distinct</td><td>2</td></tr><tr><td>Distinct (%)</td><td>< 0.1%</td></tr><tr><td>Missing</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>45.8 KiB</td></tr></table>	Distinct	2	Distinct (%)	< 0.1%	Missing	0	Missing (%)	0.0%	Memory size	45.8 KiB																			
Distinct	2																															
Distinct (%)	< 0.1%																															
Missing	0																															
Missing (%)	0.0%																															
Memory size	45.8 KiB																															
description	texto	“A young woman finds herself torn between love and duty”	<table><tr><td>Distinct</td><td>5829</td></tr><tr><td>Distinct (%)</td><td>99.9%</td></tr><tr><td>Missing</td><td>18</td></tr><tr><td>Missing (%)</td><td>0.3%</td></tr><tr><td>Memory size</td><td>45.8 KiB</td></tr></table>	Distinct	5829	Distinct (%)	99.9%	Missing	18	Missing (%)	0.3%	Memory size	45.8 KiB																			
Distinct	5829																															
Distinct (%)	99.9%																															
Missing	18																															
Missing (%)	0.3%																															
Memory size	45.8 KiB																															
release_year	NºReal	2010,2015,2020	<table><tr><td>Distinct</td><td>63</td><td>Minimum</td><td>1945</td></tr><tr><td>Distinct (%)</td><td>1.1%</td><td>Maximum</td><td>2022</td></tr><tr><td>Missing</td><td>0</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>2016.4171</td><td>Memory size</td><td>23.0 KiB</td></tr></table>	Distinct	63	Minimum	1945	Distinct (%)	1.1%	Maximum	2022	Missing	0	Zeros	0	Missing (%)	0.0%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	2016.4171	Memory size	23.0 KiB	
Distinct	63	Minimum	1945																													
Distinct (%)	1.1%	Maximum	2022																													
Missing	0	Zeros	0																													
Missing (%)	0.0%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	2016.4171	Memory size	23.0 KiB																													
age_certification	texto	“TV-MA”, “PG-13”, “TV-PG”	<table><tr><td>Distinct</td><td>11</td></tr><tr><td>Distinct (%)</td><td>0.3%</td></tr><tr><td>Missing</td><td>2619</td></tr><tr><td>Missing (%)</td><td>44.8%</td></tr><tr><td>Memory size</td><td>45.8 KiB</td></tr></table>	Distinct	11	Distinct (%)	0.3%	Missing	2619	Missing (%)	44.8%	Memory size	45.8 KiB																			
Distinct	11																															
Distinct (%)	0.3%																															
Missing	2619																															
Missing (%)	44.8%																															
Memory size	45.8 KiB																															
runtime	NºReal	96,120,240	<table><tr><td>Distinct</td><td>202</td><td>Minimum</td><td>0</td></tr><tr><td>Distinct (%)</td><td>3.5%</td><td>Maximum</td><td>240</td></tr><tr><td>Missing</td><td>0</td><td>Zeros</td><td>14</td></tr><tr><td>Missing (%)</td><td>0.0%</td><td>Zeros (%)</td><td>0.2%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>76.888889</td><td>Memory size</td><td>23.0 KiB</td></tr></table>	Distinct	202	Minimum	0	Distinct (%)	3.5%	Maximum	240	Missing	0	Zeros	14	Missing (%)	0.0%	Zeros (%)	0.2%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	76.888889	Memory size	23.0 KiB	
Distinct	202	Minimum	0																													
Distinct (%)	3.5%	Maximum	240																													
Missing	0	Zeros	14																													
Missing (%)	0.0%	Zeros (%)	0.2%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	76.888889	Memory size	23.0 KiB																													

genres	texto	“drama”, “crime”, “action”	<table><tr><td>Distinct</td><td>1726</td></tr><tr><td>Distinct (%)</td><td>29.5%</td></tr><tr><td>Missing</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>45.8 KiB</td></tr></table>	Distinct	1726	Distinct (%)	29.5%	Missing	0	Missing (%)	0.0%	Memory size	45.8 KiB																			
Distinct	1726																															
Distinct (%)	29.5%																															
Missing	0																															
Missing (%)	0.0%																															
Memory size	45.8 KiB																															
production_countries	texto	“US , GB , JP , FR”	<table><tr><td>Distinct</td><td>452</td></tr><tr><td>Distinct (%)</td><td>7.7%</td></tr><tr><td>Missing</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>45.8 KiB</td></tr></table>	Distinct	452	Distinct (%)	7.7%	Missing	0	Missing (%)	0.0%	Memory size	45.8 KiB																			
Distinct	452																															
Distinct (%)	7.7%																															
Missing	0																															
Missing (%)	0.0%																															
Memory size	45.8 KiB																															
seasons	N°Real	1,4,5	<table><tr><td>Distinct</td><td>26</td><td>Minimum</td><td>1</td></tr><tr><td>Distinct (%)</td><td>1.2%</td><td>Maximum</td><td>42</td></tr><tr><td>Missing</td><td>3744</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>64.0%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>2.162868</td><td>Memory size</td><td>45.8 KiB</td></tr></table>	Distinct	26	Minimum	1	Distinct (%)	1.2%	Maximum	42	Missing	3744	Zeros	0	Missing (%)	64.0%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	2.162868	Memory size	45.8 KiB	
Distinct	26	Minimum	1																													
Distinct (%)	1.2%	Maximum	42																													
Missing	3744	Zeros	0																													
Missing (%)	64.0%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	2.162868	Memory size	45.8 KiB																													
imdb_id	texto	“tt007531 4”	<table><tr><td>Distinct</td><td>5447</td></tr><tr><td>Distinct (%)</td><td>100.0%</td></tr><tr><td>Missing</td><td>403</td></tr><tr><td>Missing (%)</td><td>6.9%</td></tr><tr><td>Memory size</td><td>45.8 KiB</td></tr></table>	Distinct	5447	Distinct (%)	100.0%	Missing	403	Missing (%)	6.9%	Memory size	45.8 KiB																			
Distinct	5447																															
Distinct (%)	100.0%																															
Missing	403																															
Missing (%)	6.9%																															
Memory size	45.8 KiB																															
imdb_score	N°Real	4.4, 8.9, 7.7	<table><tr><td>Distinct</td><td>80</td><td>Minimum</td><td>1.5</td></tr><tr><td>Distinct (%)</td><td>1.5%</td><td>Maximum</td><td>9.6</td></tr><tr><td>Missing</td><td>482</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>8.2%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>6.5108607</td><td>Memory size</td><td>45.8 KiB</td></tr></table>	Distinct	80	Minimum	1.5	Distinct (%)	1.5%	Maximum	9.6	Missing	482	Zeros	0	Missing (%)	8.2%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	6.5108607	Memory size	45.8 KiB	
Distinct	80	Minimum	1.5																													
Distinct (%)	1.5%	Maximum	9.6																													
Missing	482	Zeros	0																													
Missing (%)	8.2%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	6.5108607	Memory size	45.8 KiB																													
imdb_votes	N°Real	808582	<table><tr><td>Distinct</td><td>3880</td><td>Minimum</td><td>5</td></tr><tr><td>Distinct (%)</td><td>72.5%</td><td>Maximum</td><td>2294231</td></tr><tr><td>Missing</td><td>498</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>8.5%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>23439.382</td><td>Memory size</td><td>45.8 KiB</td></tr></table>	Distinct	3880	Minimum	5	Distinct (%)	72.5%	Maximum	2294231	Missing	498	Zeros	0	Missing (%)	8.5%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	23439.382	Memory size	45.8 KiB	
Distinct	3880	Minimum	5																													
Distinct (%)	72.5%	Maximum	2294231																													
Missing	498	Zeros	0																													
Missing (%)	8.5%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	23439.382	Memory size	45.8 KiB																													
tmdb_popularity	N°Real	15.424	<table><tr><td>Distinct</td><td>4889</td><td>Minimum</td><td>0.0094417459</td></tr><tr><td>Distinct (%)</td><td>84.9%</td><td>Maximum</td><td>2274.044</td></tr><tr><td>Missing</td><td>91</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>1.6%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>22.637925</td><td>Memory size</td><td>45.8 KiB</td></tr></table>	Distinct	4889	Minimum	0.0094417459	Distinct (%)	84.9%	Maximum	2274.044	Missing	91	Zeros	0	Missing (%)	1.6%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	22.637925	Memory size	45.8 KiB	
Distinct	4889	Minimum	0.0094417459																													
Distinct (%)	84.9%	Maximum	2274.044																													
Missing	91	Zeros	0																													
Missing (%)	1.6%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	22.637925	Memory size	45.8 KiB																													
tmdb_score	N°Real	7.3	<table><tr><td>Distinct</td><td>4889</td><td>Minimum</td><td>0.0094417459</td></tr><tr><td>Distinct (%)</td><td>84.9%</td><td>Maximum</td><td>2274.044</td></tr><tr><td>Missing</td><td>91</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>1.6%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>22.637925</td><td>Memory size</td><td>45.8 KiB</td></tr></table>	Distinct	4889	Minimum	0.0094417459	Distinct (%)	84.9%	Maximum	2274.044	Missing	91	Zeros	0	Missing (%)	1.6%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	22.637925	Memory size	45.8 KiB	
Distinct	4889	Minimum	0.0094417459																													
Distinct (%)	84.9%	Maximum	2274.044																													
Missing	91	Zeros	0																													
Missing (%)	1.6%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	22.637925	Memory size	45.8 KiB																													

Matriz de correlação:



□ **imdb_votes vs imdb_score**

- Correlação positiva moderada ($\approx 0.25\text{--}0.50$)
- Interpretação: Quanto mais votos uma produção recebe, maior tende a ser a sua nota no IMDb.
- Explicação:
 - O envolvimento do público reflete maior reconhecimento e percepção de qualidade.
 - Produções bem avaliadas atraem mais espectadores e, conseqüentemente, mais votos.

□ **type vs runtime / seasons**



- Correlação positiva moderada ($\approx 0.25\text{--}0.50$)
- Interpretação: Séries (Shows) tendem a ter mais temporadas e episódios de menor duração.
- Explicação:
 - A estrutura das séries é desenhada para ser mais longa em número de temporadas, mas com episódios curtos.
 - A diferença entre formatos (filme vs série) explica as variações no runtime e seasons.

□ **release_year vs tmdb_popularity**

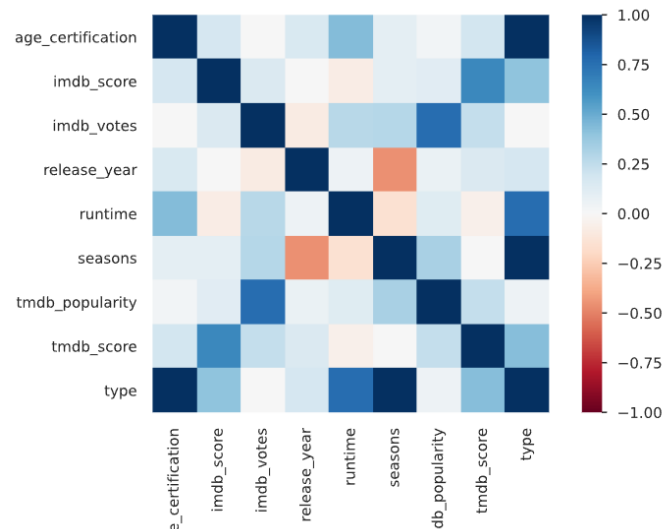
- Correlação positiva moderada ($\approx 0.25\text{--}0.50$)
- Interpretação: Produções mais recentes tendem a ser mais populares nas plataformas.
- Explicação:
 - Maior visibilidade e investimento em conteúdos recentes.
 - Relevância temporal e marketing digital favorecem os títulos novos.

“Amazon Prime TV Shows and Movies”

atributo	tipo	ejemplo	+info		gráfico
title	texto	“The Three Stooges”	Distinct	9737	
			Distinct (%)	98.6%	
			Missing	0	
			Missing (%)	0.0%	
			Memory size	77.2 KiB	
type	texto	“MOVIE ”	Distinct	2	
			Distinct (%)	< 0.1%	
			Missing	0	
			Missing (%)	0.0%	
			Memory size	77.2 KiB	
description	texto	“An aspiring actress begins to suspect that her temperamental boyfriend is a murderer.”	Distinct	9734	
			Distinct (%)	99.8%	
			Missing	119	
			Missing (%)	1.2%	
			Memory size	77.2 KiB	
released_year	NºReal	2010,2015,2020	Distinct	110	
			Distinct (%)	1.1%	
			Missing	0	
			Missing (%)	0.0%	
			Infinite	0	
			Infinite (%)	0.0%	
			Mean	2001.3272	
			Minimum	1912	
Maximum	2022				
Zeros	0				
Zeros (%)	0.0%				
Negative	0				
Negative (%)	0.0%				
Memory size	38.7 KiB				
age_certification	texto	“TV-MA”, “PG-13”, “TV-PG”	Distinct	11	
			Distinct (%)	0.3%	
			Missing	6487	
			Missing (%)	65.7%	
			Memory size	77.2 KiB	
runtime	NºReal	96,120,240	Distinct	207	
			Distinct (%)	2.1%	
			Missing	0	
			Missing (%)	0.0%	
			Infinite	0	
			Infinite (%)	0.0%	
			Mean	85.973052	
			Minimum	1	
Maximum	549				
Zeros	0				
Zeros (%)	0.0%				
Negative	0				
Negative (%)	0.0%				
Memory size	38.7 KiB				
genres	texto	“drama”, “crime”, “action”	Distinct	2028	
			Distinct (%)	20.5%	
			Missing	0	
			Missing (%)	0.0%	
			Memory size	77.2 KiB	
production_countries	texto	“US , GB , JP , FR”	Distinct	497	
			Distinct (%)	5.0%	
			Missing	0	
			Missing (%)	0.0%	
			Memory size	77.2 KiB	
seasons	NºReal	1,4,5	Distinct	32	
			Distinct (%)	2.4%	
			Missing	8514	
			Missing (%)	86.3%	
			Infinite	0	
			Infinite (%)	0.0%	
			Mean	2.7914517	
			Minimum	1	
Maximum	51				
Zeros	0				
Zeros (%)	0.0%				
Negative	0				
Negative (%)	0.0%				
Memory size	77.2 KiB				

imdb_id	texto	“tt0075314”	<table><tr><td>Distinct</td><td>9201</td></tr><tr><td>Distinct (%)</td><td>> 99.9%</td></tr><tr><td>Missing</td><td>667</td></tr><tr><td>Missing (%)</td><td>6.8%</td></tr><tr><td>Memory size</td><td>77.2 KiB</td></tr></table>	Distinct	9201	Distinct (%)	> 99.9%	Missing	667	Missing (%)	6.8%	Memory size	77.2 KiB																			
Distinct	9201																															
Distinct (%)	> 99.9%																															
Missing	667																															
Missing (%)	6.8%																															
Memory size	77.2 KiB																															
imdb_score	NºReal	4.4, 8.9, 7.7	<table><tr><td>Distinct</td><td>86</td><td>Minimum</td><td>1.1</td></tr><tr><td>Distinct (%)</td><td>1.0%</td><td>Maximum</td><td>9.9</td></tr><tr><td>Missing</td><td>1021</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>10.3%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>5.9763955</td><td>Memory size</td><td>77.2 KiB</td></tr></table>	Distinct	86	Minimum	1.1	Distinct (%)	1.0%	Maximum	9.9	Missing	1021	Zeros	0	Missing (%)	10.3%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	5.9763955	Memory size	77.2 KiB	
Distinct	86	Minimum	1.1																													
Distinct (%)	1.0%	Maximum	9.9																													
Missing	1021	Zeros	0																													
Missing (%)	10.3%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	5.9763955	Memory size	77.2 KiB																													
imdb_votes	NºReal	808582	<table><tr><td>Distinct</td><td>86</td><td>Minimum</td><td>1.1</td></tr><tr><td>Distinct (%)</td><td>1.0%</td><td>Maximum</td><td>9.9</td></tr><tr><td>Missing</td><td>1021</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>10.3%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>5.9763955</td><td>Memory size</td><td>77.2 KiB</td></tr></table>	Distinct	86	Minimum	1.1	Distinct (%)	1.0%	Maximum	9.9	Missing	1021	Zeros	0	Missing (%)	10.3%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	5.9763955	Memory size	77.2 KiB	
Distinct	86	Minimum	1.1																													
Distinct (%)	1.0%	Maximum	9.9																													
Missing	1021	Zeros	0																													
Missing (%)	10.3%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	5.9763955	Memory size	77.2 KiB																													
tmdb_popularity	NºReal	15.424	<table><tr><td>Distinct</td><td>5325</td><td>Minimum</td><td>1.1 × 10⁻⁵</td></tr><tr><td>Distinct (%)</td><td>57.1%</td><td>Maximum</td><td>1437.906</td></tr><tr><td>Missing</td><td>547</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>5.5%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>6.9102044</td><td>Memory size</td><td>77.2 KiB</td></tr></table>	Distinct	5325	Minimum	1.1 × 10 ⁻⁵	Distinct (%)	57.1%	Maximum	1437.906	Missing	547	Zeros	0	Missing (%)	5.5%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	6.9102044	Memory size	77.2 KiB	
Distinct	5325	Minimum	1.1 × 10 ⁻⁵																													
Distinct (%)	57.1%	Maximum	1437.906																													
Missing	547	Zeros	0																													
Missing (%)	5.5%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	6.9102044	Memory size	77.2 KiB																													
tmdb_score	NºReal	7.3	<table><tr><td>Distinct</td><td>89</td><td>Minimum</td><td>0.8</td></tr><tr><td>Distinct (%)</td><td>1.1%</td><td>Maximum</td><td>10</td></tr><tr><td>Missing</td><td>2082</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>21.1%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>5.984247</td><td>Memory size</td><td>77.2 KiB</td></tr></table>	Distinct	89	Minimum	0.8	Distinct (%)	1.1%	Maximum	10	Missing	2082	Zeros	0	Missing (%)	21.1%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	5.984247	Memory size	77.2 KiB	
Distinct	89	Minimum	0.8																													
Distinct (%)	1.1%	Maximum	10																													
Missing	2082	Zeros	0																													
Missing (%)	21.1%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	5.984247	Memory size	77.2 KiB																													

Matriz de correlação:



A 4.2

□ **imdb_votes vs imdb_score / tmdb_score**

- Correlação positiva moderada ($\approx 0.25-0.50$)
- Interpretação: Títulos com mais votos costumam ter melhores avaliações tanto no IMDb como no TMDB.
- Explicação:
 - Obras bem recebidas tendem a gerar mais engajamento e votos.
 - As diferentes plataformas refletem percepções semelhantes de qualidade.



□ **type vs runtime / seasons**



- Correlação positiva moderada ($\approx 0.25-0.50$)
- Interpretação: O tipo de conteúdo (filme ou série) influencia diretamente a duração e o número de temporadas.
- Explicação:
 - Séries apresentam mais seasons e episódios curtos, enquanto filmes são mais longos e únicos.
 - Essa diferença estrutural explica a correlação entre tipo e runtime.

□ **release_year vs tmdb_popularity**

- Correlação positiva moderada ($\approx 0.25-0.50$)
- Interpretação: Produções mais recentes têm maior visibilidade e engajamento.
- Explicação:
 - O algoritmo das plataformas tende a promover conteúdos novos.
 - Lançamentos recentes recebem mais atenção e marketing



“Actors_Films – IMDB”

Atributo	Tipo	Exemplo	+info	Gráfico																												
Actor	Texto	Fred Astaire	<table><tr><td>Distinct</td><td>9615</td></tr><tr><td>Distinct (%)</td><td>5.0%</td></tr><tr><td>Missing</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>1.5 MiB</td></tr></table>	Distinct	9615	Distinct (%)	5.0%	Missing	0	Missing (%)	0.0%	Memory size	1.5 MiB																			
Distinct	9615																															
Distinct (%)	5.0%																															
Missing	0																															
Missing (%)	0.0%																															
Memory size	1.5 MiB																															
ActorID	Texto	nm0000001	<table><tr><td>Distinct</td><td>9623</td></tr><tr><td>Distinct (%)</td><td>5.0%</td></tr><tr><td>Missing</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>1.5 MiB</td></tr></table>	Distinct	9623	Distinct (%)	5.0%	Missing	0	Missing (%)	0.0%	Memory size	1.5 MiB																			
Distinct	9623																															
Distinct (%)	5.0%																															
Missing	0																															
Missing (%)	0.0%																															
Memory size	1.5 MiB																															
Film	Texto	The Purple Taxi	<table><tr><td>Distinct</td><td>41050</td></tr><tr><td>Distinct (%)</td><td>21.4%</td></tr><tr><td>Missing</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>1.5 MiB</td></tr></table>	Distinct	41050	Distinct (%)	21.4%	Missing	0	Missing (%)	0.0%	Memory size	1.5 MiB																			
Distinct	41050																															
Distinct (%)	21.4%																															
Missing	0																															
Missing (%)	0.0%																															
Memory size	1.5 MiB																															
Year	Nº Inteiro	1977	<table><tr><td>Distinct</td><td>108</td><td>Minimum</td><td>1914</td></tr><tr><td>Distinct (%)</td><td>0.1%</td><td>Maximum</td><td>2021</td></tr><tr><td>Missing</td><td>0</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>1997.9529</td><td>Memory size</td><td>749.6</td></tr></table>	Distinct	108	Minimum	1914	Distinct (%)	0.1%	Maximum	2021	Missing	0	Zeros	0	Missing (%)	0.0%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	1997.9529	Memory size	749.6	
Distinct	108	Minimum	1914																													
Distinct (%)	0.1%	Maximum	2021																													
Missing	0	Zeros	0																													
Missing (%)	0.0%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	1997.9529	Memory size	749.6																													


Votes	Nº inteiro	7731	<table><tr><td>Distinct</td><td>14345</td><td>Minimum</td><td>100</td></tr><tr><td>Distinct (%)</td><td>7.5%</td><td>Maximum</td><td>23715</td></tr><tr><td>Missing</td><td>0</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>50418.573</td><td>Memory size</td><td>749.6</td></tr></table>	Distinct	14345	Minimum	100	Distinct (%)	7.5%	Maximum	23715	Missing	0	Zeros	0	Missing (%)	0.0%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	50418.573	Memory size	749.6	
Distinct	14345	Minimum	100																													
Distinct (%)	7.5%	Maximum	23715																													
Missing	0	Zeros	0																													
Missing (%)	0.0%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	50418.573	Memory size	749.6																													
Rating	Nº Real	6.3	<table><tr><td>Distinct</td><td>84</td><td>Minimum</td><td>1</td></tr><tr><td>Distinct (%)</td><td>< 0.1%</td><td>Maximum</td><td>9.3</td></tr><tr><td>Missing</td><td>0</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>5.9757637</td><td>Memory size</td><td>1.5 Mi</td></tr></table>	Distinct	84	Minimum	1	Distinct (%)	< 0.1%	Maximum	9.3	Missing	0	Zeros	0	Missing (%)	0.0%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	5.9757637	Memory size	1.5 Mi	
Distinct	84	Minimum	1																													
Distinct (%)	< 0.1%	Maximum	9.3																													
Missing	0	Zeros	0																													
Missing (%)	0.0%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	5.9757637	Memory size	1.5 Mi																													
FilmID	Texto	tt0074130	<table><tr><td>Distinct</td><td>44456</td></tr><tr><td>Distinct (%)</td><td>23.2%</td></tr><tr><td>Missing</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>1.5 MiB</td></tr></table>	Distinct	44456	Distinct (%)	23.2%	Missing	0	Missing (%)	0.0%	Memory size	1.5 MiB																			
Distinct	44456																															
Distinct (%)	23.2%																															
Missing	0																															
Missing (%)	0.0%																															
Memory size	1.5 MiB																															

- Correlação positiva moderada ($\approx 0.30-0.40$)
 - Interpretação: Filmes com mais votos tendem a ter *ratings* ligeiramente melhores
 - Explicação:
 - Filmes populares (com muitos votos) são geralmente de melhor qualidade
 - Efeito de popularidade normalmente influencia a percepção de qualidade
2. *Year vs Rating*
- Correlação muito fraca (próxima de 0)
 - Interpretação: O ano de lançamento não influencia a avaliação
 - Explicação:
 - Qualidade do cinema é consistente ao longo do tempo (1914-2021)
3. *Year vs Votes*
- Correlação positiva fraca ($\approx 0.15-0.25$)
 - interpretação: Filmes mais recentes têm mais votos
 - Explicação:
 - Maior conscientização e incentivo para votar no IMDB nos últimos anos
 - Crescimento populacional

“boxoffice_data_2024”

Atributo	Tipo	Exemplo	+info	Gráfico																												
Year	Nº inteiro	2019	<table><tr><td>Distinct</td><td>41</td><td>Minimum</td><td>1984</td></tr><tr><td>Distinct (%)</td><td>0.5%</td><td>Maximum</td><td>2024</td></tr><tr><td>Missing</td><td>0</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>2004.1326</td><td>Memory size</td><td>31.9 K</td></tr></table>	Distinct	41	Minimum	1984	Distinct (%)	0.5%	Maximum	2024	Missing	0	Zeros	0	Missing (%)	0.0%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	2004.1326	Memory size	31.9 K	
Distinct	41	Minimum	1984																													
Distinct (%)	0.5%	Maximum	2024																													
Missing	0	Zeros	0																													
Missing (%)	0.0%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	2004.1326	Memory size	31.9 K																													
Title	texto	“Ghostbusters”	<table><tr><td>Distinct</td><td>7980</td></tr><tr><td>Distinct (%)</td><td>98.0%</td></tr><tr><td>Missing</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>63.8 KiB</td></tr></table>	Distinct	7980	Distinct (%)	98.0%	Missing	0	Missing (%)	0.0%	Memory size	63.8 KiB																			
Distinct	7980																															
Distinct (%)	98.0%																															
Missing	0																															
Missing (%)	0.0%																															
Memory size	63.8 KiB																															
Gross	Nº Real	229376332.0	<table><tr><td>Distinct</td><td>8143</td><td>Minimum</td><td>2357</td></tr><tr><td>Distinct (%)</td><td>> 99.9%</td><td>Maximum</td><td>2.7994</td></tr><tr><td>Missing</td><td>0</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>82167077</td><td>Memory size</td><td>63.8 K</td></tr></table>	Distinct	8143	Minimum	2357	Distinct (%)	> 99.9%	Maximum	2.7994	Missing	0	Zeros	0	Missing (%)	0.0%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	82167077	Memory size	63.8 K	
Distinct	8143	Minimum	2357																													
Distinct (%)	> 99.9%	Maximum	2.7994																													
Missing	0	Zeros	0																													
Missing (%)	0.0%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	82167077	Memory size	63.8 K																													

Matriz de correlação:



1. year vs gross
- a. Correlação positiva moderada ($\approx 0.25\text{--}0.50$)

b. Interpretação: À medida que os anos passam, a receita total dos filmes tende a aumentar.

c. Explicação:

i. A inflação ao longo dos anos aumenta o valor nominal das receitas.




ii. O crescimento populacional resulta em audiências maiores.







iii. O mercado cinematográfico expandiu-se com mais salas e acessibilidade.

iv. O preço dos bilhetes subiu, também influenciado pela inflação.


“Rotten Tomatoes Movie Rating”

atributo	tipo	exemplo	+info	gráfico
Movie_title	texto	Percy Jackson & the Olympians: The Lightning Thief	Distinct 16106 Distinct (%) 96.8% Missing 0 Missing (%) 0.0% Memory size 1.2 MiB	
Movie_info	texto	A teenager discovers he's the descendant of a Greek god and sets out on an adventure to settle an on-going battle between the gods.		
critics_consensus	texto	Though it may seem like just another Harry Potter knockoff, Percy Jackson benefits from a strong supporting		

		cast, a speedy plot, and plenty of fun with Greek mythology.																						
rating	texto	PG	<table><tr><td>Distinct</td><td>8</td></tr><tr><td>Distinct (%)</td><td>< 0.1%</td></tr><tr><td>Missing</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>960.7 KiB</td></tr></table>	Distinct	8	Distinct (%)	< 0.1%	Missing	0	Missing (%)	0.0%	Memory size	960.7 KiB											
Distinct	8																							
Distinct (%)	< 0.1%																							
Missing	0																							
Missing (%)	0.0%																							
Memory size	960.7 KiB																							
genre	Texto	Comedy	<table><tr><td>Distinct</td><td>1080</td></tr><tr><td>Distinct (%)</td><td>6.5%</td></tr><tr><td>Missing</td><td>17</td></tr><tr><td>Missing (%)</td><td>0.1%</td></tr><tr><td>Memory size</td><td>1.4 MiB</td></tr></table>	Distinct	1080	Distinct (%)	6.5%	Missing	17	Missing (%)	0.1%	Memory size	1.4 MiB											
Distinct	1080																							
Distinct (%)	6.5%																							
Missing	17																							
Missing (%)	0.1%																							
Memory size	1.4 MiB																							
directors	texto	Chris Columbus	<table><tr><td>Distinct</td><td>8314</td></tr><tr><td>Distinct (%)</td><td>50.3%</td></tr><tr><td>Missing</td><td>114</td></tr><tr><td>Missing (%)</td><td>0.7%</td></tr><tr><td>Memory size</td><td>1.2 MiB</td></tr></table>	Distinct	8314	Distinct (%)	50.3%	Missing	114	Missing (%)	0.7%	Memory size	1.2 MiB											
Distinct	8314																							
Distinct (%)	50.3%																							
Missing	114																							
Missing (%)	0.7%																							
Memory size	1.2 MiB																							
writers	Texto	Craig Titley	<table><tr><td>Distinct</td><td>12121</td></tr><tr><td>Distinct (%)</td><td>79.3%</td></tr><tr><td>Missing</td><td>1349</td></tr><tr><td>Missing (%)</td><td>8.1%</td></tr><tr><td>Memory size</td><td>1.3 MiB</td></tr></table>	Distinct	12121	Distinct (%)	79.3%	Missing	1349	Missing (%)	8.1%	Memory size	1.3 MiB											
Distinct	12121																							
Distinct (%)	79.3%																							
Missing	1349																							
Missing (%)	8.1%																							
Memory size	1.3 MiB																							
cast	texto	Logan Lerman, Brandon T. Jackson, Alexandra Daddario, Jake Abel, Sean Bean, ...	<table><tr><td>Distinct</td><td>16326</td></tr><tr><td>Distinct (%)</td><td>99.8%</td></tr><tr><td>Missing</td><td>284</td></tr><tr><td>Missing (%)</td><td>1.7%</td></tr><tr><td>Memory size</td><td>8.6 MiB</td></tr></table>	Distinct	16326	Distinct (%)	99.8%	Missing	284	Missing (%)	1.7%	Memory size	8.6 MiB											
Distinct	16326																							
Distinct (%)	99.8%																							
Missing	284																							
Missing (%)	1.7%																							
Memory size	8.6 MiB																							
in_theaters_date	Data	2010-02-12	<table><tr><td>Distinct</td><td>5586</td><td>Minimum</td><td>1914-06-01 00</td></tr><tr><td>Distinct (%)</td><td>35.3%</td><td>Maximum</td><td>2019-12-07 00</td></tr><tr><td>Missing</td><td>815</td><td>Invalid dates</td><td>0</td></tr><tr><td>Missing (%)</td><td>4.9%</td><td>Invalid dates (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>643.7 KiB</td><td></td><td></td></tr></table>	Distinct	5586	Minimum	1914-06-01 00	Distinct (%)	35.3%	Maximum	2019-12-07 00	Missing	815	Invalid dates	0	Missing (%)	4.9%	Invalid dates (%)	0.0%	Memory size	643.7 KiB			
Distinct	5586	Minimum	1914-06-01 00																					
Distinct (%)	35.3%	Maximum	2019-12-07 00																					
Missing	815	Invalid dates	0																					
Missing (%)	4.9%	Invalid dates (%)	0.0%																					
Memory size	643.7 KiB																							
on_streaming_date	Data	2010-06-29	<table><tr><td>Distinct</td><td>2260</td><td>Minimum</td><td>1935-06-06 00</td></tr><tr><td>Distinct (%)</td><td>13.6%</td><td>Maximum</td><td>2019-11-01 00</td></tr><tr><td>Missing</td><td>2</td><td>Invalid dates</td><td>0</td></tr><tr><td>Missing (%)</td><td>< 0.1%</td><td>Invalid dates (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>650.0 KiB</td><td></td><td></td></tr></table>	Distinct	2260	Minimum	1935-06-06 00	Distinct (%)	13.6%	Maximum	2019-11-01 00	Missing	2	Invalid dates	0	Missing (%)	< 0.1%	Invalid dates (%)	0.0%	Memory size	650.0 KiB			
Distinct	2260	Minimum	1935-06-06 00																					
Distinct (%)	13.6%	Maximum	2019-11-01 00																					
Missing	2	Invalid dates	0																					
Missing (%)	< 0.1%	Invalid dates (%)	0.0%																					
Memory size	650.0 KiB																							

runtime_in_minutes	Inteiro	83	<table><tr><td>Distinct</td><td>201</td><td>Minimum</td><td>1</td></tr><tr><td>Distinct (%)</td><td>1.2%</td><td>Maximum</td><td>2000</td></tr><tr><td>Missing</td><td>155</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.9%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>102.39149</td><td>Memory size</td><td>130.1 KiB</td></tr></table>	Distinct	201	Minimum	1	Distinct (%)	1.2%	Maximum	2000	Missing	155	Zeros	0	Missing (%)	0.9%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	102.39149	Memory size	130.1 KiB	
Distinct	201	Minimum	1																													
Distinct (%)	1.2%	Maximum	2000																													
Missing	155	Zeros	0																													
Missing (%)	0.9%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	102.39149	Memory size	130.1 KiB																													
studio_name	Texto	20th Century Fox	<table><tr><td>Distinct</td><td>2886</td></tr><tr><td>Distinct (%)</td><td>17.8%</td></tr><tr><td>Missing</td><td>416</td></tr><tr><td>Missing (%)</td><td>2.5%</td></tr><tr><td>Memory size</td><td>1.2 MiB</td></tr></table>	Distinct	2886	Distinct (%)	17.8%	Missing	416	Missing (%)	2.5%	Memory size	1.2 MiB																			
Distinct	2886																															
Distinct (%)	17.8%																															
Missing	416																															
Missing (%)	2.5%																															
Memory size	1.2 MiB																															
tomatometer_status	Texto	Rotten	<table><tr><td>Distinct</td><td>3</td></tr><tr><td>Distinct (%)</td><td>< 0.1%</td></tr><tr><td>Missing</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td></tr><tr><td>Memory size</td><td>1.0 MiB</td></tr></table>	Distinct	3	Distinct (%)	< 0.1%	Missing	0	Missing (%)	0.0%	Memory size	1.0 MiB																			
Distinct	3																															
Distinct (%)	< 0.1%																															
Missing	0																															
Missing (%)	0.0%																															
Memory size	1.0 MiB																															
tomatometer_rating	Inteiro	49	<table><tr><td>Distinct</td><td>101</td><td>Minimum</td><td>0</td></tr><tr><td>Distinct (%)</td><td>0.6%</td><td>Maximum</td><td>100</td></tr><tr><td>Missing</td><td>0</td><td>Zeros</td><td>346</td></tr><tr><td>Missing (%)</td><td>0.0%</td><td>Zeros (%)</td><td>2.1%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>60.466522</td><td>Memory size</td><td>65.1 KiB</td></tr></table>	Distinct	101	Minimum	0	Distinct (%)	0.6%	Maximum	100	Missing	0	Zeros	346	Missing (%)	0.0%	Zeros (%)	2.1%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	60.466522	Memory size	65.1 KiB	
Distinct	101	Minimum	0																													
Distinct (%)	0.6%	Maximum	100																													
Missing	0	Zeros	346																													
Missing (%)	0.0%	Zeros (%)	2.1%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	60.466522	Memory size	65.1 KiB																													
tomatometer_count	Inteiro	144	<table><tr><td>Distinct</td><td>393</td><td>Minimum</td><td>5</td></tr><tr><td>Distinct (%)</td><td>2.4%</td><td>Maximum</td><td>497</td></tr><tr><td>Missing</td><td>0</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>0.0%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>56.607104</td><td>Memory size</td><td>65.1 KiB</td></tr></table>	Distinct	393	Minimum	5	Distinct (%)	2.4%	Maximum	497	Missing	0	Zeros	0	Missing (%)	0.0%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	56.607104	Memory size	65.1 KiB	
Distinct	393	Minimum	5																													
Distinct (%)	2.4%	Maximum	497																													
Missing	0	Zeros	0																													
Missing (%)	0.0%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	56.607104	Memory size	65.1 KiB																													
audience_rating	Inteiro	53	<table><tr><td>Distinct</td><td>98</td><td>Minimum</td><td>0</td></tr><tr><td>Distinct (%)</td><td>0.6%</td><td>Maximum</td><td>100</td></tr><tr><td>Missing</td><td>252</td><td>Zeros</td><td>5</td></tr><tr><td>Missing (%)</td><td>1.5%</td><td>Zeros (%)</td><td>< 0.1%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>60.470829</td><td>Memory size</td><td>130.1 KiB</td></tr></table>	Distinct	98	Minimum	0	Distinct (%)	0.6%	Maximum	100	Missing	252	Zeros	5	Missing (%)	1.5%	Zeros (%)	< 0.1%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	60.470829	Memory size	130.1 KiB	
Distinct	98	Minimum	0																													
Distinct (%)	0.6%	Maximum	100																													
Missing	252	Zeros	5																													
Missing (%)	1.5%	Zeros (%)	< 0.1%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	60.470829	Memory size	130.1 KiB																													
audience_count	Inteiro	254287	<table><tr><td>Distinct</td><td>10885</td><td>Minimum</td><td>5</td></tr><tr><td>Distinct (%)</td><td>66.4%</td><td>Maximum</td><td>35797635</td></tr><tr><td>Missing</td><td>252</td><td>Zeros</td><td>0</td></tr><tr><td>Missing (%)</td><td>1.5%</td><td>Zeros (%)</td><td>0.0%</td></tr><tr><td>Infinite</td><td>0</td><td>Negative</td><td>0</td></tr><tr><td>Infinite (%)</td><td>0.0%</td><td>Negative (%)</td><td>0.0%</td></tr><tr><td>Mean</td><td>152479.7</td><td>Memory size</td><td>130.1 KiB</td></tr></table>	Distinct	10885	Minimum	5	Distinct (%)	66.4%	Maximum	35797635	Missing	252	Zeros	0	Missing (%)	1.5%	Zeros (%)	0.0%	Infinite	0	Negative	0	Infinite (%)	0.0%	Negative (%)	0.0%	Mean	152479.7	Memory size	130.1 KiB	
Distinct	10885	Minimum	5																													
Distinct (%)	66.4%	Maximum	35797635																													
Missing	252	Zeros	0																													
Missing (%)	1.5%	Zeros (%)	0.0%																													
Infinite	0	Negative	0																													
Infinite (%)	0.0%	Negative (%)	0.0%																													
Mean	152479.7	Memory size	130.1 KiB																													

Matriz de Correlação:



1. *tomatometer_count* vs *audience_count*

a. Correlação: Positiva Moderada ($\approx 0.5-0.7$)

b. Interpretação: Há uma forte associação entre o volume de críticas profissionais e o volume de votos/avaliações da audiência.

c. Explicação: Popularidade e Exposição: As produções mais populares e de maior destaque (*Blockbusters*, séries de alto perfil) atraem naturalmente mais críticos profissionais para avaliá-las (*tomatometer_count*) e, ao mesmo tempo, originam maior *engagement* do público, resultando em mais votos (*audience_count*). Mecanismo de Plataforma: O número de críticas e o número de avaliações do público crescem em conjunto, pois ambos são reflexos diretos da visibilidade e da relevância cultural da obra.

2. *tomatometer_rating* vs *audience_rating*

a. Correlação: Positiva Moderada ($\approx 0.5-0.7$)

b. Interpretação: A avaliação média dos críticos tende a acompanhar a avaliação média da audiência. No entanto, há espaço para discordância.

c. Explicação: Acordo de Qualidade: Em geral, obras de alta qualidade (em termos de produção, escrita, atuação) são reconhecidas como boas tanto por críticos quanto pelo público, puxando a correlação para cima. Divergência de Perspetiva: A correlação não é perfeita, pois críticos e público usam critérios diferentes. O público valoriza o entretenimento e a satisfação pessoal, enquanto os críticos focam na arte, técnica e originalidade.

3. *tomatometer_status* vs *tomatometer_rating*

a. Correlação: Positiva Fortíssima ($\approx 0.8-0.9$)

b. Interpretação: O status do Tomatometer (*Fresh*, *Rotten*, *Certified Fresh*) é quase perfeitamente determinado pela pontuação percentual (*tomatometer_rating*).

c. Explicação: Dependência Algorítmica: Um é derivado do outro. O *tomatometer_status* é uma variável categórica (ou ordinal, dependendo da representação) que é definida por limiares numéricos da pontuação *tomatometer_rating*.

Por exemplo, um filme é "Fresh" se a pontuação for $\geq 60\%$. Causa e Efeito: Uma variação na pontuação causa uma variação quase direta no status (exceto nos pontos de corte), resultando numa correlação extremamente alta.

4. *audience_count* vs *runtime_in_minutes*

a. Correlação: Positiva Fraca ($\approx 0.2-0.4$)

b. Interpretação: Filmes e séries ligeiramente mais longas tendem a ter um pouco mais de votos da audiência, mas a relação não é forte.

c. Explicação: Produções de Maior Escala: Os filmes com maior tempo de execução (longas-metragens de 2h+, minisséries) são frequentemente produções de grande orçamento e alta publicidade. Essa visibilidade pode levar a um maior número de visualizações e, conseqüentemente, a um maior *audience_count*. Fator Não Determinante: Embora exista uma leve tendência, a duração do filme, por si só, não é o motor primário da popularidade. A qualidade e o *marketing* são muito mais importantes.

5. *runtime_in_minutes* vs *audience_rating*

a. Correlação: Positiva Fraca ($\approx 0.1-0.2$)

b. Interpretação: A duração da produção não tem um impacto significativo na avaliação média da audiência.

c. Explicação: Qualidade vs Duração: O público não penaliza ou recompensa uma obra apenas por ser longa ou curta. A satisfação é determinada pela qualidade do conteúdo (ritmo, enredo, desfecho), e não pelo tempo de duração. Impacto Neutro: Uma correlação próxima de zero significa que a duração é uma variável independente da pontuação final da audiência.

“TMDB API – Filmes”

Summary	tmdb_id	orcamento	receita	duracao	nota_tmdb	votos_tmdb	popularidade
Count	61913	61913	61913	61913	61913	61913	61913
Mean	213479.78	4886927.78	1.33 E7	95.68	5.62	414.98	2.15
Stdev	237852.82	1.90 E7	7.27 E7	26.58	1.53	1614.79	2.53
Min	5	0	0	0	0	0	0
max	1600634	583900000	2923706026	743	10	38476	132.808

“TMDB API – Séries”

Summary	tmdb_id	total_seasons	nota_tmdb	votos_tmdb	popularidade
Count	3163	3163	3163	3163	3163
Mean	84269.33	2.58	6.60	343.54	6.25
Stdev	45503.53	3.48	1.86	1265.52	23.86
Min	6	0	0	0	0
max	308680	53	10	19778	1154.79

Tabela resumo dos Problemas e Resoluções:

Problema	Variáveis / DataSet	Resolução
Linhas duplicados	“The Oscars Award”	Remover linhas deixando apenas uma entrada por registro
Missing Values	“name”, “film” - (The Oscars Award) “description”, “age_certification”, “seasons”, “imdb_id” “imdb_score”, “imdb_votes”, “tmdb_score” - (Disney+, Netflix, Amazon) “Tmdb_popularity” - (Netflix, Amazon) “title” - (Netflix) “genre” “directors” “writers” “cast” “in_theaters_date” “on_streaming_date” “runtime_in_minutes” “studio_name” “audience_rating” “audience_count” – (Rotten Tomatoes)	Preencher com a <i>label</i> no caso da coluna ser categórica; Forçar/manter <i>Null</i> no caso de ser numérica para não enviesar cálculos
Caractéres Especiais	“Title” (Box Office)	Padronização