



Universidade do Minho
Escola de Ciências

Licenciatura em Ciência de Dados

Paradigmas de Aprendizagem Automática

Grupo 3 – PL2

Docentes:

Manuel Filipe Vieira Torres Santos

Pedro José Silva Pereira

Dean Kuijf (A106832)

Francisca Machado (A106863)

Gabriela Durães (A106858)

2024/2025

Índice

Introdução	6
Projeto 1.....	7
M1 - <i>Business Understanding + Data Understanding</i>	7
<i>Business Understanding</i> (Compreensão do Negócio)	7
Determinar os Objetivos de Negócio.....	7
Objetivos do negócio	7
Critérios de sucesso do negócio.....	7
Avaliação da Situação Atual	7
Inventário dos recursos	7
Requisitos, pressupostos e restrições	8
Riscos e contingências	8
Terminologia.....	8
Custos e benefícios	8
Determinar os Objetivos de <i>Data Mining</i>	8
Objetivos do <i>Data Mining</i>	8
Critérios de sucesso do <i>Data Mining</i>	9
Produzir o Plano do Projeto	10
Plano do Projeto.....	10
Pressuposto inicial das Ferramentas e Técnicas	10
<i>Data Understanding</i> (Compreensão dos Dados)	11
Recolha Inicial dos Dados	11
Descrição dos Dados.....	11
Exploração dos Dados	12
Verificação da Qualidade dos Dados	15
M2 – <i>Data Preparation</i>	16
<i>Data Preparation</i> (Preparação dos Dados).....	16
Seleção dos Dados	16
Construção dos Dados	17
Limpeza dos Dados.....	18
Integração dos Dados.....	19
Formatação dos Dados.....	19
Projeto 2.....	20
M3 – <i>Modeling + Evaluation + Deployment</i>	20
<i>Modeling</i> (Modelação).....	20
Seleção das Técnicas de Modelação	20
Técnicas de Modelação.....	20
Pressupostos de Modelação	20
Criação de uma Conceção de Teste.....	20
Construção do Modelo.....	21

Ajuste de Parâmetros	21
Modelos Gerados	22
Descrição dos Modelos.....	23
Revisão dos Modelos	24
Revisão dos Modelos	24
Revisão dos Parâmetros Usados	28
<i>Evaluation</i> (Avaliação)	30
Avaliação dos Resultados	30
Revisão dos Resultados de <i>Data Mining</i>	30
Modelos Aprovados	31
Revisão do Processo	35
Determinação dos Próximos Passos	35
Lista de Ações Possíveis.....	35
Decisão	35
<i>Deployment</i> (Implementação).....	36
Planeamento da Avaliação dos Resultados	36
Planeamento da Monitorização e Manutenção	36
Produção do Relatório Final	38
Relatório Final	38
Apresentação Final	39
Revisão do Projeto.....	39
Conclusão	41
Conclusão do M1 – <i>Business Understanding + Data Understanding</i>	41
Conclusão do M2 – <i>Data Preparation</i>	41
Conclusão do M3 – <i>Modeling + Evaluation + Deployment</i>	42

Índice de Figuras

Figura 1: Histograma para o preço	12
Figura 2: Histograma para o número mínimo de noites	12
Figura 3: Matriz de correlação.....	13
Figura 4: Gráfico de dispersão para o preço	13
Figura 5: <i>Boxplot</i> para o preço por bairro.....	14
Figura 6: Gráfico (<i>pairplot</i>) de correlações entre as variáveis após a construção dos dados	17
Figura 7: Gráfico (<i>pairplot</i>) de correlações entre as variáveis após a limpeza dos dados	18
Figura 8: Cenários com melhor desempenho na regressão.....	25
Figura 9: Cenários com melhor desempenho na classificação	26
Figura 10: Método do joelho	27
Figura 11: Métrica <i>Silhouette</i>	27
Figura 12: Segmentação com 2 <i>clusters</i>	27
Figura 13: Segmentação com 3 <i>clusters</i>	27
Figura 14: Cenários com melhor desempenho na regressão com ajuste de parâmetros	29
Figura 15: Cenários com melhor desempenho na classificação com ajuste de parâmetros.....	29
Figura 16: RSC - Cenário 5 (70/30).....	31
Figura 17: Curvas REC - Cenário 5 (70/30).....	31
Figura 18: RSC - Cenário 6 (70/30).....	31
Figura 19: Curvas REC - Cenário 6 (70/30).....	31
Figura 20: Matriz de confusão - Cenário 10 (10-fold).....	32
Figura 21: Curvas ROC - Cenário 10 (10-fold) - <i>High</i> vs <i>Low</i>	32
Figura 22: Curvas ROC - Cenário 10 (10-fold) - <i>High</i> vs <i>Medium</i>	32
Figura 23: Curvas ROC - Cenário 10 (10-fold) - <i>Low</i> vs <i>Medium</i>	32
Figura 24: Matriz de confusão - Cenário 9 (10-fold).....	33
Figura 25: Curvas ROC - Cenário 9 (10-fold) - <i>High</i> vs <i>Low</i>	33
Figura 26: Curvas ROC - Cenário 9 (10-fold) - <i>High</i> vs <i>Medium</i>	33
Figura 27: Curvas ROC - Cenário 9 (10-fold) - <i>Low</i> vs <i>Medium</i>	33
Figura 28: Análise e classificação de 2 <i>clusters</i>	34
Figura 29: Gráfico de dispersão de preço por número de noites para Airbnb <i>Economic</i>	34
Figura 30: Gráfico de dispersão de preço por número de noites para Airbnb <i>Premium</i>	34
Figura 31: Interface de previsão do preço dos alojamentos (regressão).....	36
Figura 32: Interface de classificação de sucesso dos anúncios (classificação).....	36
Figura 33: Interface de determinação do perfil dos alojamentos (<i>clustering</i>)	37

Índice de Tabelas

Tabela 1: Plano do Projeto	10
Tabela 2: Plano do Projeto - Tarefas genéricas	10
Tabela 3: Informações sobre as variáveis do <i>dataset</i>	11
Tabela 4: Estatísticas descritivas para <i>price</i> e <i>minimum_nights</i>	11
Tabela 5: Dimensões do <i>dataset</i>	12
Tabela 6: Valores ausentes por variável	15
Tabela 7: Distribuição de preços acima de 500\$	15
Tabela 8: Distribuição de número mínimo de noites acima de 30	15
Tabela 9: Cenários Regressão	22
Tabela 10: Cenários Classificação	22
Tabela 11: Comparação de cenários na regressão (70/30)	24
Tabela 12: Comparação de cenários na regressão (5-fold)	25
Tabela 13: Comparação de cenários na classificação (70/30)	25
Tabela 14: Comparação de cenários na classificação (10-fold)	26
Tabela 15: Comparação de cenários com ajuste de parâmetros na regressão (70/30)	28
Tabela 16: Comparação de cenários com ajuste de parâmetros na regressão (5-fold)	28
Tabela 17: Comparação de cenários com ajuste de parâmetros na classificação (70/30)	29
Tabela 18: Comparação de cenários com ajuste de parâmetros na classificação (10-fold)	29
Tabela 19: Métricas de monitorização do desempenho dos modelos	37

Introdução

No contexto deste trabalho, desenvolvido no âmbito da unidade curricular de Paradigmas de Aprendizagem Automática, será aplicado o modelo do CRIPS-DM (*Cross Industry Standard Process for Data Mining*) para analisar uma base de dados do [Kaggle](#) de alugueres de [Airbnb em Nova Iorque](#).

O objetivo do estudo é explorar e modelar os dados para responder a três desafios principais: prever o preço por noite das propriedades (regressão), classificar o sucesso dos anúncios com base na taxa de ocupação (classificação) e segmentar os imóveis em *clusters* com características semelhantes (*clustering*). Para isso, serão utilizadas técnicas de processamento de dados, modelagem preditiva e avaliação do desempenho, garantindo uma abordagem estruturada e rigorosa.

Este relatório detalhará cada fase do CRISP-DM, desde a compreensão do negócio e dos dados até à avaliação dos modelos desenvolvidos, contribuindo para a extração de *insights* relevantes para proprietários e potenciais investidores do mercado de alojamento local.

Projeto 1

M1 - *Business Understanding + Data Understanding*

Business Understanding (Compreensão do Negócio)

Determinar os Objetivos de Negócio

Objetivos do negócio

O objetivo primário do negócio passa por desenvolver um modelo de análise e previsão que permita otimizar a gestão de propriedades no Airbnb, ajudando anfitriões e investidores a maximizar receitas e ocupação.

O objetivo secundário do negócio consiste em criar um modelo de classificação para prever um indicador de sucesso (baixo, médio ou alto) considerando a taxa de ocupação anual das propriedades.

CrITÉrios de sucesso do negócio

O sucesso do projeto será avaliado com base na precisão dos modelos. O modelo de regressão deve prever o preço por noite com pelo menos 80% de precisão, enquanto o modelo de classificação deve atingir 75% de acuidade na previsão do sucesso dos anúncios. Além disso, 80% dos clientes finais devem considerar os insights valiosos para a tomada de decisões.

O projeto será classificado em diferentes níveis de sucesso:

- **sucesso total** se os modelos atingirem o objetivo estabelecidos e a satisfação dos clientes for superior a 90%;
- **bom desempenho** se a precisão estiver entre 0-20% para o NMAE e entre 70-79% para a acuidade e se a satisfação estiver dos clientes entre 75-89%;
- **aceitável**, mas com necessidade de ajustes, se a precisão estiver entre 20-30% para o NMAE e entre 60-69% para a acuidade e se a satisfação estiver dos clientes entre 60-74%;
- **insuficiente** se os resultados forem inferiores a esses valores, indicando necessidade de revisão significativa.

Desta forma, mesmo que os objetivos principais não sejam totalmente alcançados, o desempenho será avaliado dentro dos intervalos mencionados de forma a poder orientar possíveis melhorias.

Avaliação da Situação Atual

Inventário dos recursos

Pessoal – O projeto contará com técnicos do setor imobiliário, cientistas de dados, analistas de dados, técnicos de *Data Mining* e engenheiros de dados.

Dados – Será utilizada uma extração de dados relativamente recentes (2019) para análise e aplicação de melhorias. Caso seja possível, dados mais atuais serão integrados para aumentar a relevância das previsões.

Computacionais – O processamento e análise dos dados serão realizados utilizando plataformas como Python 3.13.1, R 4.3.2 e HTML.

Requisitos, pressupostos e restrições

O projeto tem um prazo final até 15 de junho de 2025. Será garantida qualidade, compreensibilidade e estruturação dos dados, assim como a conformidade com normas de segurança e proteção de dados pessoais.

Assumimos que os dados de 2019 são representativos do mercado atual. Caso seja verificado o contrário, será necessário rever e complementar a base de dados.

Não há restrições significativas quanto ao acesso aos dados, permitindo uma análise detalhada e completa.

Riscos e contingências

O projeto poderá ser comprometido por inconsistências ou falhas na qualidade dos dados que poderão ser identificadas. Caso tal aconteça, serão aplicadas técnicas para limpeza e filtragem dos dados.

Terminologia

Termos do setor imobiliário: Taxa de ocupação, rentabilidade, precificação dinâmica.

Termos de *Data Mining*: Regressão linear, *Clustering*, DM – *Data Mining*, CRISP-DM (*Cross Industry Standard Process for Data Mining*).

Custos e benefícios

A análise do custo-benefício comparará os investimentos em tecnologia e equipa necessária com os potenciais ganhos na realização do projeto.

O principal benefício esperado é a otimização dos preços e o aumento da rentabilidade das propriedades.

O sucesso do projeto será avaliado pelo impacto dos modelos que serão aplicados, medindo a melhoria na ocupação das propriedades e a otimização da precificação em relação aos valores históricos.

- estimativa de custo (máximo): $[100, 200] * 37457 = [3\ 745\ 700, 7\ 491\ 400]$ €
- estimativa de custo (potencial): 10% do máximo
- custo do projeto: 52 250 €
- eletricidade: $750 * 3 = 2250$ €
- salários: $2000 * 15 * 3 = 121\ 500$ €

Determinar os Objetivos de *Data Mining*

Objetivos do *Data Mining*

O objetivo do *Data Mining* neste projeto é extrair padrões e relações significativas a partir dos dados de propriedades do Airbnb, fornecendo *insights* úteis para anfitriões e investidores. De acordo com a metodologia **CRISP-DM**, os modelos desenvolvidos devem apoiar a tomada de decisões estratégicas e otimizar a gestão das propriedades.

➤ Regressão – Previsão do Preço por Noite

A regressão será utilizada para prever o preço por noite de um alojamento, com base em variáveis como localização, tipo de propriedade, características do imóvel e avaliações dos hóspedes. O modelo permitirá:

- Prever o preço de um imóvel de forma precisa, auxiliando anfitriões na definição de tarifas competitivas.

- Identificar fatores que impactam o valor de um alojamento, ajudando na valorização da propriedade.

➔ **Classificação – Previsão do Indicador de Sucesso**

A classificação será usada para categorizar os alojamentos em baixo, médio ou alto sucesso, com base na taxa de ocupação anual. O modelo permitirá:

- Prever se um imóvel terá uma taxa de ocupação elevada, fornecendo recomendações personalizadas para os anfitriões.
- Identificar padrões nos imóveis mais bem-sucedidos, permitindo ajustes estratégicos.
- Avaliar a interpretabilidade do modelo.

➔ **Clustering:**

O *clustering* será aplicado para agrupar propriedades com características semelhantes, permitindo entender diferentes perfis de oferta e procura. O modelo será útil para:

- Definir segmentos de mercado, como alojamentos económicos e *premium*, possibilitando uma análise mais detalhada do comportamento do mercado.
- Identificar oportunidades de investimento com base na procura e valorização de cada cluster.
- Avaliar diferentes técnicas de *clustering* (Método do Joelho, Métrica *Silhouette*, Análise por *clusters*), garantindo a melhor separação entre grupos.

Critérios de sucesso do *Data Mining*

O sucesso do projeto em termos de *Data Mining* será avaliado com base na performance técnica dos modelos desenvolvidos. Os critérios incluem métricas de precisão para os modelos preditivos e a qualidade da segmentação dos dados.

- **Modelo de Regressão:** Deve prever o preço por noite com um erro médio absoluto normalizado - $NMAE \leq 20\%$.
- **Modelo de Classificação:** Deve atingir uma acuidade mínima de 70%, além de métricas balanceadas de precisão.
- **Modelo de *Clustering*:** Deve atingir um valor de *Silhouette Score* mínimo de 0.35.

O desempenho dos modelos será classificado nos seguintes níveis:

- ➔ **sucesso total:** Se os modelos atingirem as métricas estabelecidas e forem validados positivamente pelos especialistas em dados e negócio.
- ➔ **bom desempenho:** Se a precisão estiver entre 0-20% para o NMAE e entre 70-79% para a acuidade.
- ➔ **aceitável, mas com necessidade de ajustes:** Se a precisão estiver entre 20-30% para o NMAE e entre 60-69% para a acuidade.
- ➔ **insuficiente:** Se os resultados forem inferiores a esses valores, indicando necessidade de revisão significativa dos modelos e estratégias.

Produzir o Plano do Projeto

Plano do Projeto

A Tabela 1 representa a lista de fases do projeto, com a respetiva duração, prazo de entrega e recursos requeridos. Na Tabela 2 são referidas as tarefas genéricas associadas a cada fase do projeto.

Tabela 1: Plano do Projeto

Fases do projeto	Duração	Prazo	Recursos requeridos
M1 – <i>Business Understanding</i> + <i>Data Understanding</i>	4 semanas e 3 dias	23 de março de 2025	Microsoft Word, Python 3.13.1
M2 – <i>Data Preparation</i>	5 semanas	27 de abril de 2025	Microsoft Word, Python 3.13.1, R 4.3.2
M3 – <i>Modeling</i> + <i>Evaluation</i> + <i>Deployment</i>	6 semanas	8 de junho de 2025	Microsoft Word, Python 3.13.1, HTML

Tabela 2: Plano do Projeto - Tarefas genéricas

M1 – <i>Business Understanding</i> + <i>Data Understanding</i>		M2 – <i>Data Preparation</i>	M3 – <i>Modeling</i> + <i>Evaluation</i> + <i>Deployment</i>		
<i>Business Understanding</i>	<i>Data Understanding</i>	<i>Data Preparation</i>	<i>Modeling</i>	<i>Evaluation</i>	<i>Deployment</i>
Determinar os Objetivos de Negócio	Recolha Inicial dos Dados	Seleção dos Dados	Seleção das técnicas de Modelação	Avaliação dos Resultados	Planeamento da Avaliação dos Resultados
Avaliação da Situação Atual	Descrição dos Dados	Limpeza dos Dados	Criação de uma Conceção de Teste	Revisão do Processo	Planeamento da Monitorização e Manutenção
Determinar os Objetivos de <i>Data Mining</i>	Exploração dos Dados	Construção dos Dados	Construção do(s) Modelo(s)	Determinação dos Próximos Passos	Produção do Relatório final
Produzir o Plano do Projeto	Verificação da Qualidade dos Dados	Integração dos Dados	Revisão do(s) Modelo(s)		Revisão do Projeto

Pressuposto inicial das Ferramentas e Técnicas

As ferramentas utilizadas serão Python 3.13.1, R 4.3.2 e HTML. Esta escolha inicial poderá ser ajustada conforme o desenvolvimento do projeto e desafios encontrados.

Recolha Inicial dos Dados

Através do link <https://www.kaggle.com/datasets/dgomonov/new-york-city-airbnb-open-data>, que nos remete para a plataforma *Kaggle*, obtivemos o *dataset* para este projeto, *AB_NYC_2019.csv*, que contém informações sobre alugueres do Airbnb em Nova Iorque. Os dados incluem informações sobre os anfitriões, localização, preços, tipos de quartos e disponibilidade.

Descrição dos Dados

O *dataset* possui as seguintes colunas:

- **id**: identificador do anúncio;
- **name**: nome do anúncio;
- **host_id**: identificador do anfitrião;
- **host_name**: nome do anfitrião;
- **neighbourhood_group**: grupo de bairros (ex.: Manhattan, Brooklyn);
- **neighbourhood**: bairro específico;
- **latitude** e **longitude**: coordenadas do imóvel;
- **room_type**: tipo de quarto;
- **price**: preço por noite;
- **minimum_nights**: número mínimo de noites para reserva;
- **number_of_reviews**: quantidade de avaliações;
- **last_review**: data da última avaliação;
- **reviews_per_month**: número médio de avaliações por mês;
- **calculated_host_listings_count**: quantidade de anúncios do anfitrião;
- **availability_365**: número de dias disponíveis no ano.

Tabela 3: Informações sobre as variáveis do dataset

Coluna	Não Nulos	Tipo
id	48895	int64
name	48879	object
host_id	48895	int64
host_name	48874	object
neighbourhood_group	48895	object
neighbourhood	48895	object
latitude	48895	float64
longitude	48895	float64
room_type	48895	object
price	48895	int64
minimum_nights	48895	int64
number_of_reviews	48895	int64
last_review	38843	object
reviews_per_month	38843	float64
calculated_host_listings_count	48895	int64
availability_365	48895	int64

Tabela 4: Estatísticas descritivas para price e minimum_nights

	price	minimum_nights
min	0.0	1.0
mean	152.721	7.03
max	10000.0	1250.0

A Tabela 3 apresenta as características das variáveis do *dataset*, mostrando a quantidade de valores não nulos e o tipo de cada variável. A Tabela 4 mostra as principais estatísticas descritivas das variáveis *price* e *minimum_nights*.

Exploração dos Dados

A análise inicial do *dataset* mostra (Tabela 5):

- ➔ **número de registos:** 48895;
- ➔ **número de colunas:** 16.

Tabela 5: Dimensões do dataset

Linhas	48895
Colunas	16




Figura 1: Histograma para o preço




Figura 2: Histograma para o número mínimo de noites

Os gráficos mostram:

- ➔ num limite de até 500 dólares, a maioria dos alugueres custa entre 50 e 100 dólares por noite (Figura 1);
- ➔ num limite de até 30 noites mínimas, a maioria das reservas exige entre 1 e 4 noites (Figura 2).




Figura 3: Matriz de correlação

Na Figura 3, é possível observar uma matriz de correlação, que apresenta a relação entre as diferentes variáveis associadas às propriedades do Airbnb. É possível verificar que não existe nenhuma correlação forte com o preço, sugerindo que outros fatores, não representados na matriz, podem ter maior influência sobre os valores dos alugueres.

De forma geral, a matriz indica que as variáveis analisadas têm pouca influência direta no preço, tornando necessário considerar outros fatores externos para entender melhor a precificação dos imóveis. Além disso, esta ausência de correlações fortes, indica uma vez mais que há *outliers*, que estão a ser considerados na análise, os quais podem estar a distorcer os dados.

Por outro lado, as variáveis não apresentarem fortes correlações entre si pode ser visto como um ponto positivo, uma vez que, caso contrário, estas não poderiam ser integradas nos modelos ao mesmo tempo. Pelo menos duas ou mais variáveis com forte correlação teriam de ser testadas separadamente, de forma a evitar coeficientes instáveis ou pouco interpretáveis e uma menor precisão estatística.




Figura 4: Gráfico de dispersão para o preço

Na Figura 4, podemos observar a distribuição espacial dos preços das propriedades do Airbnb em Nova Iorque, evidenciando a concentração de anúncios ao longo dos diferentes bairros da cidade. É possível verificar uma maior densidade de propriedades em Manhattan e Brooklyn, áreas tradicionalmente mais procuradas por turistas.

A escala de cores indica os preços, sendo que a maioria das propriedades apresenta valores até 2000 dólares. No entanto, algumas propriedades dispersas apresentam preços extremamente elevados, principalmente em Manhattan, onde surgem pontos em tons avermelhados, indicando valores que ultrapassam os 6000 a 10000 dólares por noite.

Este padrão reforça que Manhattan e Brooklyn tem os preços mais elevados e maior variação, enquanto outras áreas, como partes do Bronx, Queens e Staten Island, apresentam valores mais moderados e homogêneos.




Figura 5: Boxplot para o preço por bairro

Na Figura 5, é possível verificar a distribuição dos preços de alojamentos no Airbnb em Nova Iorque por bairro (Brooklyn, Manhattan, Queens, Staten Island e Bronx), num intervalo de 0 a 500 dólares (intervalo de preços de aproximadamente 98% dos alojamentos). Dos vários bairros, Manhattan destaca-se, tendo a mediana de preços mais alta, enquanto os restantes possuem valores mais baixos e semelhantes. Manhattan apresenta também a maior dispersão de preços, refletindo a diversidade de Airbnb, desde opções acessíveis até propriedades de luxo.

Os quartis revelam que os preços variam mais em Manhattan e Brooklyn, enquanto em Queens, Staten Island e Bronx a variação é menor, sugerindo maior previsibilidade.

Assim, Manhattan é o bairro mais caro e heterogêneo, enquanto Queens, Staten Island e Bronx oferecem opções mais acessíveis e estáveis. Brooklyn situa-se numa faixa intermediária.

Verificação da Qualidade dos Dados

A análise inicial do *dataset* mostra:

➔ **dados ausentes:** a coluna *name* tem 16 valores ausentes, *host_name* tem 21, *last_name* e *reviews_per_month* têm 10052 valores ausentes (Tabela 6);

➔ **valores extremos:** o preço varia entre 0 e 10000 dólares por noite (Tabela 7); o número de noites mínimas chega a 1250 (Tabela 8).

Tabela 6: Valores ausentes por variável

Coluna	Valores Ausentes
id	0
name	16
host_id	0
host_name	21
neighbourhood_group	0
neighbourhood	0
latitude	0
longitude	0
room_type	0
price	0
minimum_nights	0
number_of_reviews	0
last_review	10052
reviews_per_month	10052
calculated_host_listings_count	0
availability_365	0

Tabela 7: Distribuição de preços acima de 500\$

Intervalo de Preço	Quantidade
500-2000	934
2000-4000	75
4000-6000	17
6000-8000	10
8000-10000	8

Tabela 8: Distribuição de número mínimo de noites acima de 30

Intervalo de Noites	Quantidade
30-180	623
180-365	81
365-730	38
730-1095	4
1095-1250	1

A Tabela 6 mostra quantos valores ausentes existem para cada variável. Apenas as variáveis *name*, *host_name*, *last_review* e *reviews_per_month* têm valores nulos, no entanto, estas variáveis não serão as mais relevantes para a análise de dados, pelo que as linhas envolvidas serão tratadas corretamente.

As Tabelas 7 e 8 mostram valores extremos para o preço e para o número mínimo de noites, respetivamente. Os valores registados nas tabelas são *outliers* e poderão representar exceções ou erros nos dados. Por exemplo, um aluguer custar acima de 500 dólares por noite, pode indicar que o Airbnb em questão tem características mais luxuosas que justifiquem um valor mais elevado, porém, um aluguer entre 4000 e 10000 dólares poderá ser excessivo e aumenta a complexidade dos dados, podendo dificultar a aprendizagem na parte da modelação. Para além disso, uma reserva com exigência acima de 30 noites mínimas, mais de 1 mês, representa uma exceção, no entanto, haver uma reserva de 1250 noites mínimas, ou seja, quase 4 anos, parece bastante anómalo. Assim, numa fase posterior, serão exploradas diferentes abordagens para lidar com estes *outliers*, como a sua remoção ou transformação, de forma a minimizar impactos negativos na modelagem e garantir a robustez dos resultados finais.

Data Preparation (Preparação dos Dados)

Seleção dos Dados

O *dataset* inicial, continha algumas colunas que não acrescentavam informações relevantes. Sendo assim, optou-se por proceder à remoção das mesmas. As entidades *name* e *host_name*, foram eliminadas, uma vez que estas não influenciam nos resultados obtidos. Além disso, também foi excluída a coluna *last_review*, pois, além de não ser relevante, apresentavam uma quantidade elevada de valores nulos, correspondendo, aproximadamente, a 20% dos dados.

Tendo em conta as alterações realizadas, o *dataset* passou a ter 13 colunas, sendo elas: *id*, *host_id*, *neighbourhood_group*, *neighbourhood*, *latitude*, *longitude*, *room_type*, *price*, *minimum_nights*, *number_of_reviews*, *reviews_per_month*, *calculated_host_listing_counts*, *availability_365*. Com isto, obteve-se um *dataset* apenas com valores nulos na variável *reviews_per_month*, os quais serão tratados posteriormente.

Construção dos Dados

Nesta fase, a coluna *reviews_per_month* foi atualizada, substituindo-se os valores omissos por '0', dado que a ausência de informação apenas ocorria quando não existiam avaliações atribuídas para o Airbnb.

Além disso, procedeu-se à transformação da variável categórica *room_type*, de forma a representar melhor os dados.

Para isso, a variável foi transformada usando a abordagem *One-Hot Encoding*, que cria uma nova coluna para cada uma das três categorias existentes, atribuindo valores binários (0 ou 1) conforme a categoria correspondente.

A construção dos dados foi realizada antes da limpeza dos dados, uma vez que as novas variáveis criadas permitiam uma melhor identificação de padrões, *outliers* e inconsistências presentes nos dados originais, que poderiam não ser evidentes numa fase inicial, contribuindo para uma limpeza mais eficaz e orientada.




Figura 6: Gráfico (pairplot) de correlações entre as variáveis após a construção dos dados

Após a construção das variáveis *dummies* para o tipo de alojamento (*room_type*), foi possível observar com maior clareza a relação entre estas categorias e outras variáveis numéricas, como o preço (*price*), o número mínimo de noites (*minimum_nights*) e a disponibilidade anual (*availability_365*). O *pairplot* da Figura 6 permite visualizar de forma intuitiva as distribuições e correlações entre variáveis, separadas por grupo de bairro (*neighbourhood_group*).

A inclusão das variáveis *room_type Entire home/apt*, *room_type Private room* e *room_type Shared room* revelou-se essencial para compreender o comportamento dos dados e orientar etapas posteriores do processo, como a limpeza de dados, uma vez que se tornou perceptível a concentração de preços e de número mínimo de noites para cada tipo de quarto.

Limpeza dos Dados

Para proceder à limpeza dos dados, foram removidos *outliers*, de forma a garantir melhores resultados nos modelos.

Para a deteção de *outliers*, foram aplicados em R dois algoritmos às variáveis *price* e *minimum_nights*, são eles o Critério usando Percentis e o método *Z-scores*. Para a variável *price*, o Critério dos Percentis identificou 2008 *outliers*, considerando apenas como valores aceitáveis os que se encontravam entre 35 e 500 dólares por noite. Já o método *Z-scores* considerou como válidos valores entre 0 e 935 dólares, identificando, no total, 349 *outliers*. Já para a variável *minimum_nights*, o Critério dos Percentis identificou os valores de 1 a 30 noites aceitáveis, resultando na identificação de 747 *outliers*. Com o algoritmo *Z-scores*, o intervalo considerado foi maior, sendo de 1 a 74 noites mínimas, detetando assim 318 *outliers*.

Apesar da análise estatística, considerou-se que os limites definidos por estes algoritmos estavam a identificar como *outliers* alguns valores que poderiam corresponder a dados reais e importantes para a análise. Por esse motivo, decidimos definir manualmente os intervalos de valores considerados plausíveis. Para a variável *price*, consideraram-se valores entre 10 e 3000 dólares por noite, enquanto para a variável *minimum_nights*, os valores considerados foram entre 1 e 200 noites mínimas, eliminando-se registos que apresentassem valores fora desses intervalos.



Figura 7: Gráfico (pairplot) de correlações entre as variáveis após a limpeza dos dados

O *pairplot* da Figura 7, obtido após a limpeza dos dados, apresenta uma distribuição mais coerente e realista das variáveis, com menor presença de *outliers* nas variáveis *price* e *minimum_nights*. Esta melhoria na qualidade dos dados permitiu uma visualização mais clara das relações entre variáveis e uma melhor distinção entre os grupos de bairros (*neighbourhood_group*), mantendo a divisão por tipo de alojamento (*room_type*).

Com a remoção de dados inconsistentes ou invulgares, as densidades tornaram-se mais informativas e representativas do comportamento típico das ofertas de alojamento na cidade de Nova Iorque.

Comparando com o gráfico anterior, é evidente a redução da dispersão excessiva e de padrões ruidosos. No primeiro gráfico, a presença de valores anómalos dificultava a identificação de tendências claras e distorcia a relação entre as variáveis. Já neste segundo gráfico, essas relações tornam-se mais visíveis, o que contribui para análises futuras mais fiáveis e para a construção de modelos preditivos mais robustos.

A sequência de construção seguida pela limpeza revelou-se eficaz, uma vez que permitiu criar variáveis úteis e, em seguida, refinar o conjunto de dados com base nessas mesmas variáveis.

Integração dos Dados

De forma a enriquecer a base de dados, foi incorporada uma nova fonte de dados proveniente do ficheiro `crimes.csv`, disponível na página web [NYCOpenData](#). Este conjunto de dados contém informações detalhadas sobre as ocorrências criminais registadas na cidade de Nova Iorque durante um ano, segmentadas por bairro.

Para possibilitar a integração com a base de dados tratada, foi realizada uma limpeza dos dados, com eliminação de entradas inválidas ou irrelevantes, e foi calculada a frequência de crimes por bairro, agora segmentada por gravidade: crimes leves (*minor_crimes*), moderados (*moderate_crimes*) e graves (*serious_crimes*).

Estes dados foram posteriormente combinados com o *dataset* do *Airbnb* com base na coluna *neighbourhood_group*, comum a ambos os ficheiros. Esta integração permite uma análise mais aprofundada sobre possíveis correlações entre o nível e tipo de criminalidade nas diferentes zonas da cidade e variáveis como o preço, a procura e a disponibilidade dos alojamentos.

Complementarmente a esta integração socioespacial, procurou-se também incorporar a dimensão turística da cidade, com o objetivo de avaliar o impacto da proximidade a atrações em variáveis como o preço e a atratividade das propriedades.

Com esse propósito, foi realizada uma integração com dados geográficos de atrações turísticas populares em Nova Iorque. As atrações foram organizadas por *neighbourhood_group* (Manhattan, Brooklyn, Queens, Bronx e Staten Island) e associadas a coordenadas geográficas específicas.

A partir disso, para cada Airbnb da base de dados tratada, foi calculada a distância, em linha reta, até cada uma das atrações localizadas no mesmo bairro. Esses cálculos permitiram quantificar a proximidade (em quilómetros) de cada alojamento em relação aos pontos turísticos, o que permitiu criar uma nova variável que indica o número de atrações turísticas situadas num raio de até 2 km da propriedade. Estes dados fornecem, assim, um indicador de acessibilidade a atrações turísticas. Essa integração visa contribuir para análises mais robustas no que diz respeito à localização dos imóveis e ao seu potencial de interesse turístico.

Finalmente, todas estas informações acrescentadas, tanto dos dados de crimes como das atrações turísticas, foram consolidadas num único ficheiro CSV denominado `Airbnb_NYC_2019_VF`, que contém o *dataset* completo e enriquecido, pronto para análise.

Formatação dos Dados

Nesta fase, procedeu-se à transformação de variáveis categóricas em numéricas, de forma a garantir a sua correta utilização posteriormente nos modelos.

As colunas modificadas foram *neighbourhood_group* e *neighbourhood*, tendo sido utilizada a abordagem *Inverse Document Frequency* (IDF) para as transformar, que atribui menor peso às categorias mais frequentes e maior peso às menos frequentes. Assim, cada categoria foi substituída pelo seu peso IDF calculado com base na sua frequência no conjunto de dados, sendo que, quanto mais próximo de 0 for o valor, mais frequente é a categoria.

Projeto 2

M3 – *Modeling + Evaluation + Deployment*

Modeling (Modelação)

Seleção das Técnicas de Modelação

Técnicas de Modelação

Nesta fase do projeto, procedeu-se à seleção de técnicas de modelação mais adequadas aos objetivos definidos, tendo em conta a natureza dos dados e o tipo de problemas a resolver, nomeadamente tarefas de regressão e classificação. Optou-se por utilizar duas abordagens principais (técnicas supervisionadas):

1. **Árvores de Decisão** – Foram escolhidas por se tratar de modelos altamente interpretáveis, permitindo uma fácil compreensão, o que é crucial em contextos de tomada de decisão. A sua capacidade de lidar com variáveis categóricas e numéricas, bem como a facilidade de visualização das regras de decisão, foram também fatores determinantes na escolha.
2. **Redes Neurais** – Estas foram selecionadas pela sua elevada capacidade de generalização e performance em problemas complexos, especialmente quando há grande quantidade de dados e padrões não-lineares difíceis de captar com modelos mais simples. A sua utilização visou aumentar a robustez e a precisão das previsões.

Para a tarefa de *clustering*, foi utilizada uma técnica não supervisionada, a técnica de *K-Means*, pela sua simplicidade e interpretabilidade.

Pressupostos de Modelação

Cada técnica escolhida possui pressupostos implícitos. No caso das redes neurais pressupõem-se que os dados estejam normalizados e sensíveis à escala das variáveis, enquanto as árvores de decisão não requerem normalização. Assumiu-se também a existência de relações não lineares entre variáveis explicativas e a variável alvo, justificando a escolha de modelos mais complexos como as redes neurais.

O *K-Means* exige que se defina previamente o número de *clusters*, o que foi feito com apoio do Método do Joelho e da Métrica *Silhouette*.

Criação de uma Conceção de Teste

De forma a garantir uma avaliação objetiva dos modelos, foi definida tanto para a regressão como para a classificação a técnica de *holdout*, onde 70% dos dados são para treino e os restantes 30% para teste. Usou-se ainda o *k-fold*, uma técnica de *cross-validation* que evita *overfitting*, para avaliar a estabilidade e robustez dos modelos, onde atribuímos a *k* o valor 5 ou 10.

As métricas selecionadas para avaliação do modelo foram:

- Regressão: *Mean Absolute Error* (MAE), *Normalized Mean Absolute Error* (NMAE) e *Root Mean Squared Error* (RMSE).
- Classificação: Acuidade (*accuracy*), Precisão (*precision*), Sensibilidade (*recall*) e *F1-Score*.

Para visualização, os métodos selecionados foram:

- ➔ Regressão: RSC (*Regression Scatter Plot*), curva de REC (*Regression Error Characteristic*) e AUC (*Area Under the REC Curve*).
- ➔ Classificação: Curva de ROC (*Receiver Operating Characteristic*) e AUC (*Area Under the ROC Curve*).

Como o *clustering* é uma técnica não supervisionada, não requer divisão treino/teste. Para avaliação do modelo foi usada a métrica de avaliação *Silhouette Score*, que estima a qualidade da separação entre clusters e ajuda na escolha do número ideal de grupos.

Construção do Modelo

Ajuste de Parâmetros

Foram definidos inicialmente alguns parâmetros. Tanto para a classificação como para a regressão os parâmetros definidos para as árvores de decisão e para as redes neurais foram os mesmos.

Árvores de Decisão:

- ➔ `max_depth=500`, que permite que a árvore capture relações complexas nos dados, evitando *underfitting*;
- ➔ `random_state=42`, que garante reprodutibilidade, fixando a aleatoriedade para que os resultados sejam consistentes em diferentes execuções.

Redes Neurais:

- ➔ `hidden_layer_sizes=[10, 5, 2]`, a qual é uma arquitetura com três camadas ocultas que equilibram a capacidade de aprendizagem e risco de *overfitting*;
- ➔ `max_iter=10000`, que permite que sejam executadas iterações suficientes para convergir, durante o treino, especialmente útil em dados complexos.
- ➔ `random_state=42`, o qual mantém a reprodutibilidade dos pesos iniciais e do processo de treino.

Cross Validation (k-fold):

Classificação (k=10) – um maior número de *folds* aumenta a robustez da avaliação. K=10 é por norma o valor mais usado.

Regressão (k=5) – redução para 5 *folds* devido a restrições computacionais (tempo de execução excedeu 8 horas com k=10), mantendo equilíbrio entre precisão e eficiência.

K-Means:

- ➔ K=2 – com base nos resultados do Método do Joelho e da Métrica *Silhouette*, concluiu-se que este número de *clusters* era a melhor escolha.

Modelos Gerados

Os modelos gerados variam por cenário e técnica. Cada cenário representa um conjunto distinto de variáveis explicativas.

Cenários de Regressão:

Tabela 9: Cenários Regressão

Cenários	Variável dependente	Variáveis Explicativas
Cenário 1	<i>price</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood_group
Cenário 2	<i>price</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood_group + number_of_reviews
Cenário 3	<i>price</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood_group + number_of_reviews + availability_365 + minimum_nights
Cenário 4	<i>price</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood_group + number_of_reviews + availability_365 + minimum_nights + serious_crimes
Cenário 5	<i>price</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood_group + number_of_reviews + availability_365 + minimum_nights + serious_crimes + attractions
Cenário 6	<i>price</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood_group + number_of_reviews + availability_365 + minimum_nights + attractions
Cenário 7	<i>price</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood_group + number_of_reviews + availability_365 + minimum_nights + attractions + availability_365 * minimum_nights
Cenário 8	<i>price</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood
Cenário 9	<i>price</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood + number_of_reviews + availability_365 + minimum_nights + attractions
Cenário 10	<i>price</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood + minimum_nights

Cenários de Classificação:

Tabela 10: Cenários Classificação

Cenários	Variável dependente	Variáveis Explicativas
Cenário 1	<i>success</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood_group + price
Cenário 2	<i>success</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood_group + price + minimum_nights
Cenário 3	<i>success</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood_group + price + number_of_reviews + attractions
Cenário 4	<i>success</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood + price
Cenário 5	<i>success</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood_group + price + number_of_reviews + attractions + neighbourhood_group * attractions
Cenário 6	<i>success</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood_group + price + number_of_reviews + attractions + neighbourhood_group * number_of_reviews + neighbourhood_group * attractions
Cenário 7	<i>success</i>	room_type_Entire.home.apartment + room_type_Private.room + room_type_Shared.room + neighbourhood + price + number_of_reviews + attractions

Cenário 8	<i>success</i>	room_type_Entire.home.appt + room_type_Private.room + room_type_Shared.room + neighbourhood + price + minimum_nights
Cenário 9	<i>success</i>	room_type_Entire.home.appt + room_type_Private.room + room_type_Shared.room + neighbourhood + price + number_of_reviews + attractions + neighbourhood * attractions
Cenário 10	<i>success</i>	room_type_Entire.home.appt + room_type_Private.room + room_type_Shared.room + neighbourhood + price + minimum_nights + neighbourhood * minimum_nights

As Tabelas 9 e 10 apresentam os cenários finais selecionados para regressão e classificação, respetivamente, resultantes de um extenso processo de modelagem. Para desenvolver estes modelos, aplicaram-se sistematicamente os algoritmos de árvore de decisão e rede neuronal sobre o conjunto de dados preparado, testando diversos cenários.

Inicialmente, foram exploradas diferentes abordagens, incluindo transformações matemáticas como a aplicação de logaritmo na variável dependente, várias combinações de variáveis explicativas e interações estratégicas entre preditores.

Durante este processo, identificou-se que algumas abordagens não traziam ganhos de performance. Após uma avaliação rigorosa, selecionou-se os 10 cenários para cada tipo de problema, tendo como referência métricas de avaliação mais relevantes para a regressão e classificação

A versão final dos modelos incorpora apenas as combinações que demonstraram melhor desempenho preditivo. Esta seleção final representa o equilíbrio ideal entre complexidade do modelo e capacidade explicativa, proporcionando bases sólidas para a fase de avaliação que se segue.

Para o *clustering*, foi gerado um modelo com 2 *clusters* e outro com 3 *clusters*.

Descrição dos Modelos

Modelos de Regressão:

Os modelos de regressão foram desenvolvidos com o objetivo de prever o valor do preço dos alojamentos com base em variáveis explicativas selecionadas. Para esse efeito, foram considerados 10 cenários distintos, nos quais a variável independente era o preço (*price*) e se testaram diferentes combinações de variáveis explicativas. Entre as mais relevantes, destacam-se: o tipo de quarto (*room_type*), o bairro (*neighbourhood_group*), o número de avaliações (*number_of_reviews*), a disponibilidade anual (*availability_365*), o número mínimo de noites (*minimum_nights*), a presença de atrações turísticas próximas (*attractions*) e a taxa de crimes graves na zona (*serious_crimes*).

Adicionalmente, foi introduzida uma variável de interação (*interaction*), calculada como o produto entre *availability_365* e *minimum_nights*, com o objetivo de capturar possíveis relações não lineares entre a disponibilidade e o tempo mínimo de estadia.

A avaliação dos diferentes cenários foi realizada com base em métricas de desempenho como o Erro Quadrático Médio (MSE), a Raiz do Erro Quadrático Médio (RMSE) e o Erro Absoluto Médio Normalizado (NMAE), permitindo comparar a eficácia dos modelos em termos de precisão preditiva.

Modelos de Classificação:

No caso dos modelos de classificação, foram igualmente definidos 10 cenários distintos, com diferentes combinações de atributos, usando como variável independente o sucesso (*success*), variável categórica que foi obtida com base na disponibilidade (*availability_365*). Tal como nos modelos de regressão, foram consideradas variáveis como *room_type*, *neighbourhood* ou *neighbourhood_group*, *price*, *number_of_reviews* e *attractions*. Além disso, foram incluídas variáveis de interação, nomeadamente:

- *interaction1*: produto entre *neighbourhood_group* e *number_of_reviews*;

- *interaction2*: produto entre *neighbourhood_group* e *attractions*;
- *interaction3*: produto entre *neighbourhood* e *minimum_nights*;
- *interaction4*: produto entre *neighbourhood* e *attractions*.

Estas variáveis adicionais foram introduzidas com o intuito de capturar efeitos cruzados entre a localização e outras características relevantes dos alojamentos.

A performance dos modelos foi avaliada com base em métricas de classificação como *accuracy*, *precision*, *recall* e *F1-Score*. Em cenários que incluíam variáveis de interação, observou-se uma alteração no comportamento discriminativo dos modelos, com impacto variável na sua capacidade de distinguir entre as diferentes classes.

Modelo de Clustering:

Os modelos de *clustering* foram desenvolvidos com o objetivo de distinguir segmentos principais de imóveis. Cada modelo foi gerado com um certo número de clusters, com base nos resultados obtidos pelo Método do Joelho e pela Métrica *Silhouette*.

Revisão dos Modelos

Revisão dos Modelos

Após a construção e avaliação de múltiplos modelos de regressão e de classificação, com base em diferentes cenários de variáveis explicativas, realizou-se uma análise aprofundada comparando o desempenho entre as duas técnicas: árvores de decisão e redes neurais, obtendo-se as Tabelas 11, 12, 13 e 14 que compara as diferentes métricas nas diferentes técnicas e cenários.

Os resultados obtidos para os modelos de regressão (Tabelas 11 e 12) apresentam padrões interessantes quando comparamos as duas abordagens de validação (70/30 e 5-fold). As redes neurais demonstraram melhor desempenho que as árvores de decisão na maioria dos cenários.

Os melhores resultados foram alcançados nos Cenários 5 e 6 com redes neurais, que mantiveram NMAE próximo de 2.1% em ambas as validações. Estes cenários incluíam variáveis de criminalidade e atrações turísticas, sugerindo que estes fatores têm significativa influência na precisão da previsão de preços.

As árvores de decisão mostraram maior variabilidade nos resultados, com desempenho significativamente pior nos cenários 3 a 7 (NMAE entre 2.62-2.65%), mas excelente performance nos cenários 8 e 10 (NMAE ~2.1%). Esta discrepância indica que as árvores são mais sensíveis à seleção de variáveis explicativas.

Tabela 11: Comparação de cenários na regressão (70/30)

Scenario	Decision Tree MAE	Decision Tree NMAE (%)	Decision Tree RMSE	Neural Network MAE	Neural Network NMAE (%)	Neural Network RMSE
Scenario 1	65.94	2.21	146.37	65.59	2.19	146.39
Scenario 2	67.15	2.25	146.48	67.07	2.24	145.66
Scenario 3	79.08	2.64	177.77	67.05	2.24	144.26
Scenario 4	79.13	2.65	177.37	65.19	2.18	144.97
Scenario 5	80.07	2.68	181.2	61.72	2.06	142.64
Scenario 6	79.75	2.67	181.1	62.34	2.08	141.96
Scenario 7	79.14	2.65	180.11	68.06	2.28	145.64
Scenario 8	63.03	2.11	142.87	68.6	2.29	149.37
Scenario 9	78.31	2.62	180.88	63.11	2.11	142.75
Scenario 10	64.22	2.15	147.39	68.69	2.3	149.12

Tabela 12: Comparação de cenários na regressão (5-fold)

Scenario	Decision Tree (CV) MAE	Decision Tree (CV) NMAE (%)	Decision Tree (CV) RMSE	Neural Network (CV) MAE	Neural Network (CV) NMAE (%)	Neural Network (CV) RMSE
Scenario 1	65.42	2.19	142.46	65.65	2.2	142.48
Scenario 2	66.24	2.22	142.42	65.62	2.19	141.83
Scenario 3	78.76	2.63	174.85	66.08	2.21	140.31
Scenario 4	78.72	2.63	174.9	63.99	2.14	141.03
Scenario 5	79.17	2.65	181.54	62.58	2.09	139.13
Scenario 6	79.09	2.65	181.14	64.43	2.15	137.97
Scenario 7	78.19	2.62	174.35	66.81	2.23	141.12
Scenario 8	62.25	2.08	139.06	68.73	2.3	145.46
Scenario 9	77.37	2.59	179.45	65.2	2.18	138.74
Scenario 10	63.45	2.12	144.47	68.69	2.3	145.16

Estes resultados sugerem que para a maioria dos casos, as redes neurais oferecem previsões mais precisas e consistentes, enquanto as árvores de decisão podem ser preferíveis em cenários específicos com determinadas combinações de variáveis. A robustez dos modelos foi confirmada pela pequena variação entre os métodos de validação (70/30 vs. 5-fold), com diferenças médias inferiores a 0.1% no NMAE.

Os cenários que obtiveram melhores desempenhos foram os apresentados na Figura 8.

Best scenarios:
Scenario 5 - Neural Network
Scenario 6 - Neural Network

Figura 8: Cenários com melhor desempenho na regressão

Os resultados dos modelos de classificação (Tabelas 13 e 14) revelam diferenças significativas entre as abordagens de árvore de decisão e rede neuronal, bem como entre os métodos de validação (70/30 vs. 10-fold). As árvores de decisão demonstraram desempenho consistentemente superior em todos os cenários, com melhoria progressiva à medida que se adicionavam interações entre variáveis.

Tabela 13: Comparação de cenários na classificação (70/30)

Scenario	Decision Tree Accuracy	Decision Tree Recall	Decision Tree Precision	Decision Tree F1-score	Neural Network Accuracy	Neural Network Recall	Neural Network Precision	Neural Network F1-score
Scenario 1	0.531	0.531	0.518	0.518	0.411	0.411	0.406	0.407
Scenario 2	0.662	0.662	0.649	0.65	0.457	0.457	0.449	0.438
Scenario 3	0.718	0.718	0.706	0.71	0.391	0.391	0.412	0.384
Scenario 4	0.692	0.692	0.679	0.682	0.414	0.414	0.407	0.404
Scenario 5	0.715	0.715	0.703	0.707	0.333	0.333	0.111	0.167
Scenario 6	0.71	0.71	0.699	0.703	0.384	0.384	0.38	0.312
Scenario 7	0.728	0.728	0.717	0.721	0.394	0.394	0.408	0.379
Scenario 8	0.735	0.735	0.726	0.729	0.458	0.458	0.458	0.439
Scenario 9	0.738	0.738	0.728	0.732	0.337	0.337	0.265	0.182
Scenario 10	0.742	0.742	0.733	0.736	0.453	0.453	0.451	0.439

Tabela 14: Comparação de cenários na classificação (10-fold)

Scenario	Decision Tree (CV) Accuracy	Decision Tree (CV) Recall	Decision Tree (CV) Precision	Decision Tree (CV) F1-score	Neural Network (CV) Accuracy	Neural Network (CV) Recall	Neural Network (CV) Precision	Neural Network (CV) F1-score
Scenario 1	0.542	0.542	0.531	0.528	0.409	0.409	0.406	0.392
Scenario 2	0.67	0.67	0.659	0.657	0.445	0.445	0.437	0.413
Scenario 3	0.743	0.743	0.734	0.737	0.413	0.413	0.421	0.398
Scenario 4	0.7	0.7	0.689	0.69	0.399	0.399	0.402	0.38
Scenario 5	0.739	0.739	0.73	0.733	0.334	0.334	0.253	0.169
Scenario 6	0.739	0.739	0.73	0.732	0.389	0.389	0.41	0.308
Scenario 7	0.757	0.757	0.75	0.753	0.417	0.417	0.409	0.385
Scenario 8	0.759	0.759	0.752	0.753	0.406	0.406	0.333	0.334
Scenario 9	0.759	0.759	0.753	0.755	0.346	0.346	0.28	0.202
Scenario 10	0.763	0.763	0.757	0.758	0.454	0.454	0.453	0.44

Desempenho geral:

- Árvores de decisão alcançaram acuidade entre 53.1%-76.3%, com melhor performance nos cenários mais complexos (Cenários 8 a 10)
- Redes neurais mostraram resultados mais modestos (33.4%-45.8%), com variações significativas entre cenários
- A validação cruzada (10-fold) confirmou a robustez das árvores, com melhoria média de 2-3% nas métricas

Os cenários que obtiveram melhores desempenhos foram os apresentados na Figura 9.

Best scenarios:
 Scenario 10 - Decision Tree (CV)
 Scenario 9 - Decision Tree (CV)

Figura 9: Cenários com melhor desempenho na classificação

Esta análise confirma a superioridade das árvores de decisão para esta tarefa específica de classificação, particularmente em cenários que incorporam relações geográficas e de preço.

De forma geral, os resultados demonstram que as árvores de decisão são mais eficazes para classificação, enquanto as redes neurais se destacam na regressão. Ambos os modelos revelaram padrões importantes: relações não-lineares entre localização e preços.

As principais limitações identificadas incluem sensibilidade a valores extremos (especialmente na previsão de preços) e instabilidade das redes neurais em certos cenários de classificação. As árvores mostraram melhor robustez, mas com risco de *overfitting* em profundidades maiores.

Para a classificação, o desequilíbrio de classes exigiu técnicas de balanceamento, enquanto na regressão, a qualidade das previsões variou significativamente conforme as interações entre variáveis incluídas.

Através do *clustering*, procedeu-se à identificação de possíveis padrões no conjunto de dados. O objetivo era explorar a existência de possíveis grupos nos dados, aprofundando a compreensão da distribuição e características das diferentes ofertas de Airbnb. Para tal, foram utilizadas as variáveis *price* e *minimum_nights*.




Figura 10: Método do joelho




Figura 11: Métrica Silhouette

Inicialmente, recorreu-se ao Método do Joelho para estimar o número ideal de *clusters*. A análise indicou que os valores mais plausíveis seriam 3, 4 ou 5 *clusters*, conforme apresentado na Figura 10.

Para reforçar esta análise, utilizou-se também a Métrica *Silhouette*, cuja avaliação apontou que a opção com 2 *clusters* apresentava o melhor valor de *Silhouette* (mais próximo de 1), tal é possível observar na Figura 11.

Por fim, foram criadas análises específicas para 2 e 3 *clusters*, cujos resultados podem ser observados nas Figuras 10 e 11, respetivamente. Na Figura 12, é possível observar uma distribuição densa em torno de preços baixos (abaixo de 500) e número baixo de noites mínimas (inferior a 30). Na Figura 13, o aumento do número de *clusters* gera uma segmentação mais detalhada.




Figura 12: Segmentação com 2 clusters




Figura 13: Segmentação com 3 clusters

Há alguns pontos mais dispersos, que representam alojamentos com preços elevados ou exigências mínimas de estadia muito altas. Em ambos os gráficos, a maior parte das ofertas está concentrada em preços baixos e requisitos baixos de noites mínimas, o que sugere um mercado predominantemente acessível e flexível. Há também algumas ofertas com preços elevados que representam imóveis com extras (*premium*) e há ofertas destinadas a estadias prolongadas.

Analisando a [Figura 7](#), não se evidenciam separações claras ou agrupamentos visivelmente distintos entre os dados, considerando a relação da variável *price* com as restantes. Desta forma, conclui-se que é possível identificar *clusters* diferenciados de forma visual, o que permite segmentar as propriedades em função do preço.

Revisão dos Parâmetros Usados

Após uma análise detalhada dos resultados iniciais, procedeu-se ao ajuste e refinamento dos parâmetros dos modelos de *machine learning*. Para a rede neuronal, testamos várias configurações de camadas ocultas, incluindo estruturas mais complexas como [128, 64, 32, 16, 8] com 1000 iterações e configurações mais simples como [6, 3] com 300 iterações. No entanto, a configuração original [10, 5, 2] mas com 900 iterações, manteve-se como a mais eficaz, demonstrando um equilíbrio ideal entre desempenho e eficiência computacional. Esta configuração apresentou tempos de treino mais rápidos e resultados mais estáveis em comparação com as alternativas testadas, tanto para a regressão como para a classificação.

No caso das árvores de decisão, explorámos diferentes valores para a profundidade máxima (*max_depth*), testando valores entre 10 e 500. No caso da regressão, verificámos que profundidades muito baixas (como 10) levavam a *underfitting*, enquanto valores muito altos (superiores a 50) resultavam em *overfitting*. A profundidade de 12 revelou-se o ponto ideal, oferecendo um bom equilíbrio entre capacidade de generalização e precisão, com uma diferença controlada entre os resultados de treino e teste. Já para a classificação, valores até aos 20 de profundidade resultavam sempre em *underfitting*, e a partir dos 40, uma estabilidade nos resultados, sendo por isso essa a escolha final.

Com este processo iterativo, foram obtidos novos resultados nas diferentes métricas de avaliação para a regressão e para a classificação, apresentados nas Tabelas 15, 16, 17 e 18, e averiguados os melhores cenários, apresentados nas Figuras 14 e 15. Este processo de ajuste permitiu melhorar significativamente a qualidade dos nossos modelos, garantindo que se alcançou a melhor combinação possível entre desempenho preditivo e robustez.

Tabela 15: Comparação de cenários com ajuste de parâmetros na regressão (70/30)

Scenario	Decision Tree MAE	Decision Tree NMAE (%)	Decision Tree RMSE	Neural Network MAE	Neural Network NMAE (%)	Neural Network RMSE
Scenario 1	65.94	2.21	146.37	65.59	2.19	146.39
Scenario 2	66.49	2.22	146.05	67.07	2.24	145.66
Scenario 3	67.34	2.25	159.66	67.05	2.24	144.26
Scenario 4	67.26	2.25	159.87	65.19	2.18	144.97
Scenario 5	67.83	2.27	164.64	61.72	2.06	142.64
Scenario 6	66.99	2.24	161.08	62.34	2.08	141.96
Scenario 7	67.14	2.25	160.84	68.06	2.28	145.64
Scenario 8	63.44	2.12	143.21	68.6	2.29	149.37
Scenario 9	65.88	2.2	163.45	63.11	2.11	142.75
Scenario 10	64.61	2.16	147.45	68.69	2.3	149.12

Tabela 16: Comparação de cenários com ajuste de parâmetros na regressão (5-fold)

Scenario	Decision Tree (CV) MAE	Decision Tree (CV) NMAE (%)	Decision Tree (CV) RMSE	Neural Network (CV) MAE	Neural Network (CV) NMAE (%)	Neural Network (CV) RMSE
Scenario 1	65.42	2.19	142.46	65.65	2.2	142.48
Scenario 2	65.77	2.2	142.14	65.62	2.19	141.83
Scenario 3	65.85	2.2	154.1	66.08	2.21	140.31
Scenario 4	66.12	2.21	155.26	63.99	2.14	141.03
Scenario 5	65.2	2.18	155.95	62.43	2.09	140.29
Scenario 6	65.42	2.19	157.09	64.43	2.15	137.97
Scenario 7	65.91	2.2	155.27	66.81	2.23	141.12
Scenario 8	62.72	2.1	139.48	68.73	2.3	145.46
Scenario 9	64.71	2.16	159.5	65.2	2.18	138.74
Scenario 10	63.65	2.13	144.18	68.69	2.3	145.16

Best cenários:
Scenario 5 - Neural Network
Scenario 6 - Neural Network

Figura 14: Cenários com melhor desempenho na regressão com ajuste de parâmetros

Tabela 17: Comparação de cenários com ajuste de parâmetros na classificação (70/30)

Scenario	Decision Tree Accuracy	Decision Tree Recall	Decision Tree Precision	Decision Tree F1-score	Neural Network Accuracy	Neural Network Recall	Neural Network Precision	Neural Network F1-score
Scenario 1	0.531	0.531	0.518	0.518	0.411	0.411	0.406	0.407
Scenario 2	0.662	0.662	0.649	0.65	0.457	0.457	0.449	0.438
Scenario 3	0.718	0.718	0.706	0.71	0.391	0.391	0.412	0.384
Scenario 4	0.692	0.692	0.679	0.682	0.414	0.414	0.407	0.404
Scenario 5	0.715	0.715	0.703	0.707	0.333	0.333	0.111	0.167
Scenario 6	0.71	0.71	0.699	0.703	0.384	0.384	0.38	0.312
Scenario 7	0.728	0.728	0.717	0.721	0.394	0.394	0.408	0.379
Scenario 8	0.735	0.735	0.726	0.729	0.458	0.458	0.458	0.439
Scenario 9	0.738	0.738	0.728	0.732	0.337	0.337	0.265	0.182
Scenario 10	0.742	0.742	0.733	0.736	0.453	0.453	0.451	0.439

Tabela 18: Comparação de cenários com ajuste de parâmetros na classificação (10-fold)

Scenario	Decision Tree (CV) Accuracy	Decision Tree (CV) Recall	Decision Tree (CV) Precision	Decision Tree (CV) F1-score	Neural Network (CV) Accuracy	Neural Network (CV) Recall	Neural Network (CV) Precision	Neural Network (CV) F1-score
Scenario 1	0.542	0.542	0.531	0.528	0.409	0.409	0.406	0.392
Scenario 2	0.67	0.67	0.659	0.657	0.445	0.445	0.437	0.413
Scenario 3	0.743	0.743	0.734	0.737	0.413	0.413	0.421	0.398
Scenario 4	0.7	0.7	0.689	0.69	0.399	0.399	0.402	0.38
Scenario 5	0.739	0.739	0.73	0.733	0.334	0.334	0.253	0.169
Scenario 6	0.739	0.739	0.73	0.732	0.389	0.389	0.41	0.308
Scenario 7	0.757	0.757	0.75	0.753	0.417	0.417	0.409	0.385
Scenario 8	0.759	0.759	0.752	0.753	0.406	0.406	0.333	0.334
Scenario 9	0.759	0.759	0.753	0.755	0.346	0.346	0.28	0.202
Scenario 10	0.763	0.763	0.757	0.758	0.454	0.454	0.453	0.44

Best cenários:
Scenario 10 - Decision Tree (CV)
Scenario 9 - Decision Tree (CV)

Figura 15: Cenários com melhor desempenho na classificação com ajuste de parâmetros

Para o *clustering*, a opção por $k=2$ *clusters*, revelou-se mais eficaz do que soluções mais complexas, como, por exemplo, 3 *clusters*, que introduzia sobreposição excessiva, como já referimos anteriormente, com base na análise das Figuras 10 e 11.

Avaliação dos Resultados

Revisão dos Resultados de *Data Mining*

Os modelos desenvolvidos apresentam resultados promissores para atender às necessidades estratégicas do negócio. Na previsão de preços, conseguiu-se alcançar uma margem de erro aceitável (em torno de 2.1%), o que permite recomendações de precificação confiáveis para a maioria dos casos, especialmente quando consideramos a localização e tipo de propriedade. Para a classificação de disponibilidade, o modelo identifica padrões úteis, embora ainda possa ser aprimorado para lidar melhor com situações específicas. O modelo de *clustering* gerou resultados consistentes e úteis para interpretação de perfis de imóvel.

Os resultados mostram que já se consegue extrair bons *insights*, tais como:

- Entendimento claro de como diferentes bairros e tipos de propriedade afetam os preços;
- Identificação de faixas de preço críticas que influenciam a disponibilidade;
- Capacidade de prever tendências básicas de ocupação.

Embora os modelos atuais já possam ser implementados para apoiar decisões operacionais, ainda há espaço para melhorias antes de alcançar todo o potencial identificado nos objetivos iniciais. A versão atual serve como base sólida, mas recomenda-se um período de testes controlados antes da implementação completa. No geral, o projeto está bem encaminhado para entregar o valor esperado, mas requer mais alguns ajustes para atingir todo seu potencial.

Modelos Aprovados

Após uma análise detalhada dos resultados, disponíveis nas Tabelas 15, 16, 17 e 18 e nas Figuras 14 e 15, considerando os critérios de negócio estabelecidos, selecionou-se os seguintes modelos para implementação:

Para a regressão (previsão de preços), o Cenário 5 usando a rede neuronal foi escolhido como modelo principal, apresentando os melhores resultados tanto na validação 70%/30% (NMAE de 2.06% e RMSE de 142.64), na *cross-validation 5-fold* (NMAE de 2.09% e RMSE de 140.29). Este modelo incorpora variáveis críticas como tipo de propriedade, localização, número de avaliações, disponibilidade anual, tempo de estadia mínima, dados criminais e atrações próximas, demonstrando robustez e precisão consistentes. Como alternativa complementar, o Cenário 6 recorrendo novamente à rede neuronal no método 70/30, também foi aprovado, mostrando excelente estabilidade (NMAE de 2.08% em 70%/30% e 2.15% em *5-fold*). Este cenário, em relação ao 5, só difere na variável *serious_crimes* que foi retirada.




Figura 16: RSC - Cenário 5 (70/30)




Figura 17: Curvas REC - Cenário 5 (70/30)




Figura 18: RSC - Cenário 6 (70/30)




Figura 19: Curvas REC - Cenário 6 (70/30)

Os gráficos RSC (Figuras 16 e 18) mostram uma correlação moderada entre os valores reais e previstos, com $R^2 = 0.21$ para o cenário 5 e $R^2 = 0.22$ para o cenário 6, em ambos os modelos (o que significa que 21% e 22%, respetivamente, da variabilidade da variável price, pode ser explicada pelo modelo). Apesar do valor relativamente baixo de R^2 , os erros normalizados (NMAE) mantêm-se baixos, sugerindo uma boa capacidade de previsão em termos absolutos. As curvas REC (Figuras 17 e 19), foram utilizadas para avaliar a capacidade discriminativa dos modelos em prever intervalos de preços, demonstrando um bom desempenho relativo entre os cenários.

Para a classificação (previsão de sucesso com base na disponibilidade), a árvore de decisão do Cenário 10, usando o *10-fold*, mostrou ser a melhor opção, com *F1-Score* de 0.758 e acuidade de 76.3%, superando consistentemente as redes neurais em todos os cenários testados. Este modelo destaca-se por capturar eficientemente as interações entre bairro, preço e estadia mínima. O Cenário 9, também usando a árvore de decisão e recorrendo ao *10-fold*, foi selecionado como modelo secundário.




Figura 20: Matriz de confusão - Cenário 10 (10-fold)




Figura 21: Curvas ROC - Cenário 10 (10-fold) - High vs Low




Figura 22: Curvas ROC - Cenário 10 (10-fold) - High vs Medium




Figura 23: Curvas ROC - Cenário 10 (10-fold) - Low vs Medium

Na Figura 20, a matriz de confusão apresenta uma excelente performance na classe ‘Low’, com 4987 acertos, e zero falsos negativos, indicando que o modelo identifica perfeitamente os casos de baixo sucesso, que podem estar associados a mais dados por ter sido requisitado mais vezes. A classe ‘High’, apresentou um desempenho moderado (3455 acertos), mas com um problema significativo, onde identificou 1.316 instâncias erradamente como ‘Medium’. Por fim, na classe ‘Medium’, houve alguma dificuldade grave, ocorrendo 3005 classificações incorretas como ‘High’. Neste problema em questão, é pior a situação onde se classifica um sucesso alto e ser baixo, do que o contrário, sugerindo que o modelo nesse aspeto teve um bom desempenho, uma vez que aconteceu de a classe ser ‘High’ e identificar como ‘Low’ em 229 instâncias e o contrário apenas ter acontecido em 13.

Na Figura 21, é possível observar as curvas de ROC da árvore de decisão e da rede neuronal, considerando as classes ‘High’ e ‘Low’. A árvore de decisão apresenta um desempenho bastante bom, com AUC de 0.98. Para as classes ‘High’ e ‘Medium’ (Figura 22), o desempenho é mais baixo, com AUC de 0.68, e para as classes ‘Low’ e ‘Medium’ (Figura 23), o desempenho é intermédio, sendo obtido um AUC de 0.82. A rede neuronal obteve um AUC inferior para todos os casos, o que nos leva a escolher o Cenário 10 usando a árvore de decisão.




Figura 24: Matriz de confusão - Cenário 9 (10-fold)




Figura 25: Curvas ROC - Cenário 9 (10-fold) - High vs Low




Figura 26: Curvas ROC - Cenário 9 (10-fold) - High vs Medium




Figura 27: Curvas ROC - Cenário 9 (10-fold) - Low vs Medium

Na Figura 24, a matriz de confusão é referente ao Cenário 9 usando o 10-fold e árvore de decisão, que apesar de apresentar a mesma acuidade que o Cenário 8, as métricas *precision* e *F1-score* apresentam melhores resultados para o Cenário 9.

Neste Cenário, é possível constatar um desempenho excepcional do modelo na classe 'Low', mais uma vez, com 4997 classificações corretas e apenas 3 erros (como 'Medium'). Este resultado sugere uma forte capacidade do modelo em identificar corretamente situações de baixo sucesso. A classe 'High' apresentou um desempenho razoável, acertando 3417 vezes, mas com 1494 classificações incorretas como 'Medium', o que representa um número considerável de erros. No entanto, apenas 152 instâncias foram classificadas erradamente como 'Low', o que é positivo, considerando que é um maior risco classificar com alto um sucesso que na verdade é baixo. Já a classe 'Medium' mostrou ser a mais problemática, o que deve-se à sua posição intermediária e sem fronteiras claras em relação às outras duas categorias, com 1738 instâncias confundidas como 'High' e 223 como 'Low', totalizando 1961 erros.

As curvas de ROC comparam o desempenho da árvore de decisão e da rede neuronal. Na Figura 25, árvore de decisão apresenta um AUC de 0.99, demonstrando um ótimo desempenho discriminativo entre as classes 'High' e 'Low'. Para as classes 'High' e 'Medium' (Figura 26), o desempenho foi bastante mais baixo, tendo sido obtido um AUC de 0.66, e para as classes 'Low' e 'Medium' (Figura 27), o desempenho foi também intermédio, obtendo-se um AUC de 0.81. A rede neuronal obteve um AUC significativamente inferior para todos os casos, sugerindo um desempenho pouco confiável neste cenário. Este resultado reforça a escolha da árvore de decisão no Cenário 9, por oferecer melhor equilíbrio entre sensibilidade e especificidade.

Para o *clustering*, foi gerado um modelo com $k=2$ clusters, que nos permitiu dividir os imóveis em dois grupos, como se pode ver na Figura 28. O valor de *Silhouette Score* que obtivemos para esta divisão foi ~ 0.85 , o que indica uma excelente separação entre os *clusters*. Este valor, bastante elevado, confirma que os pontos dentro de cada grupo estão próximos entre si e afastados dos pontos do outro grupo, validando a segmentação em dois perfis bem distintos de imóveis: *Economic* e *Premium*.




Figura 28: Análise e classificação de 2 clusters

Tendo em conta que o preço está estabelecido por noite, a relação entre a variável *price* e a variável *minimum_nights* não é uma relação linear, pelo que foram separados os grupos e foi gerado um gráfico de dispersão para cada grupo que relaciona o número mínimo de noites e o preço total por esse mínimo exigido (Figuras 29 e 30).




Figura 29: Gráfico de dispersão de preço por número de noites para Airbnb Economic




Figura 30: Gráfico de dispersão de preço por número de noites para Airbnb Premium

Os gráficos das Figuras mostram uma tendência linear crescente clara nos dois segmentos. Para o grupo *Economic*, a maioria dos alojamentos apresenta preços totais até 20.000 dólares americanos, com uma progressão regular à medida que aumentam os requisitos mínimos de estadia. Para o grupo *Premium*, apesar da menor quantidade de alojamentos, os valores totais podem atingir 350.000 dólares americanos, com uma inclinação de crescimento mais acentuada e dispersão maior.

Estes gráficos mostram que, apesar da simplicidade das variáveis usadas, os clusters captam perfis de comportamento distintos, úteis para orientar decisões práticas.

Revisão do Processo

O desenvolvimento dos modelos seguiu uma abordagem metodológica. O processo executado compreendeu etapas essenciais como estruturação de cenários progressivos, que permitiu testar combinações de variáveis de forma sistemática, testes com diferentes algoritmos e metodologias e validação rigorosa. A decisão de comparar árvores de decisão com redes neurais mostrou-se acertada. A *cross-validation* implementada provou ser essencial para garantir a robustez dos modelos finais.

No entanto, identificamos várias oportunidades de melhoria. A fase de exploração dos dados inicial foi insuficiente, não antecipando os problemas específicos de classificação entre as categorias *High* e *Medium* que só apareceram tardiamente.

Determinação dos Próximos Passos

Lista de Ações Possíveis

Como parte da fase de definição de ações possíveis, foram delineadas várias iniciativas estratégicas com base na avaliação dos modelos desenvolvidos e nos requisitos do negócio. Uma das prioridades identificadas foi a integração de dados longitudinais, nomeadamente através da introdução de variáveis sazonais, com o objetivo de melhorar a capacidade preditiva dos modelos ao longo de diferentes épocas do ano. Para tal, seria essencial garantir a recolha e consolidação de dados históricos completos, abrangendo múltiplos anos.

Adicionalmente, foi identificada a oportunidade de enriquecer os dados descritivos das propriedades do Airbnb com atributos mais detalhados. Variáveis como o número de casas de banho, presença de eletrodomésticos ou comodidades específicas (ex.: ar condicionado, máquina de lavar, varanda, entre outros) são fatores que influenciam diretamente o preço dos Airbnb. A inclusão destes elementos teria potencial para aumentar significativamente a precisão dos modelos preditivos, especialmente no caso da regressão.

No entanto, durante o desenvolvimento deste projeto, não foi possível aceder a este nível de detalhe nos dados disponíveis, o que limitou a capacidade de aprofundar estes aspetos. Esta limitação representa uma oportunidade clara para futuras iterações do modelo, caso tais dados possam ser recolhidos ou integrados no futuro.

Decisão

Com base na avaliação dos modelos e na sua performance preditiva, foram tomadas decisões orientadas tanto pelos resultados quantitativos como pela aplicabilidade prática.

Para a regressão, foi selecionado o modelo da rede neuronal do Cenário 5 (70/30), que apresentou os melhores indicadores de desempenho, tanto em *holdout* como usando *cross-validation*. No caso da classificação, a decisão recaiu sobre a árvore de decisão do Cenário 10 (*10-fold*), que obteve o melhor *F1-Score* e acuidade entre os modelos testados. Para o *clustering*, optou-se pela separação dos dados em 2 *clusters*.


Foi ainda decidido não avançar nesta fase com a integração de variáveis sazonais nem com atributos mais detalhados dos apartamentos (como número de casas de banho ou eletrodomésticos), devido à indisponibilidade desses dados. No entanto, estas melhorias foram identificadas como prioridades para fases futuras, dado o seu potencial para aumentar a precisão e a utilidade dos modelos.

Planeamento da Avaliação dos Resultados

Para tornar os modelos de *machine learning* desenvolvidos neste projeto acessíveis de forma prática e intuitiva, foi definida uma estratégia de *deployment* que integra tanto o modelo de regressão (para prever o preço de um alojamento) como o modelo de classificação (para prever o sucesso do imóvel) e o modelo de *clustering* (para determinar o perfil de um alojamento). Foram desenvolvidas três aplicações *web* distintas para disponibilizar os modelos preditivos aos utilizadores finais. Foram todas construídas utilizando o *framework* *Flask* em Python, garantindo uma integração eficiente entre os modelos treinados e as interfaces de utilizador.


A aplicação de previsão de preços foi desenvolvida para ajudar anfitriões e investidores a estimar valores adequados para as suas propriedades. O sistema recebe como entrada, informações como tipo de quarto, localização, número de avaliações, disponibilidade anual, número mínimo de noites, ocorrência de crimes graves na área e quantidade de atrações turísticas próximas, como se pode ver na Figura 31. Esses dados são processados e submetidos ao modelo de regressão, desenvolvido usando a rede neuronal e o método 70/30, que retorna uma previsão de preço em dólares. A interface foi cuidadosamente desenhada para ser intuitiva, com um formulário claro e *feedback* imediato, incluindo mensagens de erro quando os dados inseridos são inválidos.

Para a classificação do sucesso das propriedades, foi criada uma aplicação separada que avalia o potencial de um anúncio com base em critérios mais específicos. Esta solução considera o tipo de alojamento, o bairro exato (com mais de 200 localizações), o preço praticado e o número mínimo de noites. Uma característica importante deste modelo é a criação de uma *feature* de interação que combina a localização com a duração mínima da estadia. O resultado é apresentado como uma classificação de sucesso em três níveis (baixo (*low*), médio (*medium*) ou alto (*high*)), traduzido de forma compreensível para o utilizador final. É possível observar a interface correspondente na Figura 32.



The screenshot shows a web form titled "\$ Airbnb NYC Price Prediction". It features several input fields with icons: a house icon for "Room Type" (dropdown menu with "Entire Home/ Apartment" selected), a location pin for "Neighbourhood Group" (dropdown menu with "Manhattan" selected), a star for "Number of Reviews" (text input), a calendar for "Availability in the last year (365 dias)" (text input), a moon for "Minimum of Nights" (text input), a shield for "Serious crimes recorded last year" (text input), and a building for "Number of attractions less than 2 kilometers" (text input). At the bottom is a blue button labeled "Predict Price".

Figura 31: Interface de previsão do preço dos alojamentos (regressão)



The screenshot shows a web form titled "Ad Success Rating". It features four input fields with icons: a house icon for "Room Type" (dropdown menu with "Entire Home/ Apartment" selected), a location pin for "Neighbourhood" (dropdown menu with "Allerton" selected), a dollar sign for "Price" (text input), and a moon for "Minimum of Nights" (text input). At the bottom is a pink button labeled "Rate Success".

Figura 32: Interface de classificação de sucesso dos anúncios (classificação)

Figura 33: Interface de determinação do perfil dos alojamentos (clustering)

Para a determinação do perfil dos alojamentos, foi criada uma outra aplicação, considerando o preço por noite e o número mínimo de noites. O resultado mostrará se o Airbnb pertence ao grupo de alojamentos económicos (*Economic*) ou *premium* (*Premium*). É possível observar a interface correspondente na Figura 33.

Planeamento da Monitorização e Manutenção

Foi criado um plano detalhado que foi concebido para assegurar a fiabilidade, performance e evolução contínua dos modelos analíticos utilizados no contexto do mercado imobiliário de Nova Iorque. Com base em princípios de monitorização automatizada, validação periódica e ciclos regulares de melhoria, o objetivo é garantir que as decisões baseadas em dados se mantenham relevantes, precisos e alinhados com a realidade do mercado em constante mudança. O documento está estruturado para cobrir todos os aspetos essenciais: desde a recolha e atualização contínua de dados até à implementação de novas versões de modelos com base em desempenho comprovado.

1. Monitorização Contínua com Dados de Mercado em Tempo Real

A integração com uma API de dados do mercado é essencial para garantir que os modelos operem com base em informações atualizadas e relevantes. Esta API irá consumir dados em tempo real sobre preços médios por zona geográfica, taxas de ocupação históricas e novas propriedades listadas. Além disso, a utilização de uma API dedicada ao registo de crimes graves será igualmente importante, permitindo a atualização automática deste tipo de dados e eliminando a necessidade de introdução manual por parte do utilizador. O desempenho dos modelos será validado periodicamente por meio de comparações entre o modelo atual e versões alternativas treinadas com os dados mais recentes.

2. Métricas de Monitorização Específicas por Modelo

Cada tipo de modelo será monitorizado com base em métricas-chave específicas. Os modelos de regressão, serão acompanhados pelo erro absoluto médio normalizado (NMAE), sendo que serão acionados alertas em casos como apresentado na Tabela 19. Modelos de classificação serão avaliados quanto à acuidade e ao *F1-Score*, com um limite de alerta definido pela acuidade. Já os modelos de *clustering* terão como métrica principal o *Silhouette Score*.

Tabela 19: Métricas de monitorização do desempenho dos modelos

Modelo	Métrica Principal	Limite de Alerta	Frequência
Regressão	NMAE	NMAE > 25%	Semestral
Classificação	Acuidade	Acuidade < 65%	Semestral
<i>Clustering</i>	<i>Silhouette Score</i>	<i>Silhouette Score</i> < 0.35	Anual

3. Processo de Validação de Modelos

O fluxo de atualização começa com a recolha automática dos dados, realizada diariamente através da API. Em seguida, os dados passam por um processo de pré-processamento, que inclui validação da qualidade, identificação de valores ausentes e deteção de *outliers*. O teste de desempenho é então aplicado tanto a modelos existentes (utilizando *cross validation* e *holdout* com os dados novos) quanto a modelos novos, que são comparados com a versão em produção. A decisão de substituição do modelo será tomada caso o novo modelo apresente uma melhoria de, no mínimo, 5% nas métricas principais. Caso contrário, mantém-se o modelo atual.

Todos os *notebooks*, *scripts* e modelos estarão devidamente armazenados e identificados num repositório Git (GitHub).

Será ainda instituído um processo de revisão regular:

- Revisão técnica semestral, com foco na validação estatística dos modelos e no desempenho em dados recentes;
- Revisão de negócio anual, com o objetivo de verificar se os modelos e, em especial, os *clusters* continuam alinhados com a realidade de mercado e com a evolução da procura.

Produção do Relatório Final

Relatório Final

A produção deste relatório foi realizada de forma contínua ao longo do desenvolvimento do projeto, acompanhando cada fase da metodologia CRISP-DM. O relatório reflete um registo progressivo e estruturado de decisões, análises, transformações de dados e validações realizadas durante todo o processo.

O projeto teve como objetivo principal analisar dados de Airbnb em Nova Iorque, em 2019, com foco na extração de conhecimento útil para anfitriões e investidores. Através da aplicação das diferentes etapas do CRISP-DM, foi possível atingir os seguintes marcos:

- **M1 – Business Understanding + Data Understanding:** Definição dos objetivos do negócio e exploração inicial do *dataset*. Foi realizada uma análise estatística e visual dos dados, com identificação de padrões e *outliers*.
- **M2 – Data Preparation:** Limpeza e transformação dos dados, incluindo remoção de colunas irrelevantes, tratamento de valores nulos, codificação de variáveis categóricas e filtragem manual de *outliers* com base em critérios estatísticos e de negócio. O conjunto de dados foi preparado para modelação, assegurando maior consistência e robustez.
- **M3 – Modeling + Evaluation + Deployment:**
 - Desenvolvimento de modelos de regressão para prever o preço por noite ($R^2 \approx 0.21$ e NMAE $\approx 2.06\%$), de modelos de classificação para prever o sucesso do imóvel (acuidade $\approx 76.3\%$) e de modelos de *clustering* para agrupar imóveis em segmentos (melhor resultado com 2 *clusters*);
 - Validação técnica dos modelos com métricas apropriadas (NMAE, acuidade, *Silhouette Score*), garantindo a adequação dos modelos aos objetivos definidos;
 - Definição de uma estratégia para aplicar os modelos num contexto real, para apoiar decisões de precificação, otimização de anúncios dos imóveis e análise de segmentos de mercado

Este relatório reflete a totalidade do trabalho desenvolvido, com base em dados reais, aplicando técnicas de *data science* de forma rigorosa e alinhada com objetivos de negócio concretos. Os resultados obtidos demonstram o potencial da aplicação de modelos preditivos e exploratórios no setor de alojamento local, permitindo apoiar a tomada de decisões com base em dados.

Apresentação Final

A apresentação final do projeto tem como objetivo comunicar os resultados obtidos e o valor potencial para o negócio. Esta reunião tem como foco explicar, de forma clara e orientada à decisão, como os modelos desenvolvidos podem apoiar anfitriões e investidores de Airbnb em Nova Iorque.

Na apresentação, são abordados, principalmente, os seguintes tópicos:

- Apresentação dos principais objetivos e critérios de sucesso;
- Compreensão e preparação dos dados para a criação dos modelos;
- Apresentação dos principais resultados dos modelos, incluindo estimações, previsões, segmentações e recomendações;
- Análise das interfaces criadas, com explicação da sua utilização.

O foco da apresentação é demonstrar o impacto direto dos modelos nas decisões operacionais e estratégicas do negócio, promovendo uma abordagem orientada a dados para a gestão de propriedades em plataformas como o Airbnb.

Revisão do Projeto

A realização deste projeto permitiu a cada elemento do grupo adquirir uma experiência prática abrangente na aplicação da metodologia CRISP-DM, desde a definição de objetivos de negócio até à proposta de implementação dos resultados num cenário realista. O trabalho permitiu consolidar conhecimentos técnicos e analíticos, mas também desenvolveu competências de planeamento, comunicação e adaptação face a desafios reais de dados.

Pontos Fortes do Projeto

- Aplicação rigorosa da metodologia CRISP-DM: todas as fases foram documentadas e executadas de forma lógica e coerente, com clareza nas transições entre tarefas.
- Exploração e preparação de dados bem estruturada: foi feita uma análise profunda dos dados iniciais, com identificação de *outliers*, análise visual clara e transformações bem justificadas.
- Processo de limpeza e tratamento de dados adequado: a utilização de critérios estatísticos (percentis e *z-scores*) e a posterior definição manual de limites realistas demonstraram pensamento crítico e bom senso na preparação dos dados.
- Modelos construídos com fundamentos sólidos: os modelos de regressão, classificação e *clustering* foram bem selecionados e avaliados com métricas apropriadas (NMAE, acuidade e *Silhouette Score*), atingindo bons resultados, especialmente na regressão e classificação.
- Proposta de aplicação realista e alinhada com o negócio: a definição de uma interface e um plano de manutenção prático mostra uma clara preocupação com a utilidade dos resultados no mundo real.

Pontos a Melhorar / Dificuldades Sentidas

- Qualidade e atualidade dos dados: embora o *dataset* de 2019 seja rico, a sua desatualização compromete parcialmente a validade dos modelos para aplicação direta no mercado atual. Uma melhoria futura será integrar dados mais recentes (via APIs, por exemplo).

- Fraca correlação entre variáveis e preço: foi necessário reconhecer que as variáveis disponíveis não explicam totalmente a variabilidade do preço, o que limitou a capacidade preditiva da regressão.
- Segmentação com sobreposição nos *clusters*: apesar do esforço na aplicação do *K-Means*, os resultados mostraram que os *clusters* tinham alguma sobreposição, o que sugere que as variáveis usadas não eram suficientes para uma segmentação fortemente distinta.

O projeto demonstrou que a ciência de dados aplicada a contextos reais exige tanto conhecimento técnico como capacidade de adaptação e espírito crítico. O grupo soube tomar decisões fundamentadas, justificar escolhas técnicas e refletir sobre as limitações dos dados. O equilíbrio entre rigor analítico e foco no negócio foi um aspeto especialmente bem conseguido.

No geral, este projeto constituiu uma experiência formativa e valiosa, que alia a teoria à prática e nos prepara para desafios reais na área da análise de dados.

Conclusão

Conclusão do M1 – *Business Understanding + Data Understanding*

Nesta primeira fase do projeto, foi estabelecido um entendimento claro dos objetivos do negócio e dos desafios do problema. Definiram-se métricas de sucesso para a previsão do preço, classificação do sucesso dos anúncios e segmentação das propriedades, garantindo uma abordagem estruturada para a análise dos dados.

A exploração inicial do *dataset* do Airbnb em Nova Iorque revelou padrões relevantes, como a concentração de alojamentos em Manhattan e Brooklyn, a variação significativa dos preços e a predominância de estadias curtas. Além disso, foram identificadas limitações nos dados, incluindo valores ausentes e *outliers* extremos, que podem impactar as análises futuras.

Desta forma, o “M1 – *Business Understanding + Data Understanding*” permitiu compreender o contexto do problema e avaliar a qualidade dos dados disponíveis, assegurando uma base sólida para a continuidade do estudo.

Com base nas análises realizadas, a próxima fase do projeto (“M2 – *Data Preparation*”) focar-se-á na preparação dos dados para a modelagem. Nesta etapa, serão aplicadas técnicas de limpeza e transformação de variáveis, garantindo que os dados estejam prontos para os modelos preditivos. Além disso, serão exploradas estratégias para tratar os *outliers* identificados e melhorar a qualidade dos dados, otimizando a precisão dos modelos a serem desenvolvidos nas fases seguintes.

Conclusão do M2 – *Data Preparation*

No âmbito da metodologia CRISP-DM, a fase “M2 – *Data Preparation*” representa a ponte entre a compreensão inicial dos dados e a aplicação de técnicas de modelação. Após o trabalho realizado na fase M1, esta etapa foi fundamental para transformar o *dataset* bruto num conjunto de dados limpo, coerente e enriquecido, apto para a análise preditiva.

Foram selecionadas apenas as variáveis mais relevantes, eliminando colunas com grande quantidade de valores omissos ou com baixa relevância para os objetivos do projeto. Adicionalmente, foram integradas fontes externas de dados, como indicadores de criminalidade e pontos de interesse turísticos, e aplicadas técnicas de codificação como *One-Hot Encoding* e *Inverse Document Frequency* (IDF), enriquecendo o *dataset* e aumentando o seu potencial explicativo.

A limpeza dos dados incluiu o tratamento dos valores nulos, bem como a identificação e remoção dos *outliers*, recorrendo a métodos estatísticos complementados por análise manual. Estas ações asseguraram a integridade e representatividade dos dados, reduzindo o risco de enviesamento nos modelos.

Adicionalmente foram realizados testes exploratórios com algoritmos de *clustering*, que, embora tenham revelado alguma sobreposição entre grupos, permitiram identificar padrões importantes relacionados com o preço e duração das estadias, fornecendo dicas importantes para a próxima fase.

Com a conclusão do M2, garante-se uma base sólida, estruturada e pronta para a última etapa do projeto: “M3 – *Modeling + Evaluation + Deployment*”, onde serão desenvolvidos e avaliados modelos preditivos com o objetivo de estimar preços, prever o sucesso dos anúncios e segmentar os alojamentos com maior previsão.

Conclusão do M3 – *Modeling + Evaluation + Deployment*

A fase “M3 – *Modeling + Evaluation + Deployment*” consolidou o trabalho desenvolvido nas etapas anteriores, traduzindo os dados preparados em modelos funcionais e úteis para responder aos objetivos definidos. Com base numa abordagem sistemática, foram aplicadas técnicas supervisionadas (redes neuronais e árvores de decisão) e não supervisionadas (*clustering K-Means*), permitindo responder aos três desafios centrais: previsão de preços (regressão), classificação do sucesso com base na disponibilidade (classificação) e segmentação de imóveis em perfil económico ou *premium* (*clustering*).

Em termos de modelação (*Modeling*), tanto na regressão como na classificação e *clustering*, a seleção priorizou modelos que combinam performance preditiva comprovada em múltiplos métodos de validação, estabilidade operacional com baixa variância nos resultados e relevância direta para as operações do negócio.

Os melhores desempenhos foram obtidos por redes neuronais na regressão (Cenário 5 com NMAE de 2.06%) e por árvores de decisão na classificação (Cenário 10 com acuidade de 76.3% e *F1-score* de 0.758). Estes valores cumprem claramente os critérios de sucesso de *Data Mining* definidos no *Business Understanding*, que exigiam, respetivamente, um NMAE $\leq 20\%$ e uma acuidade $\geq 70\%$. O modelo de *clustering* com $k=2$ atingiu um *Silhouette Score* de ~ 0.85 , muito acima do mínimo definido de 0.35, garantindo uma segmentação eficaz e interpretável.

Durante a avaliação (*Evaluation*), foi confirmado que os modelos cumprem os objetivos do negócio, ou seja, permitem prever preços com elevada precisão, identificar padrões associados ao sucesso dos anúncios e categorizar propriedades com base em perfis de mercado relevantes (económico vs. *premium*). Além disso, os modelos demonstraram robustez nas métricas e validações aplicadas, incluindo *holdout* e *cross-validation*, indicando que são generalizáveis para novos dados.

A fase de implementação (*Deployment*) foi concluída com sucesso através da criação de interfaces *web* acessíveis aos utilizadores finais, permitindo a utilização prática dos modelos em contexto real. Esta implementação operacional reforça o potencial do projeto para impactar positivamente decisões estratégicas de anfitriões e investidores na plataforma Airbnb.

Em suma, o projeto apresenta não só viabilidade técnica, como também valor prático, estando alinhado com os objetivos de negócio definidos. No entanto, foram também identificadas oportunidades de melhoria futura, como a incorporação de variáveis sazonais e atributos mais detalhados dos imóveis, que poderão aumentar ainda mais a precisão e utilidade dos modelos.

De acordo com os critérios de sucesso do negócio e os critérios de sucesso do *Data Mining*, definidos no *Business Understanding*, podemos concluir que obtivemos sucesso total no projeto e no desempenho dos modelos.